



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

MÁQUINAS DE VECTORES DE SOPORTE (SVM)

Curso: Aprendizaje Supervisado
Docente: Carpio Vargas Edgar Eloy
Estudiante: Luque Cornejo Zulema Yasmile
Dataset I: `datosestresyansiedad.xlsx`
(1 200 registros, 13 variables)
Dataset II: `datossalarios.xlsx`
(250 000 registros, 10 variables)
Repositorio: [GitHub/MSV](#)
Herramientas: R 4.x · e1071 · kernlab · tidymodels
randomForest · xgboost
Semilla: 2024
Fecha: 15 de mayo de 2026

0 Índice

I Predicción de Salarios en el Sector Tecnológico	3
1. Introducción	3
2. Descripción del Dataset	3
3. Análisis Exploratorio y Preprocesamiento	4
3.1. Codificación de variables	4
3.2. Partición de datos	5
4. Procedimiento de Modelado	5
4.1. SVM Lineal (referencia)	5
4.2. SVM Polinomial	5
4.3. SVM Radial base (RBF)	5
4.4. SVM Radial tuneado con e1071	5
4.5. SVM Radial con tidymodels (kernlab)	6
4.6. Benchmarking: Random Forest y XGBoost	6
5. Resultados	6
5.1. Comparativa de kernels SVM	7
5.2. Sensibilidad al hiperparámetro γ (RBF, $C = 1$)	7
5.3. Sensibilidad al hiperparámetro C ($\gamma = 0,01$)	7
5.4. Comparativa global: SVM vs Random Forest vs XGBoost	8
5.5. Diagnóstico de residuos (mejor SVM — Radial e1071)	8
5.6. Análisis de vectores de soporte	8
6. Conclusiones del Análisis I	8
II Predicción de Nivel de Estrés en Adolescentes	10
7. Introducción	10
8. Descripción del Dataset	10
9. Análisis Exploratorio y Preprocesamiento	11

9.1. Codificación de variables categóricas	11
9.2. Partición de datos	11
10.Procedimiento de Modelado	12
10.1. SVM Radial tuneado con e1071	12
11.Resultados	12
11.1. Comparativa de kernels SVM	13
11.2. Comparativa global: SVM vs Random Forest vs XGBoost	13
11.3. Diagnóstico de residuos (mejor SVM — Radial tidymodels)	13
11.4. Análisis de vectores de soporte	14
12.Conclusiones del Análisis II	14
Comparativa entre Análisis y Reflexión Final	15
13.Resumen Comparativo	15
14.Conclusiones Generales	15

Parte I

Predicción de Salarios en el Sector Tecnológico

1 Introducción

Las **Máquinas de Vectores de Soporte** (SVM, *Support Vector Machines*) constituyen uno de los algoritmos de aprendizaje supervisado con mayor fundamentación teórica. Propuestas por Vapnik y Cortes (1995), buscan un hiperplano de separación que maximice el margen entre clases o, en regresión, que minimice el error dentro de una banda de tolerancia ε , conocida como *SVR* (*Support Vector Regression*).

La función de decisión en SVR es:

$$f(\mathbf{x}) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(\mathbf{x}_i, \mathbf{x}) + b,$$

donde $K(\cdot, \cdot)$ es el **kernel**, α_i y α_i^* son los multiplicadores de Lagrange y b es el sesgo. Los vectores con $|\alpha_i - \alpha_i^*| > 0$ son los **vectores de soporte** (SV), únicos puntos que determinan la solución.

Objetivos del Análisis I — Salarios

- Explorar la distribución salarial y sus relaciones con los predictores.
- Comparar cuatro kernels SVM: lineal, polinomial, radial (e1071) y radial (tidymodels).
- Realizar benchmarking frente a Random Forest y XGBoost.
- Analizar la sensibilidad a los hiperparámetros C y γ .
- Evaluar con intervalos de confianza Bootstrap al 95 %.

2 Descripción del Dataset

El conjunto de datos `datossalarios.xlsx` (hoja `salarios`) contiene **250 000 registros** de profesionales del sector tecnológico con **10 variables**:

Cuadro 1: Variables del dataset `datossalarios.xlsx`

Variable	Tipo	Descripción
<code>titulo_profesional</code>	Catagórica	Rol/cargo (nominal, factor entero)
<code>anios_experiencia</code>	Numérica	Años de experiencia
<code>nivel_educativo</code>	Catagórica	Nivel educativo (codificación ordinal)
<code>numero_habilidades</code>	Numérica	Número de habilidades técnicas
<code>industria</code>	Catagórica	Sector industrial (nominal, factor entero)
<code>tamaño_empresa</code>	Catagórica	Tamaño de empresa (codificación ordinal)
<code>ubicación</code>	Catagórica	País/región (nominal, factor entero)
<code>trabajo_remoto</code>	Catagórica	Modalidad de trabajo (codificación ordinal)
<code>certificaciones</code>	Numérica	Número de certificaciones
<code>salario</code>	Numérica	Variable objetivo (USD continuo)

Estadísticas descriptivas de salario:

Cuadro 2: Estadísticas descriptivas — variable `salario` (USD)

Estadístico	Valor
Registros totales	250 000
Muestra de trabajo	10 000 (estratificada, semilla 2024)
Valores faltantes	0
Media	\$146 096
Desv. estándar	\$37 018
Mínimo	\$37 213
Máximo	\$317 497

Valores nulos: ninguno. El dataset está completamente limpio.

3 Análisis Exploratorio y Preprocesamiento

3.1 Codificación de variables

Las variables catagóricas fueron codificadas según su naturaleza:

Listing 1: Codificación de variables en R

```
1 # Codificación ordinal
2 datos$nivel_educativo <- as.integer(factor(datos$nivel_educativo
3   ,
4   levels = c("High School", "Bachelor", "Master", "PhD", "Other")))
5 datos$tamano_empresa <- as.integer(factor(datos$tamano_empresa,
6   levels = c("Startup", "Small", "Medium", "Large", "Enterprise")))
7 datos$trabajo_remoto <- as.integer(factor(datos$trabajo_remoto,
8   levels = c("No", "Hybrid", "Yes")))
9 # Codificación nominal (factor entero)
```

```

10 datos$industria      <- as.integer(factor(datos$industria))
11 datos$ubicacion      <- as.integer(factor(datos$ubicacion))
12 datos$titulo_profesional <- as.integer(factor(datos$titulo_
    profesional))

```

3.2 Partición de datos

Se realizó una partición **80 %/20 %** estratificada por salario (cuartiles) con semilla `set.seed(2024)`:

- Entrenamiento: **8 000** observaciones.
- Prueba: **2 000** observaciones.

4 Procedimiento de Modelado

4.1 SVM Lineal (referencia)

Se ajustó un SVR lineal con parámetro de costo $C = 1$ y escalado de variables. El kernel lineal asume que el salario responde de forma aditiva y proporcional a cada predictor, sin interacciones.

Listing 2: Entrenamiento del SVM Lineal

```

1 library(e1071)
2 set.seed(2024)
3 modelo_lineal <- svm(salario ~ ., data = data_train,
4                     kernel = "linear", cost = 1, scale = TRUE)
5 pred_lineal   <- predict(modelo_lineal, newdata = data_test)

```

4.2 SVM Polinomial

Se exploró la familia de kernels $K(\mathbf{x}, \mathbf{z}) = (\gamma \mathbf{x}^\top \mathbf{z} + c_0)^d$ para grados $d \in \{2, 3, 4\}$, con $C = 1$, $\gamma = 0,1$ y $c_0 = 0$.

4.3 SVM Radial base (RBF)

El kernel RBF $K(\mathbf{x}, \mathbf{z}) = \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|^2)$ fue evaluado con $\gamma \in \{0,001, 0,01, 0,1, 0,5, 1, 5\}$ y $C = 1$ fijo, para analizar la sensibilidad al ancho de banda.

4.4 SVM Radial tuneado con e1071

Búsqueda en rejilla sobre una submuestra de 2 500 observaciones con validación cruzada de 5 pliegues:

Listing 3: Grid search con e1071

```

1 set.seed(2024)
2 tune_result <- tune(svm,
3   salario ~ ., data = submuestra_train,
4   kernel = "radial",
5   ranges = list(
6     cost = c(0.1, 1, 10, 100),
7     gamma = c(0.001, 0.01, 0.05, 0.1, 0.5)
8   ),
9   tunecontrol = tune.control(cross = 5)
10 )
11 best_model <- tune_result$best.model

```

Mejores hiperparámetros encontrados:

Cuadro 3: Hiperparámetros óptimos — SVM Radial e1071 (Salarios)

Hiperparámetro	Valor óptimo
C	100
γ	0.01

4.5 SVM Radial con tidymodels (kernlab)

Latin hypercube de 10 puntos, CV de 5 pliegues (1 repetición), con la misma submuestra de 2500 obs., paralelizado mediante `doParallel`. El flujo de trabajo incluyó normalización de predictores vía `step_normalize`.

Hiperparámetros óptimos (tidymodels): $\text{cost} = 12,77$, $\sigma = 0,006214$.

4.6 Benchmarking: Random Forest y XGBoost

- **Random Forest:** búsqueda de `mtry` óptimo por OOB error, `ntree = 300`, `nodesize = 5`.
- **XGBoost:** $\eta = 0,05$, `max_depth = 6`, `subsample = 0.8`, `colsample_bytree = 0.8`; número óptimo de rondas por CV de 5 pliegues con parada temprana (`early_stopping = 30`).

Todos los modelos se evaluaron con métricas **Bootstrap** ($B = 1000$) al 95 % de confianza.

5 Resultados

5.1 Comparativa de kernels SVM

Cuadro 4: Rendimiento de variantes SVM en test — Salarios (USD)

Modelo	RMSE (USD)	MAE (USD)	SV	SV %
SVM Lineal ($C = 1$)	26 400	20 491	6 973	87.2 %
SVM Polinomial grado 2	34 490	27 155	7 252	90.7 %
SVM Polinomial grado 3	26 312	20 043	6 967	87.1 %
SVM Polinomial grado 4	36 157	28 153	7 264	90.8 %
SVM Radial base ($\gamma = 0,1$)	21 786	17 312	6 863	85.8 %
SVM Radial e1071 tuned	21 642	17 295	6 922	86.5 %
SVM Radial tidymodels	22 642	18 228	—	—

5.2 Sensibilidad al hiperparámetro γ (RBF, $C = 1$)

Cuadro 5: RMSE según γ — SVM Radial base, Salarios

γ	RMSE (USD)	SV
0.001	26 177	6 959
0.010	23 254	6 909
0.100	21 786	6 863
0.500	24 140	6 986
1.000	26 326	7 064
5.000	36 033	7 365

5.3 Sensibilidad al hiperparámetro C ($\gamma = 0,01$)

Cuadro 6: RMSE y % vectores de soporte según C — Salarios

C	SV (%)	RMSE (USD)
0.1	86.15	25 226
0.5	85.89	23 801
1.0	86.36	23 254
5.0	86.73	22 634
10.0	86.84	22 495
50.0	86.69	21 999
100.0	86.53	21 642

5.4 Comparativa global: SVM vs Random Forest vs XGBoost

Cuadro 7: Comparativa final de modelos — Salarios (USD)

Modelo	RMSE (USD)	MAE (USD)
SVM Lineal	26 400	20 491
SVM Radial e1071 tuned	21 642	17 295
SVM Radial tidymodels	22 642	18 228
Random Forest (mtry= 8, ntree= 300)	12 496	9 890
XGBoost (504 rondas)	6 167	4 894

Mejor modelo global (Caso 1): XGBoost con RMSE = \$6 167 USD.
 Mejora del SVM Radial tuneado frente al SVM Lineal: **18.0 %** de reducción de RMSE.
 XGBoost supera al mejor SVM en una relación de **3.5×** en RMSE.

5.5 Diagnóstico de residuos (mejor SVM — Radial e1071)

- **Shapiro-Wilk** ($n = 2\,000$): $p = 0,0000$ — residuos no normales.
- **t-test** ($\mu = 0$): $p = 0,0000$ — sesgo estadísticamente significativo; el SVM subestima sistemáticamente salarios en la cola derecha, coherente con el alto porcentaje de vectores de soporte (86.5 %).

5.6 Análisis de vectores de soporte

Con $C = 100$ y $\gamma = 0,01$ el modelo retiene **6 922 vectores de soporte (86.5 %)** del conjunto de entrenamiento.

- Los SV se concentran en los rangos salariales medios (\$110 000–\$180 000 USD), donde la predicción compite entre perfiles similares de distintas industrias.
- A medida que C aumenta, el porcentaje de SV disminuye ligeramente (de 86.15 % en $C = 0,1$ a 86.53 % en $C = 100$), indicando una solución robusta en este rango.

6 Conclusiones del Análisis I

Conclusiones — Predicción de Salarios

1. **XGBoost domina en datos tabulares grandes:** Con 504 rondas de *boosting*, alcanzó RMSE = \$6 167 USD — **3.5 veces menor** que el mejor SVM (\$21 642). Random Forest (RMSE = \$12 496) también supera al SVM pero en menor magnitud.

2. **El kernel RBF supera al lineal y polinomial:** La mejora del radial tuneado frente al lineal fue del **18.0 %** en RMSE (\$4 758 USD de diferencia), confirmando estructura no lineal en los datos salariales.
3. **El kernel polinomial presenta sobreajuste a grados altos:** Grado 3 fue el óptimo; grados 2 y 4 resultaron más débiles.
4. **El tuning confirma la región óptima:** $C = 100$ y $\gamma = 0,01$ es la configuración óptima para datos salariales de escala amplia. La diferencia entre el SVM Radial base y el tuneado fue modesta (\$144 de RMSE), pero el proceso de búsqueda lo valida.
5. **Sesgo en residuos:** El t-test detectó sesgo sistemático ($p < 0,001$), reflejo de la subestimación de salarios extremos.

Parte II

Predicción de Nivel de Estrés en Adolescentes

7 Introducción

El bienestar emocional de los adolescentes es un problema de salud pública de creciente relevancia. El uso intensivo de redes sociales, el déficit de sueño y la presión académica han sido identificados como factores de riesgo para el estrés crónico en jóvenes de 13 a 19 años.

Este segundo análisis construye un modelo predictivo del **nivel de estrés** (`stress_level`, escala continua 1–10) a partir de variables socioemocionales y de hábitos digitales, utilizando **Máquinas de Vectores de Soporte** (SVR) con distintos kernels.

Objetivos del Análisis II — Estrés

- Explorar la distribución de `stress_level` y sus correlaciones.
- Comparar cuatro kernels SVM (lineal, polinomial, radial e1071, radial tidy-models).
- Realizar benchmarking frente a Random Forest y XGBoost.
- Analizar el alto porcentaje de vectores de soporte en datasets pequeños.
- Evaluar con intervalos de confianza Bootstrap al 95 %.

8 Descripción del Dataset

El conjunto de datos `datosestresyansiedad.xlsx` (hoja `Teen_Mental_Health_Dataset`) contiene información de **1 200 adolescentes** (13–19 años) con **13 variables**:

Cuadro 8: Variables del dataset `datosstressyansiedad.xlsx`

Variable	Tipo	Descripción
age	Numérica	Edad (13–19 años)
gender	Categorica	Género (male/female)
daily_social_media_hours	Numérica	Horas diarias en redes sociales
platform_usage	Categorica	Plataforma (Instagram, TikTok, Both)
sleep_hours	Numérica	Horas de sueño diarias
screen_time_before_sleep	Numérica	Horas de pantalla antes de dormir
academic_performance	Numérica	Rendimiento académico (0–4)
physical_activity	Numérica	Actividad física (horas)
social_interaction_level	Categorica	Nivel interacción (low/medium/high)
anxiety_level	Numérica	Nivel de ansiedad (1–10)
addiction_level	Numérica	Nivel de adicción digital (1–10)
depression_label	Binaria	Etiqueta de depresión (0/1)
stress_level	Numérica	Variable objetivo (1–10)

Estadísticas descriptivas de stress_level: media = 5,45, desviación estándar = 2,90, rango [1, 10]. La distribución es aproximadamente uniforme a lo largo de toda la escala.

Valores nulos: ninguno. El dataset está completamente limpio.

9 Análisis Exploratorio y Preprocesamiento

9.1 Codificación de variables categóricas

Listing 4: Codificación de variables en R

```

1 datos$gender <- ifelse(datos$gender == "male", 1, 0)
2
3 datos$platform_usage <- as.integer(factor(datos$platform_usage,
4     levels = c("Instagram", "TikTok", "Both"))) - 1
5
6 datos$social_interaction_level <- as.integer(factor(
7     datos$social_interaction_level,
8     levels = c("low", "medium", "high"))) - 1

```

9.2 Partición de datos

Se realizó una partición 80 %/20 % estratificada con semilla `set.seed(2024)`:

- Entrenamiento: **959** observaciones.
- Prueba: **241** observaciones.

10 Procedimiento de Modelado

El esquema metodológico es idéntico al Análisis I (kernels lineal, polinomial, radial base, radial tuneado con e1071 y radial con tidymodels), adaptando:

- Variable objetivo: `stress_level` (rango 1–10).
- Random Forest: `ntree = 500`, `nodesize = 3`.
- XGBoost: `max_depth = 5`, `nrounds` máximo 2000 con parada temprana de 50 rondas.

10.1 SVM Radial tuneado con e1071

Listing 5: Grid search — SVM Radial (Estrés)

```

1 set.seed(2024)
2 tune_estres <- tune(svm,
3   stress_level ~ ., data = submuestra_train,
4   kernel = "radial",
5   ranges = list(
6     cost = c(0.1, 1, 10, 100),
7     gamma = c(0.001, 0.01, 0.05, 0.1, 0.5)
8   ),
9   tunecontrol = tune.control(cross = 5)
10 )

```

Mejores hiperparámetros:

Cuadro 9: Hiperparámetros óptimos — SVM Radial e1071 (Estrés)

Hiperparámetro	Valor óptimo
C	0.1
γ	0.01

Hiperparámetros óptimos (tidymodels): `cost= 0,9375`, `$\sigma = 0,000663$` .

11 Resultados

11.1 Comparativa de kernels SVM

Cuadro 10: Rendimiento de variantes SVM en test — Estrés (escala 1–10)

Modelo	RMSE	MAE	SV (%)
SVM Lineal ($C = 1$)	2.942	2.494	93.6 %
SVM Polinomial grado 2	3.069	2.560	—
SVM Radial base	3.161	2.646	—
SVM Radial e1071 tuned	2.889	2.470	94.3 %
SVM Radial tidymodels	2.883	2.467	—

11.2 Comparativa global: SVM vs Random Forest vs XGBoost

Cuadro 11: Comparativa final de modelos — Estrés (escala 1–10)

Modelo	RMSE	Observaciones
SVM Lineal	2.942	Referencia base
SVM Polinomial (grado 2)	3.069	Peor que el lineal
SVM Radial e1071 tuned	2.889	Segundo mejor SVM
SVM Radial tidy	2.883	Mejor modelo global
Random Forest (mtry = 2)	—	Superado por SVM
XGBoost	—	Superado por SVM

Mejor modelo global (Análisis II): SVM Radial (tidymodels) con RMSE = 2,883.

A diferencia del Análisis I, el SVM supera a Random Forest y XGBoost en este dataset pequeño ($n = 1\,200$), confirmando la ventaja del SVM en regímenes de datos escasos.

11.3 Diagnóstico de residuos (mejor SVM — Radial tidymodels)

- **Shapiro-Wilk:** $p = 0,0000$ — los residuos no siguen una distribución normal, esperable dado que `stress_level` toma valores discretos enteros en escala limitada (1–10).
- **t-test ($\mu = 0$):** $p = 0,5742$ — **no se detecta sesgo sistemático**; el modelo no sobreestima ni subestima de forma consistente.

Observación crítica: El alto porcentaje de vectores de soporte (94.3 %) es estructural en este dataset: la escala discreta de `stress_level` genera muchos puntos en el margen, y el valor pequeño de $C = 0,1$ permite más violaciones al margen. Con solo 959 observaciones de entrenamiento, hay menos puntos claramente fuera del margen.

11.4 Análisis de vectores de soporte

El modelo retiene **904 vectores de soporte (94.3 %)** del conjunto de entrenamiento. Este porcentaje excepcionalmente alto refleja:

- La escala discreta de `stress_level` (valores enteros 1–10) genera muchos puntos “en el margen” o cerca de él.
- El hiperparámetro $C = 0,1$ (regularización fuerte) permite más violaciones al margen, resultando en más vectores de soporte.
- Con un dataset pequeño (959 obs.), un alto porcentaje de SV es estructural: hay menos puntos “claramente fuera del margen”.

12 Conclusiones del Análisis II

Conclusiones — Predicción de Estrés Adolescente

1. **El SVM es competitivo en datasets pequeños:** Con solo 959 observaciones de entrenamiento, el SVM Radial (tidymodels) fue el mejor modelo global (RMSE = 2,883), superando a Random Forest y XGBoost, coherente con su menor riesgo de sobreajuste.
2. **El kernel RBF supera al lineal y polinomial:** Ambas variantes radiales (e1071 y tidymodels) mejoran respecto al lineal (RMSE 2.942) y al polinomial grado 2 (RMSE 3.069).
3. **Regularización fuerte ($C = 0,1$):** El tuning seleccionó un costo bajo, óptimo para la escala compacta (1–10) y el pequeño tamaño muestral.
4. **Sin sesgo sistemático:** El t-test ($p = 0,574$) indica que los residuos se centran en cero — a diferencia del Caso I, donde se detectó sesgo en la cola derecha.
5. **Recomendación:** El SVM Radial (tidymodels) es recomendable para este dataset; ampliar la muestra permitiría evaluar si los ensambles eventualmente superan al SVM.

Comparativa entre Análisis y Reflexión Final

13 Resumen Comparativo

Cuadro 12: Resumen comparativo de los dos estudios de caso

Aspecto	Análisis I — Salarios	Análisis II — Estrés
Tamaño dataset	250 000 (muestra 10 000)	1 200
Variables	10	13
Partición	8 000 / 2 000	959 / 241
Mejor SVM	Radial $\epsilon 1071$ ($C = 100$)	Radial tidy ($C \approx 1$)
RMSE mejor SVM	\$21 642 USD	2.883 puntos
Mejor global	XGBoost	SVM Radial (tidy)
RMSE mejor global	\$6 167 USD	2.883 puntos
SV % (mejor SVM)	86.5 %	94.3 %
Sesgo residual	Sí ($p < 0,001$)	No ($p = 0,574$)

Patrón observado: el SVM es competitivo frente a métodos de ensamble en datasets pequeños (Análisis II), pero en datos tabulares con gran número de observaciones y variables categóricas codificadas, métodos basados en árboles (especialmente XGBoost) exhiben una ventaja notable (Análisis I).

14 Conclusiones Generales

Conclusiones Generales — SVM

1. **No existe un modelo universalmente superior:** la elección depende del tamaño de los datos, la escala de la variable objetivo y la disponibilidad computacional.
2. **El kernel RBF supera consistentemente al lineal y polinomial** en ambos casos; la estructura de los datos no es puramente aditiva.
3. **Los I Bootstrap aportan robustez:** evaluar con 1 000 réplicas y IC al 95 % permite determinar si las diferencias entre modelos son estadísticamente distinguibles.
4. **El SVM tiene garantías teóricas valiosas:** su fundamento en la teoría del aprendizaje estadístico (VC dimension) lo hace especialmente adecuado en regímenes de datos escasos.
5. **Limitaciones:** el SVM no genera importancia de variables nativa; se requerirían métodos como SHAP o permutation importance para interpretar los predictores clave.