



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

REDES NEURONALES ARTIFICIALES PARA REGRESIÓN SUPERVISADA

Curso: Aprendizaje Supervisado
Docente: Carpio Vargas Edgar Eloy
Estudiante: Luque Cornejo Zulema Yasmile
Dataset I: *Teen Mental Health Dataset* (1 200 registros)
Dataset II: *Salarios Tech Dataset* (250 000 registros)
Tecnologías: Python 3.10 · TensorFlow/Keras
scikit-learn
Repositorio: [GitHub/REDES_NEURONALES](https://github.com/REDES_NEURONALES)
Fecha: 22 de mayo de 2026

Índice

1. Introducción	2
2. Marco Teórico	2
2.1. Redes Neuronales para Regresión	2
2.2. Función de Pérdida y Métricas	2
2.3. Técnicas de Regularización	3
3. Experimento I: Nivel de Estrés en Adolescentes	3
3.1. Descripción del Dataset	3
3.2. Estadísticas Descriptivas	4
3.3. Preprocesamiento	4
3.3.1. Codificación de Variables Categóricas	4
3.3.2. División del Dataset	5
3.3.3. Escalado de Variables	5
3.4. Arquitectura de la Red Neuronal	5
3.5. Resultados	6
3.5.1. Curvas de Aprendizaje	6
3.5.2. Métricas en Conjunto de Prueba	6
3.5.3. Análisis de Residuos	7
3.5.4. Importancia de Variables	7
3.5.5. Predicciones sobre Perfiles de Ejemplo	8
4. Experimento II: Predicción de Salarios en el Sector Tech	8
4.1. Descripción del Dataset	8
4.2. Preprocesamiento	8
4.2.1. Codificación de Variables Categóricas	9
4.2.2. División del Dataset	9
4.3. Arquitectura de la Red Neuronal	9
4.4. Resultados	9
4.4.1. Curvas de Aprendizaje	9
4.4.2. Métricas en Conjunto de Prueba	10
4.4.3. Análisis de Residuos	10
4.4.4. Importancia de Variables	11
4.4.5. Predicciones sobre Perfiles de Ejemplo	11
5. Comparación entre Modelos	11
5.1. Resultados Comparativos	12
5.2. Diferencias de Diseño	12
5.3. Justificación de las Diferencias Arquitectónicas	12
6. Conclusiones	13
6.1. Conclusiones Técnicas	13
6.2. Conclusiones Sustantivas	13
6.2.1. Sobre el estrés en adolescentes	13
6.2.2. Sobre los salarios en el sector tech	13

1. Introducción

Las redes neuronales artificiales (RNA) constituyen una de las herramientas más versátiles del aprendizaje automático moderno. Su capacidad para modelar relaciones no lineales complejas entre variables las convierte en una alternativa poderosa frente a los métodos de regresión clásicos, especialmente cuando los datos presentan interacciones de alto orden o distribuciones no gaussianas.

El presente informe documenta el diseño, implementación y evaluación de dos modelos de regresión basados en redes neuronales profundas (*deep learning*), desarrollados sobre datasets de naturaleza sociológica y laboral:

1. **Predicción del nivel de estrés en adolescentes** a partir de hábitos digitales, sueño, rendimiento académico y salud mental, con el objetivo de comprender los factores de riesgo psicosocial en jóvenes.
2. **Predicción de salarios en el sector tecnológico** a partir de variables profesionales como experiencia, educación, industria y modalidad de trabajo, con aplicación directa en decisiones de contratación y estrategia salarial.

2. Marco Teórico

2.1. Redes Neuronales para Regresión

Una red neuronal de regresión aproxima una función $f : \mathbb{R}^p \rightarrow \mathbb{R}$ que mapea un vector de p características $\mathbf{x}$ hacia una salida continua $\hat{y}$. Cada neurona en la capa l computa:

$$\mathbf{a}^{(l)} = \sigma(\mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}) \quad (1)$$

donde $\mathbf{W}^{(l)}$ son los pesos, $\mathbf{b}^{(l)}$ los sesgos y σ la función de activación. En ambos modelos se emplea **ReLU** en las capas ocultas:

$$\text{ReLU}(z) = \max(0, z) \quad (2)$$

y activación **lineal** en la capa de salida, apropiada para tareas de regresión.

2.2. Función de Pérdida y Métricas

El entrenamiento minimiza el **Error Cuadrático Medio** (MSE):

$$\mathcal{L}_{\text{MSE}} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3)$$

Las métricas de evaluación en el conjunto de prueba son:

$$\text{RMSE} = \sqrt{\mathcal{L}_{\text{MSE}}} \quad (4)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5)$$

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad (6)$$

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (7)$$

2.3. Técnicas de Regularización

Para controlar el sobreajuste (*overfitting*) se utilizan tres mecanismos complementarios:

Regularización L_2

Añade una penalización $\lambda \|\mathbf{W}\|^2$ a la pérdida, desalentando pesos de gran magnitud. Se aplica con $\lambda = 0,001$ en las dos primeras capas ocultas.

Batch Normalization

Normaliza las activaciones de cada mini-lote, estabilizando el gradiente y permitiendo tasas de aprendizaje más altas.

Dropout Desactiva aleatoriamente una fracción p de neuronas durante el entrenamiento, equivalente a entrenar un conjunto de subredes. Se aplica con tasas decrecientes: 30 %, 20 % y 10 % en las tres primeras capas ocultas.

3. Experimento I: Nivel de Estrés en Adolescentes

3.1. Descripción del Dataset

El dataset *Teen Mental Health Dataset* contiene información de **1,200 adolescentes** (edades 13–19 años) con 13 variables que caracterizan sus hábitos digitales, académicos y de salud mental. No presenta valores nulos en ninguna columna.

Cuadro 1: Descripción de variables — Dataset de Estrés

Variable	Descripción	Tipo
age	Edad del adolescente (13–19 años)	Numérica
gender	Género (<i>male</i> / <i>female</i>)	Categórica binaria
daily_social_media_hours	Horas diarias en redes sociales	Numérica
platform_usage	Plataforma principal (Instagram / TikTok / Both)	Categórica nominal
sleep_hours	Horas de sueño por noche	Numérica
screen_time_before_sleep	Tiempo de pantalla antes de dormir (h)	Numérica
academic_performance	Rendimiento académico (GPA estimado)	Numérica
physical_activity	Actividad física diaria (horas)	Numérica
social_interaction_level	Nivel de interacción social (low/medium/high)	Categórica ordinal
anxiety_level	Nivel de ansiedad (escala 1–10)	Numérica
addiction_level	Nivel de adicción a redes (escala 1–10)	Numérica
depression_label	Indicador de depresión (0 = no, 1 = sí)	Binaria
stress_level	Variable objetivo: nivel de estrés (1–10)	Numérica

3.2. Estadísticas Descriptivas

El dataset presenta las siguientes características en la variable objetivo y las principales predictoras numéricas:

Cuadro 2: Estadísticas descriptivas — Variables clave (Dataset Estrés)

Variable	Media	Std	Mín	Mediana	Máx
age	15.93	2.02	13	16.0	19
daily_social_media_hours	4.54	2.03	1	4.5	8
sleep_hours	6.45	1.44	4	6.5	9
screen_time_before_sleep	1.74	0.72	0.5	1.8	3
anxiety_level	5.64	2.86	1	6.0	10
addiction_level	5.57	2.83	1	6.0	10
stress_level	5.45	2.90	1	5.0	10

3.3. Preprocesamiento

3.3.1. Codificación de Variables Categóricas

Dado que las redes neuronales operan sobre valores numéricos, las variables categóricas fueron transformadas mediante los siguientes esquemas:

Cuadro 3: Esquemas de codificación — Dataset de Estrés

Variable	Tipo	Método	Valores resultantes
gender	Binaria	Binario	male=0, female=1
platform_usage	Nominal	One-Hot Encoding	3 columnas dummy
social_interaction_level	Ordinal	Codificación ordinal	low=0, medium=1, high=2

El resultado final fue un vector de **14 features** por observación.

3.3.2. División del Dataset

Se aplicó una división en tres conjuntos sin solapamiento:

$$\underbrace{70\%}_{\text{Entrenamiento}} + \underbrace{15\%}_{\text{Validación}} + \underbrace{15\%}_{\text{Prueba}} = 100\% \implies 840 + 180 + 180 = 1,200 \text{ muestras} \quad (8)$$

3.3.3. Escalado de Variables

Se aplicó **StandardScaler** tanto a las features **X** como a la variable objetivo *y*, ajustando los parámetros *únicamente sobre el conjunto de entrenamiento*:

$$x' = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}} \quad (9)$$

Este procedimiento evita el *data leakage*, garantizando que la información de validación y prueba no influya en la normalización.

3.4. Arquitectura de la Red Neuronal

Cuadro 4: Arquitectura — Modelo de Estrés (13,569 parámetros totales)

Capa	Tipo	Unidades	Activación	Reg. L_2	Dropout
Entrada	Input	14	—	—	—
1	Dense + BN	128	ReLU	0.001	0.30
2	Dense + BN	64	ReLU	0.001	0.20
3	Dense	32	ReLU	—	0.10
4	Dense	16	ReLU	—	—
Salida	Dense	1	Lineal	—	—

- **Optimizador:** Adam con $\eta_0 = 0,001$
- **Función de pérdida:** MSE

- **Métrica de monitoreo:** MAE
- **Épocas máximas:** 300 | **Batch size:** 32
- **Early Stopping:** patience = 30 épocas
- **ReduceLROnPlateau:** factor = 0.5, patience = 15 épocas

3.5. Resultados

3.5.1. Curvas de Aprendizaje

El entrenamiento finalizó en **37 épocas** (el modelo recuperó los pesos de la época 7, la mejor). El Early Stopping se activó debido a que la pérdida de validación no mejoró en las últimas 30 épocas. El comportamiento de las curvas muestra que la pérdida de validación (*val_loss*) se mantuvo por encima de la de entrenamiento desde épocas tempranas, lo que indica las limitaciones del modelo ante el tamaño reducido del dataset.

Cuadro 5: Evolución del entrenamiento — Hitos clave (Modelo Estrés)

Época	Train Loss	Train MAE	Val Loss	Val MAE	LR
1	1.5318	0.9803	1.0278	0.8324	0.001
7	1.0601	0.8295	1.0006	0.8116	0.001
22	0.9371	0.7726	1.0984	0.8531	0.001 → 0.0005
37	0.9385	0.7670	1.1051	0.8541	<i>Early Stop</i>

3.5.2. Métricas en Conjunto de Prueba

Métrica	Fórmula	Valor obtenido
MSE	$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$	7.5787
RMSE	$\sqrt{\text{MSE}}$	2.7529 puntos
MAE	$\frac{1}{n} \sum y_i - \hat{y}_i $	2.3452 puntos
MAPE	$\frac{100}{n} \sum \left \frac{y_i - \hat{y}_i}{y_i} \right $	86.41 %
R^2	$1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$	0.0165 (1.6 %)

Interpretación: El modelo se equivoca en promedio ± 2.35 puntos de estrés (en una escala 1–10) y explica únicamente el **1.6 %** de la variabilidad del nivel de estrés. Estos resultados indican que el modelo **no logró aprender patrones predictivos significativos** a partir de las variables disponibles.

3.5.3. Análisis de Residuos

Los residuos $e_i = y_i - \hat{y}_i$ presentan una media de $-0,04$ (prácticamente centrada en cero, sin sesgo sistemático). Sin embargo, la alta dispersión (± 2.35 puntos) y el patrón en el gráfico de residuos vs. predichos —donde las predicciones convergen hacia la media de la distribución— confirman que el modelo esencialmente predice valores cercanos a la media del *stress_level* (5.45) sin discriminar entre casos de bajo y alto estrés.

3.5.4. Importancia de Variables

Método de pesos de la primera capa Las cinco variables con mayor importancia estimada fueron:

Cuadro 6: Top 5 variables — Importancia por pesos (Modelo Estrés)

Variable	Importancia relativa (%)
platform_TikTok	7.6 %
academic_performance	7.6 %
addiction_level	7.5 %
sleep_hours	7.5 %
platform_Both	7.4 %

Nótese que las importancias son muy similares entre sí (rango 6.3 %–7.6 %), lo que sugiere que la red no logró identificar predictores claramente dominantes. Esto es consistente con el bajo R^2 obtenido.

Permutation Importance La caída en R^2 al permutar cada variable confirma que ningún predictor individualmente tiene un impacto decisivo. Las variables con mayor caída fueron:

Cuadro 7: Top 8 variables — Permutation Importance (Modelo Estrés)

Variable	Caída en R^2
physical_activity	0.0189
social_enc	0.0157
sleep_hours	0.0141
age	0.0104
depression_label	0.0089
screen_time_before_sleep	0.0068
gender_enc	0.0063
academic_performance	0.0056

Algunas variables mostraron caídas negativas al ser permutadas (*platform_Instagram*: $-0,0262$; *platform_TikTok*: $-0,0148$; *addiction_level*: $-0,0061$), lo que indica que su permutación *mejora* ligeramente el R^2 base, señal adicional de que el modelo no las aprovecha de forma útil.

3.5.5. Predicciones sobre Perfiles de Ejemplo

Cuadro 8: Perfiles de ejemplo — Predicción de estrés

Perfil	Sueño (h)	Redes (h/día)	Ansiedad	Estrés predicho
Bajo riesgo	8.5	1.5	2	5.68
Alto riesgo	4.5	7.5	9	7.33
Perfil promedio	6.5	4.0	5	5.07

Aunque la dirección de las predicciones es correcta (mayor riesgo → mayor estrés predicho), la diferencia entre perfiles extremos es pequeña (5.68 vs. 7.33), lo que refleja la baja capacidad discriminativa del modelo.

4. Experimento II: Predicción de Salarios en el Sector Tech

4.1. Descripción del Dataset

El dataset de salarios contiene **250,000 registros** de profesionales del sector tecnológico de 10 países distintos, con 9 variables predictoras y el salario anual en USD como variable objetivo. Es un dataset limpio, sin valores nulos.

Cuadro 9: Descripción de variables — Dataset de Salarios

Variable	Descripción	Tipo
titulo_profesional	Rol tecnológico (12 categorías)	Categórica nominal
anios_experiencia	Años de experiencia (0–20)	Numérica
nivel_educativo	Nivel de estudios (High School → PhD)	Categórica ordinal
numero_habilidades	Número de habilidades técnicas (1–19)	Numérica
industria	Sector industrial (10 categorías)	Categórica nominal
tamaño_empresa	Tamaño de la empresa (Startup → Enterprise)	Categórica ordinal
ubicación	País de trabajo (10 países + Remote)	Categórica nominal
trabajo_remoto	Modalidad (No / Hybrid / Yes)	Categórica ordinal
certificaciones	Número de certificaciones (0–5)	Numérica
salario	Variable objetivo: salario anual (USD)	Numérica

El rango salarial oscila entre \$31,867 y \$333,046 USD anuales, con una **media de \$145,718 USD** y desviación estándar de \$37,408 USD. La distribución es aproximadamente simétrica (mediana: \$143,453).

4.2. Preprocesamiento

4.2.1. Codificación de Variables Categóricas

Cuadro 10: Esquemas de codificación — Dataset de Salarios

Variable	Naturaleza	Método	Cols. generadas
nivel_educativo	Ordinal	Codificación ordinal (0–4)	1
tamaño_empresa	Ordinal	Codificación ordinal (0–4)	1
trabajo_remoto	Ordinal	Codificación ordinal (0–2)	1
titulo_profesional	Nominal	One-Hot (<i>drop_first</i>)	11
industria	Nominal	One-Hot (<i>drop_first</i>)	9
ubicación	Nominal	One-Hot (<i>drop_first</i>)	9
Total de features resultantes			35

4.2.2. División del Dataset

$$175,100 \text{ (train, 70 \%)} + 37,400 \text{ (val, 15 \%)} + 37,500 \text{ (test, 15 \%)} = 249,999 \approx 250,000 \quad (10)$$

4.3. Arquitectura de la Red Neuronal

Cuadro 11: Arquitectura — Modelo de Salarios (54,017 parámetros totales)

Capa	Tipo	Unidades	Activación	Reg. L_2	Dropout
Entrada	Input	35	—	—	—
1	Dense + BN	256	ReLU	0.001	0.30
2	Dense + BN	128	ReLU	0.001	0.20
3	Dense	64	ReLU	—	0.10
4	Dense	32	ReLU	—	—
Salida	Dense	1	Lineal	—	—

- **Optimizador:** Adam con $\eta_0 = 0,001$
- **Épocas máximas:** 200 | **Batch size:** 128
- **Early Stopping:** patience = 20 épocas
- **ReduceLROnPlateau:** factor = 0.5, patience = 10 épocas

4.4. Resultados

4.4.1. Curvas de Aprendizaje

El entrenamiento finalizó en **60 épocas** (recuperando pesos de la época 40). La tasa de aprendizaje fue reducida dos veces (de 0.001 a 0.0005 en época 50, y a 0.00025 en

época 60). Las curvas de pérdida mostraron convergencia rápida en las primeras 20 épocas y luego estabilización.

Cuadro 12: Evolución del entrenamiento — Hitos clave (Modelo Salarios)

Época	Train Loss	Train MAE	Val Loss	Val MAE	LR
1	0.2807	0.2580	0.1171	0.1608	0.001
8	0.0487	0.1584	0.0436	0.1500	0.001
20	0.0431	0.1480	0.0370	0.1361	0.001
40	0.0409	0.1433	0.0338	0.1273	0.001
50	0.0408	0.1428	0.0420	0.1449	0.001 → 0.0005
60	0.0333	0.1335	0.0393	0.1458	<i>Early Stop</i>

4.4.2. Métricas en Conjunto de Prueba

Métrica	Interpretación	Valor obtenido
MSE	Error cuadrático medio (USD ²)	35,958,200.00
RMSE	Raíz del MSE (USD)	\$5,996.52 USD
MAE	Error absoluto medio (USD)	\$4,780.94 USD
MAPE	Error relativo porcentual	3.61 %
R^2	Varianza explicada (%)	0.9741 (97.4 %)

Interpretación: El modelo se equivoca en promedio $\pm$ \$4,781 USD por año (3.61 % del salario) y explica el **97.4 %** de la variabilidad salarial. Estos resultados son **excelentes** para una tarea de regresión sobre datos laborales.

4.4.3. Análisis de Residuos

Los residuos presentan una distribución aproximadamente simétrica con media de \$-305 USD (sesgo muy bajo respecto al rango salarial). El gráfico de residuos vs. valores predichos muestra homocedasticidad razonable, aunque con mayor dispersión en salarios extremos (por encima de \$250,000 USD).

4.4.4. Importancia de Variables

Cuadro 13: Top 8 variables — Importancia por pesos (Modelo Salarios)

Variable	Importancia relativa (%)
anios_experiencia	7.6 %
tamano_enc	7.1 %
titulo_Data Analyst	6.6 %
titulo_Business Analyst	6.2 %
edu_enc	5.8 %
ubi_India	5.3 %
ubi_USA	5.3 %
titulo_Frontend Developer	4.9 %

Método de pesos de la primera capa

Permutation Importance Los resultados de permutación confirmaron la relevancia de las variables estructurales del modelo. Las variables con mayor caída en R^2 fueron: `tamano_enc`, `anios_experiencia`, `ubi_India` (diferencial negativo de mercado), `edu_enc` y `ubi_USA` (diferencial positivo de mercado).

4.4.5. Predicciones sobre Perfiles de Ejemplo

Cuadro 14: Perfiles de ejemplo — Predicción de salario

Perfil	Título	Exp.	Edu.	País	Salario predicho
Senior de alto perfil	AI Engineer	15	PhD	USA	\$310,575
Junior en mercado bajo	Data Analyst	2	Bachelor	India	\$89,402
Perfil internacional	Software Engineer	10	Master	Alemania	\$203,934
ML especializado	ML Engineer	8	Master	Canadá	\$202,294
Junior sin experiencia	Frontend Dev.	1	High School	India	\$75,654

Las predicciones muestran diferencias sustanciales y coherentes: el rango entre el perfil de mayor salario (\$310,575) y el de menor (\$75,654) representa una brecha de $4,1\times$, consistente con los patrones reales del mercado tecnológico global.

5. Comparación entre Modelos

5.1. Resultados Comparativos

Cuadro 15: Comparativa de métricas — Ambos experimentos

Métrica	Modelo Estrés	Modelo Salarios
MSE	7.5787	35,958,200
RMSE	2.7529 puntos	\$5,996.52 USD
MAE	2.3452 puntos	\$4,780.94 USD
MAPE	86.41 %	3.61 %
R^2	0.0165	0.9741
Épocas	37	60

5.2. Diferencias de Diseño

Cuadro 16: Comparativa de configuración entre ambos experimentos

Aspecto	Modelo Estrés	Modelo Salarios
Muestras totales	1,200	250,000
Features de entrada	14	35
Neuronas capa 1	128	256
Parámetros totales	13,569	54,017
Batch size	32	128
Épocas máximas	300	200
Épocas reales	37	60
Early Stopping patience	30	20
ReduceLR patience	15	10
Escala variable objetivo	Puntos (1–10)	USD (31k–333k)

5.3. Justificación de las Diferencias Arquitectónicas

- 1. Capacidad vs. tamaño del dataset.** El modelo de salarios dispone de ≈ 208 veces más datos, lo que justifica una primera capa de 256 neuronas (el doble) sin riesgo de sobreajuste.
- 2. Batch size y convergencia.** Con 250,000 muestras, `batch_size=128` reduce las actualizaciones a $\approx 1,367$ pasos/época, manteniendo eficiencia computacional sin sacrificar calidad del gradiente.
- 3. Patience del Early Stopping.** El modelo de estrés usa `patience=30` porque la señal de validación es más ruidosa (180 muestras de validación). El modelo de salarios usa `patience=20` porque con 37,400 muestras la estimación del error es más estable.

6. Conclusiones

6.1. Conclusiones Técnicas

1. **El rendimiento depende críticamente del tamaño del dataset.** Con tan solo 1,200 muestras, el modelo de estrés alcanzó un $R^2 = 0,017$, mientras que con 250,000 muestras el modelo de salarios logró $R^2 = 0,974$. Esto evidencia que las redes neuronales profundas requieren grandes volúmenes de datos para generalizar eficazmente.
2. **Arquitectura común, parametrización adaptada.** Una arquitectura de cuatro capas ocultas con BatchNorm, Dropout y regularización L_2 fue una base sólida para el modelo de salarios. Para el modelo de estrés, la arquitectura era apropiada pero los datos eran insuficientes.
3. **Prevención de data leakage.** El ajuste del scaler *exclusivamente* sobre el conjunto de entrenamiento es una práctica indispensable, implementada correctamente en ambos experimentos.
4. **Codificación coherente con la naturaleza de las variables.** El uso de codificación ordinal para variables con orden natural y One-Hot Encoding para variables nominales respeta la estructura semántica de los datos.
5. **Estrategia de entrenamiento adaptativa.** Los callbacks de Early Stopping y ReduceLROnPlateau permitieron detener el entrenamiento en 37 y 60 épocas respectivamente, evitando sobreajuste y tiempo de cómputo innecesario.

6.2. Conclusiones Sustantivas

6.2.1. Sobre el estrés en adolescentes

El bajo $R^2 = 1,6\%$ indica que las variables del dataset (*hábitos digitales, horas de sueño, rendimiento académico*) tienen un poder predictivo muy limitado sobre el nivel de estrés autorreportado en la escala 1–10. Esto puede deberse a: (a) el tamaño pequeño del dataset (1,200 muestras), (b) la alta variabilidad individual del estrés percibido, (c) la ausencia de variables psicológicas más profundas, o (d) que la relación entre hábitos digitales y estrés en adolescentes no es capturables linealmente por estas variables. Se recomienda ampliar el dataset y explorar modelos alternativos como *XGBoost* antes de atribuir los resultados a limitaciones del dato en sí.

6.2.2. Sobre los salarios en el sector tech

La estructura salarial en tecnología está determinada principalmente por la combinación de **años de experiencia, tamaño de empresa, educación y ubicación geográfica**. El modelo predice con un error promedio de \$4,781 USD (3.6 % del salario medio), lo que lo hace útil para aplicaciones prácticas de referencia salarial, auditoría de equidad y estrategia de contratación.