

UNIVERSIDAD NACIONAL DEL ALTIPLANO

Facultad de Ingeniería

Escuela Profesional de Ingeniería Estadística e Informática



ARBOLES DE REGRESIÓN

- I. PREDICCIÓN DEL NIVEL DE ESTRES - 1,200 muestras
- II. PREDICCIÓN DEL SALARIO - 250,000 muestras

Curso: Aprendizaje Supervizado

Docente: Carpio Vargas Edgar Eloy

Estudiante):

Luque Cornejo Zulema Yasmile

Base de datos: datosestresyansiedad.xlsx, datossalarios.xlsx

Repositorio GitHub:

https://github.com/zuleeex/AP/tree/main/MODELO_ARBOL

Fecha: 7 de mayo de 2026

1 Introducción

Los **árboles de regresión** son modelos de aprendizaje automático supervisado que permiten predecir una variable numérica continua a partir de un conjunto de características. A diferencia de la regresión lineal, no asumen ninguna relación funcional previa entre predictores y respuesta: el modelo aprende reglas de partición jerárquicas directamente de los datos.

En este informe se aplican y comparan árboles de regresión sobre dos datasets reales con contextos muy distintos:

- **Caso I — Estrés en adolescentes:** predice el nivel de estrés (`stress_level`, escala 1–10) a partir de variables relacionadas con hábitos digitales, salud mental y rendimiento académico.
- **Caso II — Salarios tecnológicos:** predice el salario anual (`salario`, en USD) a partir de título profesional, experiencia, educación, industria y condiciones laborales.

Ambos análisis siguen el mismo flujo metodológico implementado en Python con `scikit-learn`, lo que permite una comparación directa entre los dos contextos.

Herramientas utilizadas

- `pandas` — manipulación de datos
- `numpy` — cálculo numérico
- `matplotlib` — visualizaciones
- `scikit-learn` — modelos y métricas
- `DecisionTreeRegressor`
- `GridSearchCV`
- `RandomizedSearchCV`
- `cross_val_score`

2 Caso I — Predicción del Nivel de Estrés

2.1 Descripción del dataset

Cuadro 1: Características del Teen Mental Health Dataset

Atributo	Detalle
Muestras	1,200
Variables	13
Variable objetivo	<code>stress_level</code> (escala 1 – 10)
Tipo de problema	Regresión continua
División	80 % entrenamiento (960) / 20 % prueba (240)

2.1.1 Variables predictoras

Cuadro 2: Variables del dataset de estrés

Variable	Tipo	Descripción
age	Numérica	Edad del adolescente
daily_social_media_hours	Numérica	Horas diarias en redes sociales
sleep_hours	Numérica	Horas de sueño por noche
screen_time_before_sleep	Numérica	Tiempo de pantalla antes de dormir
academic_performance	Numérica	Rendimiento académico (GPA)
physical_activity	Numérica	Horas de actividad física semanal
anxiety_level	Entera	Nivel de ansiedad (0–10)
addiction_level	Entera	Nivel de adicción a redes (0–10)
depression_label	Binaria	Indicador de depresión (0/1)
gender_encoded	Categórica	Género codificado
platform_encoded	Categórica	Plataforma de redes (Instagram/Tik-Tok/Both)
social_encoded	Categórica	Nivel de interacción social

2.2 Métricas del modelo base

Resultados — Árbol Base (Estrés)

Métrica	Valor	Interpretación
MAE	≈ 2.10	Error promedio de 2.1 puntos en escala 1–10
RMSE	≈ 2.62	Penaliza errores grandes
R^2	≈ 0.18	El modelo explica ~18 % de la varianza

Nota de interpretación

Un R^2 bajo en el árbol base es esperado: sin optimización de hiperparámetros y con variables de salud mental que tienen alta variabilidad inherente, el modelo captura una fracción modesta de la varianza. La optimización mejora significativamente este indicador.

2.3 Comparación de modelos — Estrés

2.4 Importancia de características — Estrés

La importancia de cada característica se mide como la **reducción total del MSE** atribuida a esa variable a lo largo del árbol. Las variables con mayor importancia son las que el árbol usa en las divisiones de los nodos superiores, donde el impacto en la predicción es mayor.

Cuadro 3: Comparación de métricas en datos de prueba — Nivel de Estrés

Modelo	MAE	RMSE	R^2
Árbol base (sin optimizar)	≈ 2.81	≈ 3.52	≈ 0.00
GridSearchCV	≈ 2.10	≈ 2.62	≈ 0.18
RandomizedSearchCV	≈ 2.10	≈ 2.62	≈ 0.18

Variables más relevantes para predecir el estrés

De acuerdo con la importancia de características del árbol optimizado, las variables con mayor poder predictivo del nivel de estrés son:

1. **anxiety_level** — el nivel de ansiedad captura la mayor parte de la varianza del estrés.
2. **addiction_level** — la adicción a redes sociales es el segundo predictor más relevante.
3. **sleep_hours** — las horas de sueño influyen significativamente en el nivel de estrés percibido.
4. **daily_social_media_hours** — el uso prolongado de redes sociales contribuye al estrés adolescente.
5. **academic_performance** — el rendimiento académico muestra una relación inversa con el nivel de estrés.

3 Caso II — Predicción del Salario

3.1 Descripción del dataset

Cuadro 4: Características del Tech Salary Dataset

Atributo	Detalle
Muestras	250,000
Variables	10
Variable objetivo	salario (USD, rango: \$31,867 – \$333,046)
Media del salario	\$145,718
Desviación estándar	\$37,408
Tipo de problema	Regresión continua
División	80 % entrenamiento / 20 % prueba

3.1.1 Variables predictoras

Cuadro 5: Variables del dataset de salarios

Variable	Tipo	Descripción
anios_experiencia	Numérica	Años de experiencia laboral
numero_habilidades	Numérica	Número de habilidades técnicas
certificaciones	Entera	Cantidad de certificaciones
titulo_profesional	Categórica	Puesto de trabajo (12 categorías)
nivel_educativo	Categórica	Nivel de educación (5 categorías)
industria	Categórica	Sector industrial (10 categorías)
tamaño_empresa	Categórica	Tamaño de la empresa (5 categorías)
ubicacion	Categórica	País de trabajo (10 países)
trabajo_remoto	Categórica	Modalidad: Presencial/Híbrido/Remoto

3.2 Métricas del modelo base

Resultados — Árbol Base (Salarios)			
Métrica	Valor	Interpretación	
MAE	≈ \$27,500	Error promedio de \$27.5K por predicción	
RMSE	≈ \$34,000	Penaliza errores grandes en USD	
R^2	≈ 0.17	El modelo explica ~17% de la varianza	

3.3 Comparación de modelos — Salarios

Cuadro 6: Comparación de métricas en datos de prueba — Salario

Modelo	MAE (USD)	RMSE (USD)	R^2
Árbol base	≈ \$34,000	≈ \$43,000	≈ 0.00
GridSearchCV	≈ \$27,500	≈ \$34,000	≈ 0.17
RandomizedSearchCV	≈ \$27,500	≈ \$34,000	≈ 0.17

3.4 Importancia de características — Salarios

Variables más relevantes para predecir el salario

Las características con mayor importancia en el árbol optimizado son:

1. `titulo_encoded` — el título profesional es el predictor más influyente del salario.
2. `anios_experiencia` — los años de experiencia determinan directamente la banda salarial.
3. `ubicacion_encoded` — el país de trabajo introduce diferencias salariales significativas.
4. `industria_encoded` — ciertos sectores como tecnología y finanzas pagan consistentemente más.
5. `nivel_educativo` — el grado académico modifica la expectativa salarial, aunque menos que la experiencia.

4 Análisis Comparativo

4.1 Similitudes metodológicas

Ambos casos comparten exactamente la misma estructura de análisis:

1. Carga y exploración inicial del dataset.
2. Codificación de variables categóricas con `.cat.codes`.
3. División 80 %/20 % con `train_test_split`.
4. Entrenamiento de árbol base con `max_depth=5`.
5. Evaluación con MAE, RMSE y R^2 .
6. Validación cruzada 5-fold con `cross_val_score`.
7. Optimización con `GridSearchCV` y `RandomizedSearchCV`.
8. Curvas de validación y aprendizaje.
9. Análisis de importancia de características.
10. Árbol simplificado (3 niveles) para visualización interpretable.

4.2 Diferencias clave

4.3 Discusión del R^2

Ambos modelos obtienen un R^2 modesto (≈ 0.17 – 0.18), lo que es esperable por varias razones:

- **Alta variabilidad inherente:** tanto el estrés como el salario son fenómenos determinados por numerosos factores no capturados en el dataset (personalidad, negociación salarial, contexto familiar, etc.).

Cuadro 7: Comparación entre ambos casos de estudio

Aspecto	Estrés (Caso I)	Salarios (Caso II)
Tamaño del dataset	1,200 muestras	250,000 muestras
Variable objetivo	<code>stress_level</code> (1–10)	<code>salario</code> (USD)
Escala de respuesta	Escala Likert discreta	Valor monetario continuo
Número de features	12	9
Variables categóricas	3	6
Principal predictor	<code>anxiety_level</code>	<code>titulo_profesional</code>
Interpretabilidad	Alta (escala 1–10)	Alta (USD directos)
R^2 optimizado	≈ 0.18	≈ 0.17
Contexto	Salud mental adolescente	Mercado laboral tecnológico

- **Limitaciones del árbol simple:** un único árbol de decisión tiene menor capacidad expresiva que métodos de ensemble como Random Forest o Gradient Boosting.
- **Codificación ordinal:** `.cat.codes` impone un orden arbitrario en variables nominales. Usar *one-hot encoding* o embeddings podría mejorar el rendimiento.

Recomendación para mejorar el R^2

Para ambos casos, se recomienda evaluar métodos de ensemble: **Random Forest** (promedia múltiples árboles) y **Gradient Boosting / XGBoost** (construcción secuencial de árboles) suelen obtener $R^2 > 0.5$ en problemas similares con el mismo conjunto de variables.

5 Conclusiones

1. **Los árboles de regresión son interpretables y versátiles.** Tanto en el contexto de salud mental como en el mercado laboral, el árbol produce reglas de decisión comprensibles: condiciones del tipo “*si la ansiedad > 6.5 y las horas de sueño < 5.5 , entonces `stress_level` ≈ 8.2* ” son directamente utilizables por profesionales no técnicos.