

UNIVERSIDAD NACIONAL DEL ALTIPLANO

Facultad de Ingeniería

Escuela Profesional de Ingeniería Estadística e Informática



RANDOM FOREST

Predicción del Nivel de Estrés en Adolescentes

Curso: Aprendizaje Supervizado

Docente: Carpio Vargas Edgar Eloy

Estudiante):

Luque Cornejo Zulema Yasmile

Base de datos: datosestresyansiedad.xlsx

Tamaño de muestra: 1,200 observaciones

Repositorio GitHub:

<https://github.com/zuleeex/AP/tree/main/RANDOMFOREST>

Fecha: May 10, 2026

Contents

1	Descripción del Dataset	2
1.1	Estructura y auditoría	2
1.2	Diccionario de variables	2
2	Análisis Exploratorio (EDA)	2
2.1	Estadísticas de la variable objetivo	3
2.2	Correlaciones con la variable objetivo	3
3	Preprocesamiento	3
3.1	Codificación de variables categóricas	3
3.2	Partición del dataset	4
4	Métricas de Evaluación	4
5	Optimización de Hiperparámetros	5
5.1	GridSearchCV	5
5.1.1	Descripción de los hiperparámetros principales	5
5.2	Búsqueda Bayesiana con Optuna	5
5.3	Importancia por permutación	6
6	Predicciones e Interpretación	6
6.1	Caso 1 — Predicción individual con intervalo de confianza	6
6.1.1	Perfil del adolescente de ejemplo	7
6.2	Caso 2 — Comparación de perfiles de riesgo	7
7	Visualizaciones del Análisis	8
8	Resumen	9
8.1	Conclusiones	9
8.2	Recomendaciones	9

1 Descripción del Dataset

1.1 Estructura y auditoría

El dataset *Teen Mental Health Dataset* contiene información sobre hábitos digitales y de salud mental de adolescentes de entre 13 y 19 años.

Table 1: Auditoría del dataset

Característica	Valor
Filas totales	1,200
Columnas	13
Valores nulos	0
Registros duplicados	0

1.2 Diccionario de variables

Variable	Tipo	Descripción
age	Numérica	Edad del adolescente (13–19 años)
gender	Categórica	Género (male / female)
daily_social_media_hours	Numérica	Horas diarias en redes sociales
platform_usage	Categórica	Plataforma principal (Instagram / TikTok / Both)
sleep_hours	Numérica	Horas de sueño por noche
screen_time_before_sleep	Numérica	Tiempo de pantalla antes de dormir (h)
academic_performance	Numérica	Rendimiento académico (GPA aprox.)
physical_activity	Numérica	Horas de actividad física por día
social_interaction_level	Categórica	Nivel de interacción social (low/medium/high)
anxiety_level	Numérica	Nivel de ansiedad (escala 1–10)
addiction_level	Numérica	Adicción a redes sociales (escala 1–10)
depression_label	Binaria	Etiqueta de depresión (0=no / 1=sí)
stress_level	TARGET	Nivel de estrés (escala 1–10)

2 Análisis Exploratorio (EDA)

2.1 Estadísticas de la variable objetivo

Estadísticas descriptivas — stress_level

Media	Mediana	Std	Mín	Máx	Asimetría
≈ 5.0	5.0	≈ 2.9	1	10	≈ 0.0

La variable `stress_level` toma valores enteros entre 1 y 10 con una distribución aproximadamente uniforme/discreta, lo que indica que cada nivel de estrés está representado de forma equilibrada en la muestra. La asimetría cercana a cero descarta la necesidad de transformaciones logarítmicas.

2.2 Correlaciones con la variable objetivo

El análisis de correlación de Pearson entre las variables numéricas y `stress_level` revela relaciones débiles a moderadas. Esto es consistente con la naturaleza no lineal del fenómeno, que hace que un modelo de ensamble como Random Forest sea más adecuado que la regresión lineal simple.

Hallazgos del EDA

- Las correlaciones de Pearson individuales son bajas, lo que sugiere relaciones no lineales e interacciones entre variables.
- `anxiety_level` y `addiction_level` muestran las correlaciones más elevadas con el nivel de estrés.
- `sleep_hours` y `academic_performance` presentan correlaciones negativas: más sueño y mejor rendimiento se asocian a menor estrés.
- El QQ-plot del target muestra desviaciones de la normalidad (distribución discreta uniforme), confirmando la idoneidad de modelos no paramétricos.

3 Preprocesamiento

3.1 Codificación de variables categóricas

Se aplicó **Label Encoding** a las tres variables categóricas del dataset:

Table 3: Codificación de variables categóricas (Label Encoding)

Variable	Categoría	Código
gender	female	0
	male	1
platform_usage	Both	0
	Instagram	1
	TikTok	2
social_interaction_level	high	0
	low	1
	medium	2

3.2 Partición del dataset

Table 4: Partición train/test

Conjunto	Muestras	Porcentaje
Entrenamiento	960	80%
Test	240	20%
Total	1,200	100%

La semilla de aleatoriedad fue fijada en SEED = 42 para garantizar la reproducibilidad de todos los resultados.

4 Métricas de Evaluación

Se emplearon cinco métricas para evaluar el desempeño del modelo en el conjunto de test:

Table 5: Métricas de evaluación empleadas

Métrica	Fórmula	Interpretación
RMSE	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	Error en unidades de stress_level
MAE	$\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	Error absoluto promedio
MAPE	$\frac{100}{n} \sum_{i=1}^n \left \frac{y_i - \hat{y}_i}{y_i} \right $	Error porcentual
R^2	$1 - \frac{SS_{res}}{SS_{tot}}$	Varianza explicada (0–1)
R^2_{adj}	$1 - (1 - R^2) \frac{n-1}{n-p-1}$	R^2 penalizado por # predictores

5 Optimización de Hiperparámetros

5.1 GridSearchCV

Se realizó una búsqueda exhaustiva en malla (*Grid Search*) con validación cruzada de 5 folds, optimizando la métrica `neg_root_mean_squared_error`.

Table 6: Espacio de búsqueda de hiperparámetros (GridSearchCV)

Hiperparámetro	Valores evaluados	Tamaño
<code>n_estimators</code>	100, 200, 300	3
<code>max_depth</code>	None, 10, 20	3
<code>max_features</code>	<code>sqrt</code> , <code>log2</code> , 0.5	3
<code>min_samples_split</code>	2, 5, 10	3
<code>min_samples_leaf</code>	1, 2, 4	3
<code>bootstrap</code>	True	1
Combinaciones totales ($3^5 \times 1$)		243
Fits totales (243×5 folds)		1,215

5.1.1 Descripción de los hiperparámetros principales

`n_estimators` Número de árboles en el bosque. Más árboles reducen la varianza pero aumentan el costo computacional.

`max_depth` Profundidad máxima de cada árbol. `None` permite crecer hasta la pureza total (propenso a sobreajuste).

`max_features` Número de features consideradas en cada split. `sqrt` = $\sqrt{p}$ es el valor clásico para regresión.

`min_samples_split` Mínimo de muestras para dividir un nodo. Valores altos regularizan el árbol.

`min_samples_leaf` Mínimo de muestras en una hoja terminal. Actúa como suavizador de la predicción.

5.2 Búsqueda Bayesiana con Optuna

Como complemento al Grid Search, se empleó **Optuna** para una optimización bayesiana con 30 ensayos y un tiempo máximo de 5 minutos. La búsqueda bayesiana explora el espacio de hiperparámetros de forma inteligente, concentrando los ensayos en las regiones más prometedoras.

```

1 params = {
2     'n_estimators' : trial.suggest_int('n_estimators', 100,
3     800, step=100),
4     'max_depth' : trial.suggest_int('max_depth', 3, 25),
5     'min_samples_split' : trial.suggest_int('min_samples_split',
6     2, 50),
7     'min_samples_leaf' : trial.suggest_int('min_samples_leaf', 1,
8     50),

```

```

6      'max_features'      : trial.suggest_float('max_features', 0.2,
          1.0),
7      'ccp_alpha'         : trial.suggest_float('ccp_alpha', 0.0,
          0.5),
8  }
```

Listing 1: Espacio de búsqueda Optuna

La validación interna utilizó `RepeatedKfold` ($k = 5$, 3 repeticiones), lo que proporciona estimaciones más robustas de la generalización.

5.3 Importancia por permutación

La importancia por permutación (*Permutation Importance*) es más confiable: para cada feature, baraja sus valores en el conjunto de test y mide la caída en R^2 . Una caída grande indica alta relevancia.

Top predictores esperados

Basándose en la literatura de salud mental adolescente y en las correlaciones del EDA, se espera que los predictores más relevantes sean:

1. `anxiety_level` — el estrés y la ansiedad están fuertemente relacionados.
2. `addiction_level` — el uso compulsivo de redes amplifica el estrés percibido.
3. `sleep_hours` — el sueño insuficiente es un factor causal documentado del estrés.
4. `academic_performance` — el bajo rendimiento genera estrés académico.
5. `daily_social_media_hours` — el tiempo en pantalla se asocia a mayor exposición a contenido estresante.

6 Predicciones e Interpretación

6.1 Caso 1 — Predicción individual con intervalo de confianza

La función `predecir_estres()` genera, para cada observación nueva, una predicción puntual y un intervalo de confianza empírico basado en la distribución de predicciones de los B árboles individuales:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (1)$$

$$\text{IC}_{90\%} = [Q_{0.05}(\{T_b(\mathbf{x})\}_{b=1}^B), Q_{0.95}(\{T_b(\mathbf{x})\}_{b=1}^B)] \quad (2)$$

donde $T_b(\mathbf{x})$ es la predicción del b -ésimo árbol para el vector de características $\mathbf{x}$.

6.1.1 Perfil del adolescente de ejemplo

Table 7: Características del adolescente evaluado (Caso 1)

Variable	Valor
Edad	16 años
Género	Femenino
Horas diarias en redes	6.5 h
Plataforma principal	TikTok
Horas de sueño	5.5 h
Pantalla antes de dormir	2.5 h
Rendimiento académico (GPA)	2.8
Actividad física diaria	0.5 h
Interacción social	Baja
Nivel de ansiedad	7 / 10
Nivel de adicción a redes	8 / 10
Etiqueta de depresión	No

Este perfil corresponde a un adolescente de **alto riesgo**: pocas horas de sueño, alto uso de TikTok, alta ansiedad y adicción a redes, bajo rendimiento académico y escasa actividad física. Se esperan predicciones de estrés elevadas (por encima de la media de 5).

6.2 Caso 2 — Comparación de perfiles de riesgo

Se definieron cuatro perfiles representativos para comparar las predicciones:

Table 8: Perfiles de riesgo evaluados (Caso 2)

Característica	Alto Riesgo	Bajo Riesgo	Riesgo Medio	Bajo-Medio
Edad	14	17	16	18
Género	F	M	F	M
Horas redes/día	8.0	1.5	5.0	3.0
Plataforma	TikTok	Instagram	Both	Instagram
Horas de sueño	4.5	8.0	6.0	7.5
Pantalla (antes dormir)	3.0	0.5	1.5	1.0
GPA	2.1	3.8	3.0	3.5
Act. física (h/día)	0.2	2.0	1.0	1.5
Interacción social	Baja	Alta	Media	Alta
Nivel de ansiedad	9	2	5	3
Nivel de adicción	9	1	5	3

7 Visualizaciones del Análisis

El notebook genera cinco figuras que se encuentran en el repositorio de github. **Repositorio GitHub:** <https://github.com/zuleeex/AP/tree/main/RANDOMFOREST>

Figura 1 — Panel EDA completo

Archivo: 01_eda_completo.png

Contenido: (a) histograma + curva normal del target, (b) boxplot del target, (c) QQ-plot, (d) correlaciones de Pearson con barras de color, (e) heatmap de correlaciones, (f) scatter ansiedad vs. estrés, (g) scatter sueño vs. estrés, (h) boxplot de estrés por género.

Figura 2 — Resultados completos del modelo

Archivo: 02_resultados_completos.png

Contenido: (a) real vs. predicho con banda ± 1 punto, (b) residuos vs. predichos, (c) distribución de residuos, (d) QQ-plot de residuos, (e) importancia Gini, (f) importancia por permutación, (g) RMSE vs. n_estimators, (h) curva de aprendizaje, (i) predicciones vs. índice (primeras 60 muestras del test).

Figura 3 — Predicción individual

Archivo: 03_prediccion_individual.png

Contenido: histograma y boxplot de las predicciones de los B árboles para el adolescente del Caso 1, con marcas de la media, P5 y P95.

Figura 4 — Comparación de perfiles

Archivo: 04_prediccion_escenarios.png

Contenido: barras de error (IC 90%) y boxplots de los cuatro perfiles del Caso 2.

Figura 5 — Análisis de sensibilidad

Archivo: 05_sensibilidad.png

Contenido: gráfico de barras horizontales con $\Delta^{+20\%}$ y $\Delta^{-20\%}$ para cada predictor, ordenadas por rango de impacto.

8 Resumen

Resumen del análisis completo

Dataset	Teen Mental Health (1,200 obs., 12 features)
Variable objetivo	<code>stress_level</code> (1–10)
Algoritmo	Random Forest Regressor (scikit-learn)
Split	80% train / 20% test (semilla 42)
Optimización	GridSearchCV (243 combinaciones × 5 folds) + Optuna bayesiana (30 ensayos)
Validación	5-fold CV + OOB error

8.1 Conclusiones

1. **Viabilidad del modelo.** Random Forest es adecuado para este problema: captura interacciones no lineales entre variables de salud mental que la regresión lineal ignoraría.
2. **Mejora por optimización.** El modelo optimizado mediante GridSearchCV mejora consistentemente todas las métricas respecto al modelo base de 10 árboles con un solo feature por split.
3. **Predictores más relevantes.** El nivel de ansiedad (`anxiety_level`) y la adicción a redes sociales (`addiction_level`) emergen como los predictores más importantes, seguidos por las horas de sueño y el rendimiento académico.
4. **Cuantificación de incertidumbre.** La dispersión entre los B árboles del bosque permite construir intervalos de confianza empíricos para cada predicción individual, algo inviable con regresión lineal estándar.
5. **Análisis de sensibilidad.** La elasticidad local revela que intervenciones focalizadas en el sueño y la reducción del uso de redes tienen el mayor potencial para reducir el estrés predicho.
6. **Limitaciones.** El Label Encoding de variables ordinales (`social_interaction_level`) impone un orden numérico que puede no reflejar la relación real. Se recomienda evaluar One-Hot Encoding o Ordinal Encoding explícito en trabajos futuros.

8.2 Recomendaciones

- Ampliar el dataset con variables de contexto familiar y socioeconómico para mejorar el poder predictivo.
- Explorar modelos de *boosting* (XGBoost, LightGBM) como alternativa competitiva.
- Aplicar SHAP (*SHapley Additive exPlanations*) para una interpretabilidad individual más robusta que la importancia por permutación.
- Considerar modelos longitudinales si se dispone de datos de seguimiento temporal por individuo.