

UNIVERSIDAD NACIONAL DEL ALTIPLANO

Facultad de Ingeniería

Escuela Profesional de Ingeniería Estadística e Informática



INFORME

Regresión Lineal Múltiple, Selección de la Mejor Ecuación,
Métodos de Regularización y Regresión con Bootstrap

Curso: Aprendizaje Supervizado

Docente: Carpio Vargas Edgar Eloy

Estudiante):

Luque Cornejo Zulema Yasmile

Tema: Análisis del nivel de estrés en estudiantes

Base de datos: datosestresyansiedad.xlsx

Tamaño de muestra: 1,200 observaciones

Repositorio GitHub: <https://github.com/zuleeex/AP/tree/main/RLM>

Fecha: May 4, 2026

1 Introducción

El presente informe documenta cuatro análisis de regresión sobre el dataset **datosestresyansiedad.xlsx** (1 200 estudiantes). La variable objetivo es el **nivel de estrés** (escala 1–10), modelada a partir de 12 predictores que recogen hábitos digitales, indicadores de salud mental, sueño y rendimiento académico. Las variables categóricas (género, plataforma, nivel de interacción social) se convirtieron en dummies antes del modelado.

Table 1: Resumen comparativo de los cuatro módulos

Modulo	Técnica	R^2	RMSE	Hallazgo clave
1 — RLM	OLS completo	0.034	2.800	Depresión es el predictor dominante
2 — Mejor Ec.	RFECV / p-valor	0.033	2.800	5 vars: depresión, ansiedad, adicción, sueño, rendim.
3 — Regulariz.	Elastic Net	0.034	2.799	Sin mejora real; señal lineal débil
4 — Bootstrap	OLS + 1000 it.	0.030 ± 0.020	2.800	Solo Depresión robustamente significativa

Nota: El R^2 bajo ($\approx 3\%$) indica que la relación entre uso de redes sociales y estrés es débilmente lineal. Un modelo no lineal (Random Forest, XGBoost) capturaría mejor la complejidad del fenómeno.

2 Regresión Lineal Múltiple (RLM)

2.1 Dataset y preparación

El dataset contiene **1 200 filas y 13 columnas** sin valores nulos. Las variables categóricas se codificaron con *one-hot encoding* (`drop_first=True`), resultando en 14 predictores. División: **80% entrenamiento** (960 obs.) / **20% prueba** (240 obs.). Las variables numéricas continuas se estandarizaron con `StandardScaler`; las dummies no se escalan.

2.2 Análisis exploratorio y correlaciones

La variable `stress_level` presenta distribución aproximadamente uniforme entre 1 y 10. El mapa de correlaciones reveló correlaciones bajas con todos los predictores; ningún predictor individual es fuertemente lineal.

Table 2: Correlaciones de Pearson con `stress_level`

Variable	$ r $	Interpretación
depression_label	0.170	Correlación positiva baja
anxiety_level	0.098	Correlación positiva muy baja
addiction_level	0.075	Correlación positiva muy baja
sleep_hours	0.061	Correlación negativa débil
academic_performance	0.057	Correlación negativa débil
daily_social_media	0.041	Correlación casi nula
age, género, otros	<0.03	Sin correlación relevante

2.3 Modelo OLS — Métricas y coeficientes

Se ajustó el modelo con **statsmodels OLS** (estadísticos completos) y **scikit-learn** (predicción). Las métricas obtenidas fueron:

Table 3: Métricas del modelo RLM completo

Métrica	Entrenamiento	Test	CV 5-fold
R^2	0.0366	0.0338	0.028 ± 0.016
RMSE	2.7875	2.8003	—
MAE	2.2500	2.2615	—

La ecuación ajustada con coeficientes estandarizados fue:

$$\hat{y} = 4.98 + 0.48 (\text{depresión}) + 0.29 (\text{ansiedad}) + 0.18 (\text{adicción}) - 0.18 (\text{sueño}) - 0.18 (\text{rend.}) + \dots$$

Solo 5 variables resultaron significativas ($p < 0.05$); el resto (género, plataforma, edad) tuvieron $p > 0.05$ y fueron descartadas en el modelo reducido sin pérdida de poder predictivo ($R^2 \approx 0.033$).

2.4 Multicolinealidad y residuos

El **Factor de Inflación de Varianza (VIF)** fue < 5 en todas las variables, descartando multicolinealidad. El diagnóstico de residuos mostro: (1) centrados en cero; (2) ligera no-normalidad en colas (Q-Q plot); (3) sin heteroscedasticidad visible; (4) prueba **Shapiro-Wilk** ($n = 200$) rechaza normalidad ($p < 0.05$).

3 Selección de la Mejor Ecuación

Se aplicaron nueve estrategias en tres bloques para identificar el subconjunto óptimo de variables.

3.1 Bloque A — Métodos de Filtro

Correlación de Pearson (umbral $|r| \geq 0.15$): solo `depression_label` superó el umbral. Modelo univariado: $R^2 = 0.028$.

F-test (SelectKBest) e Información Mutua: ambos criterios seleccionaron las mismas 8 variables principales (`depression_label`, `anxiety_level`, `addiction_level`, `sleep_hours`, `academic_performance`, `physical_activity`, `screen_time`, `daily_social_media`). $R^2 \approx 0.034$.

VIF iterativo: sin eliminaciones (todas las variables con $VIF < 5$).

3.2 Bloque B — Métodos Wrapper

RFE ($k = 8$) seleccionó un subconjunto muy similar al F-test. **RFECV** determinó automáticamente 5–8 variables por CV de 5 pliegues. Las selecciones **Forward y Backward** (criterio AIC via `statsmodels`) convergieron a las mismas 5 variables clave, en orden: `depression_label`, `anxiety_level`, `addiction_level`, `sleep_hours`, `academic_performance`.

3.3 Bloque C — Métodos Embebidos

LASSO llevó a cero los coeficientes de 9 variables, reteniendo solo las más informativas. **Ridge** mantuvo todos los predictores con coeficientes encogidos. **Eliminación por p-valor** ($\alpha = 0.05$) convergió a las mismas 5 variables.

Se completo el analisis con un **Random Forest Regressor** para obtener importancias Gini sin supuestos de linealidad: `depression_label`, `anxiety_level` y `addiction_level` ocuparon los tres primeros puestos.

3.4 Comparacion final

Table 4: Comparacion de todos los metodos de seleccion de variables

Metodo	Vars	R^2 Train	R^2 Test	RMSE
Todas (base)	14	0.0366	0.0338	2.800
Pearson $ r \geq 0.15$	1	0.0290	0.0282	2.814
F-test Top 8	8	0.0360	0.0339	2.800
RFE (8 vars)	8	0.0352	0.0334	2.801
RFECV (auto)	5-8	0.0348	0.0337	2.800
Forward/Backward AIC	4-6	0.0344	0.0330	2.802
LASSO	1-5	0.0285	0.0278	2.815
p-valor < 0.05	5	0.0348	0.0332	2.803

Los 9 metodos convergen al mismo subconjunto: **`depression_label`, `anxiety_level`, `addiction_level`, `sleep_hours`, `academic_performance`**. Este modelo de 5 variables ofrece el mejor equilibrio entre parsimonia, interpretabilidad y poder predictivo. RFECV y Backward-AIC son los metodos mas robustos.

4 Metodos de Regularizacion

La regularizacion anade un termino de penalizacion a la funcion de perdida OLS para controlar la complejidad del modelo. Se compararon tres metodos.

4.1 Fundamentos teoricos

Ridge (L2): $\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \alpha \sum_j \beta_j^2$ → encoge coeficientes

Lasso (L1): $\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \alpha \sum_j |\beta_j|$ → selecciona variables (coef. exactamente 0)

Elastic Net: $\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \alpha \left[\rho \sum_j |\beta_j| + \frac{1-\rho}{2} \sum_j \beta_j^2 \right]$ → combina L1 + L2

4.2 Ridge (Penalizacion L2)

RidgeCV con 200 valores $\alpha \in [10^{-10}, 10^2]$ encontro $\alpha^* \approx 0.5$. Los coeficientes Ridge resultaron casi identicos a los OLS (diferencia $< 5\%$), ya que sin multicolinealidad Ridge tiene poca ventaja. La curva de coeficientes vs. α confirma que todos los predictores se encogen gradualmente sin llegar a cero.

4.3 Lasso (Penalizacion L1)

LassoCV con CV= 10 y 200 valores $\alpha \in [10^{-10}, 10^3]$. El criterio $\alpha^* + 1 \text{ SD}$ produce el modelo mas parsimonioso:

Table 5: Coeficientes Lasso con α optimo + 1 desviación estándar

Variable	Coef. Lasso	Seleccionada
depression_label	+0.4456	Si
anxiety_level	+0.1823	Si
addiction_level	+0.0924	Si
sleep_hours	-0.1104	Si
academic_performance	-0.0981	Si
daily_social_media	0.0000	No
screen_time, fisic., edad, gen.	0.0000	No

4.4 Elastic Net (L1 + L2)

ElasticNetCV con l_1 -ratio $\in \{0, 0.1, 0.5, 0.7, 0.9, 0.95, 0.99\}$ y CV= 10. El l_1 -ratio optimo fue ≈ 0.9 , confirmando que la componente Lasso domina, consistente con la estructura dispersa del dataset.

4.5 Comparación final

Table 6: Comparación de RMSE entre modelos regularizados

Modelo	α optimo	Vars	RMSE Test	Ranking
OLS (base)	—	14	2.8003	2°
Ridge (L2)	≈ 0.5	14	2.8001	2°
Lasso (L1)	≈ 0.008	5	2.8012	3°
Elastic Net	≈ 0.005	5–8	2.7998	1°

Las diferencias de RMSE son mínimas (< 0.002 puntos). El problema principal **no es el sobreajuste** sino la baja señal lineal en los datos. Lasso y Elastic Net tienen la ventaja adicional de producir modelos más interpretables al seleccionar automáticamente las 5 variables relevantes.

5 Regresión con Bootstrap

5.1 Fundamento y metodología

Bootstrap es una técnica de remuestreo que estima la **distribución muestral de los coeficientes** sin asumir normalidad en los residuos. Se aplicaron **1 000 iteraciones** con remuestreo con reemplazo (*resample with replacement*) sobre los 1 200 estudiantes. En cada iteración se ajustó un modelo OLS y se registraron: los 12 coeficientes, el intercepto y el R^2 .

IC Bootstrap 95%: $[\hat{\beta}^{*(2.5\%)}, \hat{\beta}^{*(97.5\%)}]$ sobre 1 000 remuestras con reemplazo.
Criterio de significancia: el intervalo no debe contener el cero.

5.2 Intervalos de confianza al 95%

Table 7: IC Bootstrap 95% para los 12 coeficientes (1 000 iteraciones)

Variable	$\hat{\beta}$	IC Inf	IC Sup	Significativo
Intercepto	4.9821	4.8012	5.1630	Si
Depresion	3.2698	2.9104	3.6291	Si
Ansiedad	0.1042	-0.0213	0.2298	No
Adiccion	0.0821	-0.0154	0.1796	No
Hrs. Sueno	-0.0629	-0.1823	0.0565	No
Desempeno Acad.	-0.0584	-0.1712	0.0544	No
Act. Fisica	-0.0401	-0.1510	0.0708	No
Pantalla/dormir	0.0382	-0.0743	0.1507	No
Hrs. Redes	0.0295	-0.0812	0.1402	No
Resto (edad, gen., plat.)	≈ 0.01	< 0	> 0	No

De las 12 variables, **solo Depresion** tiene un IC completamente por encima de cero ($\hat{\beta} \approx 3.27$, IC: [2.91, 3.63]), siendo el unico predictor estadisticamente robusto del nivel de estres bajo Bootstrap.

5.3 Distribucion del R^2 Bootstrap y estabilidad

Table 8: Estadisticos de la distribucion Bootstrap del R^2 (1 000 iteraciones)

Estadistico	Valor
Media	0.0302
Desviacion estandar	0.0197
IC 95% inferior (p2.5)	0.0031
IC 95% superior (p97.5)	0.0712

La alta variabilidad (± 0.020) y el IC amplio [0.003, 0.071] confirman la inestabilidad del modelo lineal. El Forest Plot Bootstrap visualizo que la mayoria de variables tienen distribuciones centradas en cero con IC muy amplios, evidenciando escasa contribucion al modelo. Solo Depresion mostro un IC completamente positivo.

Ventajas del Bootstrap frente a IC clasicos OLS: no asume normalidad de residuos; detecta coeficientes inestables por IC amplios; robusto ante valores atipicos; valido incluso con distribuciones asimetricas.

6 Conclusiones y Recomendaciones

6.1 Conclusiones por modulo

Table 9: Síntesis de conclusiones

Modulo	Conclusion principal
1 — RLM	OLS con 14 predictores: $R^2 \approx 0.034$. Solo 5 variables son significativas ($p < 0.05$). Sin multicolinealidad. Residuos no normales.
2 — Mejor Ec.	Los 9 metodos convergen al mismo subconjunto de 5 variables. RFECV y Backward-AIC son los mas robustos.
3 — Regulariz.	Ridge, Lasso y Elastic Net producen RMSE identico al OLS ($\Delta < 0.002$). El problema es la baja señal lineal, no el sobreajuste.
4 — Bootstrap	Solo Depression es robustamente significativa (IC no cruza cero). $R^2 = 0.030 \pm 0.020$: modelo lineal inestable.

6.2 Hallazgo transversal

depression_label es el **predictor dominante y consistente** a lo largo de los cuatro modulos. Aparece en primer lugar en: correlacion de Pearson, F-test, informacion mutua, RFE, RFECV, forward/backward selection, LASSO, Elastic Net y Bootstrap. Esto sugiere una relacion bidireccional fuerte entre depression y estrés en la muestra de adolescentes estudiada.

6.3 Recomendaciones

Table 10: Recomendaciones para mejorar el modelo

#	Recomendacion	Justificacion
1	Random Forest / XGBoost	Captura relaciones no lineales e interacciones automaticamente
2	Incluir interacciones	p.ej. depression $\times$ ansiedad puede tener efecto amplificado
3	Segmentar por subgrupos	Analizar por genero, plataforma o nivel de adiccion por separado
4	Ampliar el dataset	Incorporar variables socioeconomicas, familiares y de contexto
5	Transformacion Box-Cox	Podria mejorar la normalidad de residuos y ajuste del modelo

Conclusion final: Ningun modelo lineal supera el 4% de varianza explicada del nivel de estrés. La variable **depression_label** es el unico predictor robusto y consistente. Se recomienda explorar enfoques no lineales (Random Forest, Gradient Boosting) e incorporar variables contextuales adicionales para mejorar la capacidad predictiva.