



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

ÁRBOLES DE DECISIÓN (CART) PARA LA DETECCIÓN DE ANEMIA INFANTIL

Curso: Aprendizaje Supervisado
Docente: Carpio Vargas Edgar Eloy
Estudiante: [Nombre del estudiante]
Dataset: *ENDES 2024 – Módulo RECH6* (17 798 registros válidos)
Variable objetivo: Nivel de anemia infantil (Sin_Anemia / Con_Anemia)
Tecnologías: Python 3.10 · scikit-learn · scikit-fuzzy · pandas · NumPy
Repositorio: [GitHub/ARBOLES](#)
Fecha: 24 de julio de 2026

Informe académico basado en árboles de decisión CART (simple y optimizado con poda por costo-complejidad), comparados contra un árbol difuso heurístico y un Random Forest de referencia.

Índice

1. Introducción	2
2. Marco Teórico	2
2.1. Árboles de Decisión CART	2
2.2. Poda por Costo-Complejidad (<code>ccp_alpha</code>)	2
2.3. Árbol Difuso (Lógica Difusa)	3
2.4. Random Forest como Referencia	3
2.5. Importancia de Variables por Permutación	3
2.6. Métricas de Evaluación	3
3. Descripción del Dataset	4
3.1. Fuente y Filtrado	4
3.2. Estadísticas Descriptivas	5
3.3. Distribución de la Variable Objetivo	5
3.4. Variables Categóricas	6
3.5. Correlación y Distribución de Predictores	7
4. Preprocesamiento y Configuración del Modelo	8
4.1. Codificación de Variables Categóricas	8
4.2. División del Dataset	8
4.3. Implementación de los Modelos	9
5. Resultados	9
5.1. Comparación General de Modelos	10
5.2. Matrices de Confusión	11
5.3. Métricas por Clase — Mejor Modelo (CART Optimizado)	11
5.4. Importancia de Variables	12
5.5. Predicción sobre un Caso de Ejemplo	13
6. Conclusiones	13
6.1. Recomendaciones	14

1. Introducción

La anemia infantil es uno de los principales problemas de salud pública en el Perú, particularmente en zonas altoandinas como la región Puno. Su detección oportuna a partir de indicadores antropométricos y sociodemográficos —recolectados de forma rutinaria en encuestas nacionales como la Encuesta Demográfica y de Salud Familiar (ENDES)— puede orientar estrategias de tamizaje cuando la medición directa de hemoglobina no está disponible.

El presente informe documenta el diseño, implementación y evaluación de modelos de clasificación supervisada basados en **árboles de decisión CART**, aplicados al módulo **RECH6** de la ENDES 2024, con el objetivo de clasificar a un niño como *Con Anemia* o *Sin Anemia* a partir de variables antropométricas y sociodemográficas, excluyendo deliberadamente la hemoglobina medida como predictor. Se compararon cuatro modelos: un **árbol CART simple** (hiperparámetros modestos), un **árbol CART optimizado** (GridSearchCV con poda por costo-complejidad `ccp_alpha`), un **árbol difuso** heurístico basado en funciones de membresía gaussianas, y un **Random Forest** como referencia de ensamble robusto.

2. Marco Teórico

2.1. Árboles de Decisión CART

El algoritmo **CART** (*Classification and Regression Trees*) construye un árbol binario particionando recursivamente el espacio de predictores mediante reglas del tipo $x_j \leq t$. En cada nodo se elige la partición que minimiza la impureza de Gini de los subconjuntos resultantes:

$$G = 1 - \sum_{c=1}^C p_c^2 \quad (1)$$

donde p_c es la proporción de observaciones de la clase c en el nodo. Un árbol sin restricciones de profundidad tiende a memorizar el conjunto de entrenamiento (varianza alta), lo que motiva las estrategias de regularización descritas a continuación.

2.2. Poda por Costo-Complejidad (`ccp_alpha`)

La poda por costo-complejidad busca el subárbol T_α que minimiza:

$$R_\alpha(T) = R(T) + \alpha |T| \quad (2)$$

donde $R(T)$ es la tasa de error del árbol, $|T|$ su número de hojas, y $\alpha \geq 0$ un parámetro de penalización: a mayor α , más se favorecen árboles pequeños. La ruta de poda (`cost_complexity_pruning_path`) calcula la secuencia de valores de α efectivos, que se usa para acotar la búsqueda de hiperparámetros.

2.3. Árbol Difuso (Lógica Difusa)

Como alternativa no paramétrica, se construyó un **puntaje difuso de riesgo** combinando funciones de membresía gaussianas sobre variables clínicamente relevantes:

$$\mu(x; \mu_0, \sigma) = \exp\left(-\frac{1}{2} \left(\frac{x-\mu_0}{\sigma}\right)^2\right) \quad (3)$$

El puntaje final es el promedio de los grados de membresía "alto riesgo" de edad, puntaje Z Talla/Edad y puntaje Z Peso/Edad; la clasificación se obtiene comparando este puntaje contra un **umbral optimizado** (maximizando F_1 sobre el conjunto de entrenamiento).

2.4. Random Forest como Referencia

Como benchmark robusto se entrenó un **Random Forest**, que promedia las predicciones de múltiples árboles entrenados sobre muestras *bootstrap* con aleatorización adicional de variables por partición, reduciendo la varianza respecto a un árbol individual sin aumentar sustancialmente el sesgo.

2.5. Importancia de Variables por Permutación

Además de la importancia intrínseca (disminución media de impureza Gini), se calculó la **importancia por permutación**: la caída real de *balanced accuracy* al permutar aleatoriamente los valores de una variable en el conjunto de prueba, que es menos sesgada frente a variables de alta cardinalidad.

2.6. Métricas de Evaluación

Dado el desbalance de clases (69 % Sin_Anemia / 31 % Con_Anemia), se prioriza la **Balanced Accuracy** sobre la Accuracy simple:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

$$\text{Balanced Accuracy} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right) \quad (5)$$

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (6)$$

$$\text{Recall (Sensibilidad)} = \frac{TP}{TP + FN} \quad (7)$$

$$\text{Especificidad} = \frac{TN}{TN + FP} \quad (8)$$

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \quad (9)$$

3. Descripción del Dataset

3.1. Fuente y Filtrado

El dataset proviene del módulo **RECH6** (Cuestionario Individual de Niños) de la ENDES 2024, con 20 290 registros originales y 43 columnas. Se aplicó el siguiente filtrado:

- $HC57A \in \{1, 2, 3, 4\}$: nivel de anemia efectivamente medido (Nueva Directriz OMS 2024), lo que redujo el dataset a 18 358 casos.
- $HC2, HC3, HC70, HC71, HC72, HC73 < 9000$: se descartan los códigos de peso, talla y puntuaciones Z fuera de límites plausibles o marcados.
- $HC61 \in \{0, 1, 2, 3\}$: nivel educativo de la madre con código válido.

Tras el filtrado quedaron **17 798 niños** con información completa y válida —el mismo dataset utilizado en los informes previos de Naive Bayes y Random Forest de este curso, para mantener comparabilidad entre modelos.

Cuadro 1: Descripción de variables del modelo — Módulo RECH6 (ENDES 2024)

Variable	Descripción	Tipo
Edad_meses	Edad del niño en meses (HC1, 6–59)	Numérica
Peso_kg	Peso corporal en kg (HC2/10)	Numérica
Talla_cm	Talla corporal en cm (HC3/10)	Numérica
TallaEdad_DE	Puntuación Z Talla/Edad, OMS (HC70/100)	Numérica
PesoEdad_DE	Puntuación Z Peso/Edad, OMS (HC71/100)	Numérica
PesoTalla_DE	Puntuación Z Peso/Talla, OMS (HC72/100)	Numérica
IMC_DE	Puntuación Z de IMC, OMS (HC73/100)	Numérica
Sexo	Sexo del niño (HC27: Hombre / Mujer)	Categórica
EducMadre	Nivel educativo de la madre (HC61)	Categórica
NivelAnemia	Variable objetivo: Con_Anemia (HC57A $\in$ {1, 2, 3}) / Sin_Anemia (HC57A=4)	Binaria

Nota metodológica: la hemoglobina (HC56A y variables relacionadas) se excluyó de los predictores por definir directamente al target; se conserva únicamente como referencia visual (Figura 2), no como *feature* del modelo.

3.2. Estadísticas Descriptivas

Cuadro 2: Estadísticas descriptivas de las variables numéricas

Variable	Media	Desv. Est.	Mín	Mediana	Máx
Edad_meses	32.294	15.621	6.00	32.00	59.00
Peso_kg	13.230	3.460	4.90	13.00	31.90
Talla_cm	88.718	11.844	55.20	89.60	119.00
TallaEdad_DE	-0.877	1.013	-5.51	-0.88	3.54
PesoEdad_DE	-0.141	1.041	-4.54	-0.18	4.43
PesoTalla_DE	0.480	1.011	-4.74	0.44	4.92
IMC_DE	0.576	0.994	-4.87	0.54	4.97

3.3. Distribución de la Variable Objetivo

Cuadro 3: Distribución del nivel de anemia

Diagnóstico	Frecuencia	Porcentaje (%)
Sin_Anemia	12 189	68.49
Con_Anemia	5 609	31.51




Figura 1: Distribución absoluta de la variable objetivo NivelAnemia




Figura 2: Hemoglobina ajustada por NivelAnemia (uso referencial, no es predictor del modelo)

3.4. Variables Categóricas

Cuadro 4: Distribución de las variables categóricas

Variable	Categoría	Frecuencia
Sexo	Hombre	9 035
	Mujer	8 763
EducMadre	Secundaria	12 144
	Superior	2 783
	Primaria	2 693
	Sin_educacion	178




Figura 3: Variables categóricas (Sexo, EducMadre) según NivelAnemia

3.5. Correlación y Distribución de Predictores




Figura 4: Heatmap de correlaciones entre las variables numéricas y el target




Figura 5: Distribución de Edad_meses, TallaEdad_DE e IMC_DE según NivelAnemia




Figura 6: Distribución de la edad (meses) por NivelAnemia

4. Preprocesamiento y Configuración del Modelo

4.1. Codificación de Variables Categóricas

Las variables `Sexo` y `EducMadre` se transformaron mediante **One-Hot Encoding** (`drop_first=False`), generando 6 columnas dummy. Combinadas con las 7 variables numéricas, el modelo utiliza **13 predictores** en total. A diferencia de Naive Bayes, los árboles de decisión **no requieren escalado**: son invariantes a transformaciones monótonas de los predictores.

4.2. División del Dataset

$$\underbrace{80\%}_{\text{Entrenamiento}} + \underbrace{20\%}_{\text{Prueba}} = 100\% \implies 14\,238 + 3\,560 = 17\,798 \text{ niños} \quad (10)$$

La división se realizó de forma **estratificada** respecto al target (`NivelAnemia`), con `random_state=42`.

Cuadro 5: Distribución del target en entrenamiento y prueba

Clase	Entrenamiento (n=14 238)	Prueba (n=3 560)
Sin _Anemia	9 751	2 438
Con _Anemia	4 487	1 122

4.3. Implementación de los Modelos

- **CART Simple:** `max_depth=4`, `min_samples_split=10`, `min_samples_leaf=5` (hiperparámetros fijos, sin optimización).
- **CART Optimizado:** `GridSearchCV` con validación cruzada estratificada repetida (5 folds), optimizando *balanced accuracy* sobre la grilla `max_depth` ∈ {3, 4, 5, 6}, `min_samples_split` ∈ {10, 20, 30}, `min_samples_leaf` ∈ {5, 10, 15}, `class_weight` ∈ {None, balanced}, y 5 valores de `ccp_alpha` tomados de la ruta de poda del árbol simple (360 combinaciones, 1 800 ajustes).
- **Árbol Difuso:** puntaje difuso (Ecuación 3) sobre edad, `TallaEdad_DE` y `PesoEdad_DE`, con umbral optimizado por F_1 en entrenamiento.
- **Random Forest:** 300 árboles, `class_weight="balanced"`, `max_features="sqrt"`, como referencia de ensamble.

Cuadro 6: Mejores hiperparámetros encontrados por `GridSearchCV` (CART Optimizado)

Hiperparámetro	Valor óptimo
<code>max_depth</code>	6
<code>min_samples_split</code>	10
<code>min_samples_leaf</code>	5
<code>class_weight</code>	balanced
<code>ccp_alpha</code>	0.00039
Mejor Balanced Accuracy (CV)	0.5976

5. Resultados

5.1. Comparación General de Modelos

Cuadro 7: Comparación de los 4 modelos — conjunto de prueba ($n = 3\,560$)

Modelo	Accuracy	Balanced Accuracy	F1 Macro
CART Simple	0.6913	0.5319	0.4905
CART Optimizado	0.6143	0.5953	0.5836
Fuzzy Tree	0.4340	0.5466	0.4280
Random Forest	0.6551	0.5591	0.5592

Cuadro 8: Validación cruzada repetida (5 folds $\times$ 3 repeticiones)

Modelo	Accuracy ($\mu \pm \sigma$)	Bal. Accuracy ($\mu \pm \sigma$)	F1 Macro ($\mu \pm \sigma$)
CART Simple	0.6911 ± 0.0036	0.5496 ± 0.0091	0.5288 ± 0.0170
CART Optimizado	0.6078 ± 0.0213	0.5986 ± 0.0096	0.5819 ± 0.0140
Fuzzy Tree	0.4374 ± 0.0074	0.5528 ± 0.0061	0.4307 ± 0.0084
Random Forest	0.6569 ± 0.0038	0.5613 ± 0.0052	0.5616 ± 0.0058




Figura 7: Accuracy vs Balanced Accuracy — conjunto de prueba, los 4 modelos

El **CART Optimizado** obtiene la mejor *Balanced Accuracy* tanto en prueba (**0.5953**) como en validación cruzada (**0.5986 ± 0.0096**), superando a Random Forest (0.5591 / 0.5613) y muy por encima del CART Simple (0.5319 / 0.5496). Aunque su *accuracy* bruta (61.4 %) es menor que la del CART Simple (69.1 %) o Random Forest (65.5 %), esa *accuracy* más alta es **engañoso**: se logra prediciendo casi siempre *Sin_Anemia*, la clase mayoritaria (ver Sección 5.2).

5.2. Matrices de Confusión

Cuadro 9: Matrices de confusión — conjunto de prueba (n = 3 560)

Modelo	TN	FP	FN	TP
CART Simple	2 348	90	1 009	113
CART Optimizado	1 577	861	512	610
Fuzzy Tree	590	1 848	167	955
Random Forest	1 996	442	786	336




Figura 8: Matrices de confusión — CART Simple, CART Optimizado, Fuzzy Tree y Random Forest

El CART Simple clasifica correctamente 2 348 de 2 438 niños Sin_Anemia (96 % de especificidad), pero solo detecta **113 de 1 122** niños Con_Anemia (recall de apenas **10.1 %**). El CART Optimizado, al usar `class_weight="balanced"`, detecta **610 de 1 122** (recall **54.4 %**) a costa de más falsos positivos (861). El Fuzzy Tree se va al extremo opuesto: detecta el 85 % de los casos de anemia, pero a costa de clasificar mal a más de las tres cuartas partes de los niños sanos.

5.3. Métricas por Clase — Mejor Modelo (CART Optimizado)

Cuadro 10: Precisión, recall y F1-score por clase — CART Optimizado (conjunto de prueba)

Clase	Precisión	Recall	F1-Score	Soporte
Sin_Anemia	0.75	0.65	0.70	2 438
Con_Anemia	0.41	0.54	0.47	1 122
Macro avg	0.58	0.60	0.58	3 560
Weighted avg	0.65	0.61	0.63	3 560

Métrica	Valor
Accuracy final	0.6143 (61.43 %)
Balanced Accuracy	0.5953 (59.53 %)
Precisión (Con_Anemia)	0.4147
Recall (Con_Anemia)	0.5437
Especificidad	0.6468
F1-Score (Con_Anemia)	0.4705

Interpretación: el CART Optimizado identifica correctamente el **54.4 %** de los niños con anemia —muy por encima del 10.1 % del CART Simple, del 16.1 % reportado para Random Forest en el informe previo del curso, y del 35.3 % de Naive Bayes— a cambio de una especificidad menor (64.7 %). Para un caso de uso de tamizaje clínico, este es un compromiso más razonable: prioriza no dejar de detectar niños en riesgo.

5.4. Importancia de Variables




Figura 9: Importancia de variables — CART Optimizado (Gini y Permutación) y Random Forest (Gini)

Cuadro 11: Importancia de variables por permutación — CART Optimizado (top 5)

Variable	Caída de Balanced Accuracy
Talla_cm	0.0785
EducMadre_Superior	0.0092
Edad_meses	0.0089
EducMadre_Primeria	0.0065
IMC_DE	0.0001

El 63.9 % de la importancia Gini del CART Optimizado recae en **Talla_cm**: el árbol, tras la poda, colapsó a un modelo que decide principalmente por un umbral de estatura, con aportes menores de nivel educativo materno y edad. Esto contrasta con el Random Forest (Figura 9, panel derecho), cuya importancia se reparte de forma mucho más uniforme entre **Talla_cm** (15.8 %), **TallaEdad_DE** (14.7 %), **PesoEdad_DE** (14.0 %), **IMC_DE** (13.5 %) y **PesoTalla_DE** (13.4 %) — evidencia de que el ensamble

aprovecha mejor los puntajes Z antropométricos que un único árbol podado.

5.5. Predicción sobre un Caso de Ejemplo

Se evaluó el CART Optimizado sobre un niño hipotético de 18 meses, con $Talla_{Edad_DE} = -1,8$, $Peso_{Edad_DE} = -1,2$, $PesoTalla_{DE} = -0,5$, $IMC_{DE} = -0,6$, sexo Mujer y madre con educación Secundaria:

Cuadro 12: Predicción sobre el caso de ejemplo (CART Optimizado)

Resultado	Valor
Predicción	Con _Anemia
Probabilidad de Con _Anemia	0.5633

Este perfil, con puntajes Z moderadamente negativos característicos de un déficit nutricional leve-moderado, fue clasificado como **Con_Anemia** con una probabilidad apenas superior al umbral de decisión (56.3 %) — un caso límite consistente con el *recall* moderado (54 %) del modelo.

6. Conclusiones

- 1. La optimización con `class_weight="balanced"` triplicó el recall de la clase minoritaria.** El CART Simple prácticamente ignora la clase **Con_Anemia** (recall 10.1 %), mientras que el CART Optimizado —al incorporar `class_weight` y podar con `ccp_alpha` en la búsqueda de `GridSearchCV`— eleva el recall a **54.4 %**, a costa de una *accuracy* global menor. Esto confirma que *accuracy* es una métrica engañosa en datasets desbalanceados (69 %/31 %): *Balanced Accuracy* y F_1 por clase cuentan una historia más honesta.
- 2. El árbol óptimo colapsó en un modelo casi univariado.** Tras la poda por costo-complejidad, el 63.9 % de la importancia Gini del CART Optimizado recae en `Talla_cm`. Esto sugiere que, para este dataset, un único árbol no logra aprovechar la información conjunta de los 4 puntajes Z antropométricos tan bien como el Random Forest, cuya importancia se distribuye de forma mucho más pareja.
- 3. El árbol difuso prioriza sensibilidad sobre especificidad de forma extrema.** Con un recall de 85.1 % para **Con_Anemia** pero una especificidad de solo 24.2 %, el Fuzzy Tree ilustra el otro extremo del compromiso sensibilidad-especificidad: útil como filtro de primera línea muy conservador, pero generando demasiados falsos positivos para uso clínico directo sin una etapa de confirmación posterior.
- 4. Random Forest ofrece el mejor equilibrio entre accuracy y estabilidad,** pero no el mejor *Balanced Accuracy*. Su recall para **Con_Anemia** (30.0 %) queda por debajo del CART Optimizado (54.4 %), reforzando que la elección del "mejor" modelo depende del costo relativo de falsos negativos frente a falsos positivos en el caso de uso.

5. **La poda por costo-complejidad es una herramienta de regularización efectiva.** El valor óptimo hallado (`ccp_alpha=0.00039`) es pequeño pero no nulo, y junto con `max_depth=6` evita tanto el sobreajuste del árbol sin restricciones como la simplificación excesiva de un árbol con `max_depth` muy bajo.
6. **Prevención de *data leakage*.** La hemoglobina se excluyó de los predictores por definir directamente al target, y ningún hiperparámetro se ajustó mirando el conjunto de prueba, garantizando la validez metodológica de la evaluación.

6.1. Recomendaciones

Se recomienda comparar estos árboles con los demás clasificadores de la serie (Naive Bayes, Random Forest, K-NN, LDA, QDA) usando *Balanced Accuracy* y F_1 por clase como criterio principal de selección, dado el desbalance de clases. También se sugiere explorar técnicas de remuestreo (SMOTE, *undersampling*) como alternativa o complemento a `class_weight="balanced"`, ajustar directamente el umbral de decisión del CART Optimizado en lugar de 0.5, e incorporar variables adicionales del cuestionario del hogar (acceso a agua, saneamiento, altitud) que podrían mejorar la capacidad discriminativa más allá de la talla.