



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

ANÁLISIS DISCRIMINANTE LINEAL Y CUADRÁTICO

Reclasificación de Buenos Clientes — Compartamos Financiera

Curso: Aprendizaje Supervisado
Docente: Carpio Vargas Edgar Eloy
Estudiante: Luque Cornejo Zulema Yasmile
Dataset: databuenosclientes.xlsx
(114 clientes, 25 variables originales)
Variable objetivo: Categoría del cliente
(A / A+ / B)
Repositorio: [GitHub/CLIENTES](#)
Institución: Compartamos Financiera
Fecha: 22 de junio de 2026

0 Índice

Introducción General	3
I Preparación del Dataset	4
1. Descripción del Dataset	4
2. Limpieza y Preparación de Datos	5
II Verificación de Supuestos	7
3. Análisis Exploratorio de Datos	7
4. Supuesto 1: Normalidad Univariante (Shapiro-Wilk)	7
5. Supuesto 2: Homogeneidad de Matrices de Covarianza	8
6. Supuesto 3: Multicolinealidad	9
III Análisis Discriminante Lineal (LDA)	10
7. Fundamento Teórico	10
8. Estimación del Modelo	10
8.1. Medias de grupo en el espacio escalado	10
8.2. Coeficientes de las funciones discriminantes	11
8.3. Función discriminante LD1	11
9. Reclasificación: Predicciones y Probabilidades Posteriores	12
10. Evaluación del Modelo LDA	12
10.1. Matriz de confusión	12
10.2. Métricas de desempeño	13
10.3. Validación cruzada	13
10.4. Clientes mal clasificados	13
11. Visualización del Espacio Discriminante	14

IV Análisis Discriminante Cuadrático (QDA)	15
12.Fundamento Teórico	15
13.Estimación del Modelo	15
14.Evaluación del Modelo QDA	15
14.1. Matriz de confusión	15
14.2. Métricas de desempeño	16
Comparación entre Modelos y Conclusiones	17
15.Resumen Comparativo	17
16.Predicción para Nuevos Clientes	18
17.Conclusiones Generales	18

0 Introducción General

El presente informe desarrolla dos modelos de **análisis discriminante** aplicados al problema de **reclasificar a los clientes** de una entidad microfinanciera (Compartamps Financiera) según su perfil crediticio, utilizando variables de mora, endeudamiento e ingresos registradas a nivel de cliente.

El análisis discriminante busca una combinación lineal (o cuadrática) de variables predictoras que separe óptimamente a G grupos preestablecidos. Para el caso lineal (LDA), la función discriminante de Fisher es:

$$D_j = \sum_{i=1}^p \beta_{ij} X_i$$

y la regla de clasificación bayesiana asigna cada observación al grupo k que maximiza la probabilidad posterior:

$$P(G = k | X) = \frac{\pi_k f_k(X)}{\sum_{l=1}^G \pi_l f_l(X)}$$

donde π_k es la probabilidad a priori del grupo k y $f_k(X)$ es la densidad normal multivariante del grupo. El **LDA** asume una matriz de covarianza *común* entre grupos (fronteras de decisión lineales), mientras que el **QDA** estima una matriz de covarianza distinta por grupo (fronteras de decisión cuadráticas).

Objetivos del Informe

- Preparar y depurar el dataset de clientes, documentando la imputación de valores faltantes.
- Verificar los supuestos de normalidad univariante (Shapiro-Wilk), homogeneidad de varianzas (Levene) y multicolinealidad.
- Ajustar y evaluar un modelo de Análisis Discriminante Lineal (LDA) para reclasificar a los clientes en las categorías A, A+ y B.
- Ajustar y evaluar un modelo de Análisis Discriminante Cuadrático (QDA) como alternativa cuando la homogeneidad de covarianzas no se cumple.
- Comparar el desempeño de ambos modelos mediante matriz de confusión, validación cruzada 5-fold y Leave-One-Out (LOO), e identificar a los clientes mal clasificados.

Parte I

Preparación del Dataset

1 Descripción del Dataset

El archivo `databuenosclientes.xlsx` contiene **114 clientes** con **25 variables** originales, incluyendo información de mora, deuda, ingresos y la categoría asignada por el analista de crédito. Para este análisis se seleccionaron **12 variables independientes** de naturaleza numérica, relevantes para el perfil crediticio:

Cuadro 1: Variables independientes seleccionadas

Variable	Descripción
<code>mora promedio del cliente (dias)</code>	Mora promedio histórica del cliente
<code>atraso maximo del cliente (dias)</code>	Atraso máximo histórico
<code>atraso maximo del cliente ultimos 3 meses (dias)</code>	Atraso máximo reciente (últimos 3 meses)
<code>numero de creditos vigentes</code>	Cantidad de créditos activos
<code>maximo capital desembolsado vigente</code>	Mayor capital desembolsado vigente
<code>deuda total en compartamos</code>	Deuda total con la entidad
<code>numero de empresas en la SBS</code>	Número de entidades financieras donde el cliente tiene deuda (SBS)
<code>deuda directa en la SBS</code>	Deuda directa reportada en el sistema financiero (SBS)
<code>Ingresos</code>	Ingresos mensuales declarados
<code>egresos</code>	Egresos mensuales declarados
<code>resultado neto</code>	Resultado neto (Ingresos – egresos)
<code>monto aprobado de cash</code>	Monto del crédito aprobado

Variable dependiente: `cliente`, con tres categorías (A, A+, B) que reflejan la calificación crediticia asignada por el analista.

Cuadro 2: Distribución de la variable dependiente `cliente`

Categoría	Frecuencia	Porcentaje
A	61	53.5 %
A+	28	24.6 %
B	25	21.9 %
Total	114	100.0 %

La muestra está **moderadamente desbalanceada**: la categoría A representa más de la mitad de los clientes (53.5 %), mientras que A+ y B concentran proporciones similares y minoritarias. Esto condiciona las probabilidades a priori del modelo y favorece la clasificación hacia la categoría mayoritaria.

2 Limpieza y Preparación de Datos

Dos variables presentaron valores nulos, los cuales fueron imputados con la **mediana** de cada columna:

Listing 1: Imputación de valores nulos y preparación del dataset

```

1 VARS_INDEP = [
2     'mora promedio del cliente (dias)',
3     'atraso maximo del cliente (dias)',
4     'atraso maximo del cliente ultimos 3 meses (dias)',
5     'numero de creditos vigentes',
6     'maximo capital desembolsado vigente',
7     'deuda total en compartamos',
8     'numero de empresas en la SBS',
9     'deuda directa en la SBS',
10    'Ingresos',
11    'egresos',
12    'resultado neto',
13    'monto aprobado de cash'
14 ]
15 VAR_DEP = 'cliente'
16
17 df = df_raw[[VAR_DEP] + VARS_INDEP].copy()
18
19 # Imputar nulos numericos con la mediana de cada columna
20 for col in VARS_INDEP:
21     if df[col].isnull().sum() > 0:
22         mediana = df[col].median()
23         df[col].fillna(mediana, inplace=True)

```

Cuadro 3: Resultado de la imputación de valores faltantes

Variable	Mediana imputada
numero de empresas en la SBS	2.00
deuda directa en la SBS	2 480.13

Cuadro 4: Resultado de la preparación del dataset

Descripción	Valor
Registros originales	114
Variables originales	25
Variables independientes usadas	12
Registros válidos	114 (100 %)

Posteriormente, la variable dependiente se codificó numéricamente (`LabelEncoder`: $A=0$, $A+=1$, $B=2$) y las 12 variables independientes se **estandarizaron** (`StandardScaler`, media 0 y desviación 1) antes del ajuste de los modelos, dado que las variables originales presentan escalas muy distintas (días, soles, cantidades).

Parte II

Verificación de Supuestos

3 Análisis Exploratorio de Datos

Cuadro 5: Probabilidades a priori estimadas ($\hat{\pi}_k$)

Categoría	$\hat{\pi}_k$	Porcentaje
A	0.5351	53.5 %
A+	0.2456	24.6 %
B	0.2193	21.9 %




Figura 1: Distribución de la variable dependiente `cliente` y boxplots de las principales variables independientes (`mora`, `ingresos`, `resultado neto`, `deuda`, `monto aprobado`, `atraso máximo`) por categoría.

Los boxplots y mapas de correlación muestran que los clientes **A+** tienden a presentar menor `mora` y `atraso`, mientras que los clientes **B** muestran mayor dispersión en `deuda` y menores `ingresos netos`.

4 Supuesto 1: Normalidad Univariante (Shapiro-Wilk)

Se aplicó la prueba de **Shapiro-Wilk** a cada una de las 12 variables independientes, dentro de cada una de las 3 categorías (36 combinaciones en total), bajo la hipótesis nula H_0 : la variable sigue una distribución normal.

Listing 2: Prueba de normalidad Shapiro-Wilk por variable y categoría

```

1 from scipy.stats import shapiro
2
3 resultados_sw = []

```



```

4 for cat in orden:
5     for var in VARS_INDEP:
6         datos = df[df[VAR_DEP] == cat][var]
7         W, p = shapiro(datos)
8         resultados_sw.append((cat, var, W, p, p >= 0.05))

```

Cuadro 6: Resumen de la prueba de Shapiro-Wilk (selección de resultados)

Categoría	Variable	W	p-valor	Normal
A	mora promedio del cliente (días)	0.7149	< 0,001	NO
A	Ingresos	0.8980	< 0,001	NO
A+	resultado neto	0.9241	0.0439	NO
A+	monto aprobado de cash	0.8887	0.0063	NO
B	numero de empresas en la SBS	0.6246	< 0,001	NO
B	monto aprobado de cash	0.6467	< 0,001	NO

Ninguna de las 36 combinaciones (12 variables $\times$ 3 categorías) cumple el supuesto de normalidad univariante ($p < 0,05$ en todos los casos). Esto representa una violación generalizada del supuesto teórico del LDA/QDA. Sin embargo, ambos métodos son **razonablemente robustos** ante violaciones moderadas de normalidad, especialmente cuando el tamaño de muestra por grupo no es extremadamente pequeño, por lo que se continúa con el análisis tomando esta limitación en cuenta al interpretar los resultados.

5 Supuesto 2: Homogeneidad de Matrices de Covarianza

Se utilizó la prueba de **Levene** (univariante, como proxy del test de Box's M) sobre cada una de las 12 variables, bajo H_0 : las varianzas son iguales en los tres grupos.

Cuadro 7: Prueba de homogeneidad de varianzas (Levene) por variable

Variable	Levene W	p-valor	Homogéneo
mora promedio del cliente (días)	0.3220	0.7254	SÍ
atraso máximo del cliente (días)	1.2102	0.3020	SÍ
atraso máximo últimos 3 meses	0.5427	0.5827	SÍ
número de créditos vigentes	0.2010	0.8182	SÍ
máximo capital desembolsado vigente	1.8364	0.1642	SÍ
deuda total en compartamos	1.6476	0.1972	SÍ
número de empresas en la SBS	3.2048	0.0443	NO
deuda directa en la SBS	3.6269	0.0298	NO
Ingresos	0.9597	0.3862	SÍ
egresos	0.7224	0.4878	SÍ
resultado neto	1.6394	0.1988	SÍ
monto aprobado de cash	0.9473	0.3909	SÍ

De las 12 variables, solo **2** (numero de empresas en la SBS y deuda directa en la SBS) rechazan la hipótesis de homogeneidad de varianzas. La **mayoría** (10 de 12) cumple el supuesto, lo cual **favorece la elección del LDA** sobre el QDA, ya que este último requiere estimar matrices de covarianza separadas con muestras pequeñas por grupo (25–61 observaciones), aumentando el riesgo de sobreajuste.

6 Supuesto 3: Multicolinealidad

Cuadro 8: Pares de variables con correlación $|r| > 0,7$

Variable 1	Variable 2	r
máximo capital desembolsado vigente	deuda total en compartamos	0.8531
máximo capital desembolsado vigente	deuda directa en la SBS	0.7839
deuda total en compartamos	deuda directa en la SBS	0.7551
Ingresos	egresos	0.9627

El determinante de la matriz de correlación fue de **0.000025**, un valor muy cercano a cero que confirma la presencia de **multicolinealidad relevante** entre las variables de endeudamiento (máximo capital desembolsado, deuda total, deuda SBS) y entre Ingresos y egresos.

A diferencia de la regresión logística, el LDA y el QDA **no requieren** ausencia estricta de multicolinealidad para producir una solución, pero la presencia de variables redundantes diluye la interpretabilidad de los coeficientes discriminantes y puede inflar artificialmente la varianza de las estimaciones. Se mantienen las 12 variables originales en este informe por fines descriptivos, dejando la simplificación del modelo como una línea de trabajo futura.

Parte III

Análisis Discriminante Lineal (LDA)

7 Fundamento Teórico

El LDA asume que cada grupo k sigue una distribución normal multivariante $X | G = k \sim N(\mu_k, \Sigma)$ con una matriz de covarianza **común** Σ para todos los grupos. Bajo este supuesto, la función discriminante resultante es **lineal** en X , y el número máximo de funciones discriminantes que pueden extraerse es:

$$\min(G - 1, p) = \min(3 - 1, 12) = 2$$

es decir, con 3 categorías se pueden obtener como máximo **2 funciones discriminantes** (LD1, LD2).

8 Estimación del Modelo

Listing 3: Ajuste del modelo LDA con scikit-learn

```
1 from sklearn.discriminant_analysis import
   LinearDiscriminantAnalysis
2
3 lda = LinearDiscriminantAnalysis(solver='svd', store_covariance=
   True)
4 lda.fit(X_scaled, y_enc)
```

8.1 Medias de grupo en el espacio escalado

Cuadro 9: Medias de grupo ($\hat{\mu}_k$) — espacio estandarizado (variables seleccionadas)

Variable	A	A+	B
mora promedio del cliente	-0,039	0,048	0,042
atraso máximo del cliente	-0,115	0,172	0,087
atraso máximo últimos 3 meses	0,060	-0,226	0,107
deuda directa en la SBS	0,236	-0,329	-0,207
Ingresos	0,080	0,057	-0,259
resultado neto	0,144	-0,080	-0,263
monto aprobado de cash	0,004	0,296	-0,340

8.2 Coeficientes de las funciones discriminantes

Cuadro 10: Coeficientes de las funciones discriminantes (*scalings*)

Variable	LD1	LD2
mora promedio del cliente (días)	0,1547	-0,5735
atraso máximo del cliente (días)	0,3117	0,5904
atraso máximo últimos 3 meses (días)	-0,5521	0,2647
número de créditos vigentes	0,1382	-0,3394
máximo capital desembolsado vigente	-0,3171	0,3523
deuda total en compartamos	0,5372	-0,5821
número de empresas en la SBS	-0,4510	-0,3074
deuda directa en la SBS	-0,7820	-0,1053
Ingresos	0,8704	-0,7112
egresos	-0,5886	0,2328
resultado neto	-0,5634	0,3545
monto aprobado de cash	0,8725	-0,5330
Varianza explicada	79.32 %	20.68 %

8.3 Función discriminante LD1

$$\begin{aligned}
 LD1 = & 0,1547 \times \text{mora_prom} + 0,3117 \times \text{atraso_max} \\
 & - 0,5521 \times \text{atraso_3m} + 0,1382 \times \text{n_creditos} \\
 & - 0,3171 \times \text{cap_desemb} + 0,5372 \times \text{deuda_compartamos} \\
 & - 0,4510 \times \text{n_empresas_SBS} - 0,7820 \times \text{deuda_SBS} \\
 & + 0,8704 \times \text{Ingresos} - 0,5886 \times \text{egresos} \\
 & - 0,5634 \times \text{resultado_neto} + 0,8725 \times \text{monto_cash}
 \end{aligned}$$

LD1 explica el 79.32 % de la varianza discriminante total, por lo que concentra casi toda la capacidad de separación de los grupos. Las variables con mayor peso (en valor absoluto) en LD1 son **Ingresos** (0.8704), **monto aprobado de cash** (0.8725) y **deuda directa en la SBS** (-0,7820), lo cual sugiere que la combinación de **capacidad de pago** (ingresos, monto aprobado) y **nivel de endeudamiento externo** (deuda SBS) es lo que más separa a las categorías de clientes.

9 Reclasificación: Predicciones y Probabilidades Posteriores

El modelo se evaluó mediante **reclasificación** (predicción sobre la misma muestra de entrenamiento), siguiendo la lógica clásica del análisis discriminante descriptivo.

Cuadro 11: Ejemplo de tabla de reclasificación LDA (primeras filas)

Clase Real	Clase Predicha	Correcta	P(A)	P(A+)	P(B)
A	A	✓	0.3691	0.3489	0.2820
A+	A+	✓	0.1465	0.8261	0.0274
A	A+	×	0.2272	0.7420	0.0309
A+	A	×	0.4349	0.3759	0.1892
B	A	×	0.4908	0.1768	0.3325
B	B	✓	0.3796	0.0326	0.5878

10 Evaluación del Modelo LDA

10.1 Matriz de confusión

Cuadro 12: Matriz de confusión — LDA (reclasificación, $n = 114$)

Real / Predicho	A	A+	B	Total
A	52	6	3	61
A+	13	14	1	28
B	20	3	2	25
Total	85	23	6	114




Figura 2: Matriz de confusión gráfica — LDA

10.2 Métricas de desempeño

Cuadro 13: Reporte de clasificación por categoría — LDA

Categoría	Precisión	Recall	F1-score	Soporte
A	0.61	0.85	0.71	61
A+	0.61	0.50	0.55	28
B	0.33	0.08	0.13	25
Accuracy	0.5965 (59.65 %)			114
Macro avg	0.52	0.48	0.46	114
Weighted avg	0.55	0.60	0.54	114

10.3 Validación cruzada

Cuadro 14: Validación cruzada — LDA

Métrica	Valor
Training Accuracy	59.65 %
Training Error	40.35 %
5-Fold CV Accuracy	53.48 % $\pm$ 3.79 %
Scores por fold	0.5217, 0.5217, 0.6087, 0.5217, 0.500
LOO CV Accuracy	46.49 %
LOO Error rate	53.51 %

El **training accuracy** (59.65 %) es notablemente más optimista que la **validación cruzada LOO** (46.49 %), una brecha de casi 13 puntos porcentuales. Esto confirma que el error de entrenamiento subestima el error real de generalización del modelo, y que la estimación LOO —al usar 113 observaciones para entrenar y 1 para validar en cada iteración— es la referencia más confiable dado el tamaño reducido de la muestra (114 clientes).

10.4 Clientes mal clasificados

El modelo LDA **clasifica incorrectamente a 46 de 114 clientes (40.4 %)**. El patrón de error más frecuente es la confusión entre las categorías A y B: numerosos clientes reales B son reclasificados como A (con probabilidades posteriores moderadas, entre 0.43 y 0.77), lo que indica que el perfil de riesgo de algunos clientes B se superpone considerablemente con el de los clientes A en el espacio de las 12 variables utilizadas.

11 Visualización del Espacio Discriminante




Figura 3: Puntuaciones discriminantes LD1 vs LD2 por categoría real, y mapa de probabilidades posteriores en el espacio discriminante.

En el plano LD1–LD2 se observa una separación parcial entre los grupos: los clientes A+ tienden a ubicarse en valores positivos de LD1, mientras que existe una superposición considerable entre A y B alrededor del origen, consistente con la baja precisión y recall obtenidos para la categoría B (precisión = 0.33, recall = 0.08).

Parte IV

Análisis Discriminante Cuadrático (QDA)

12 Fundamento Teórico

El QDA relaja el supuesto de igualdad de covarianzas del LDA, permitiendo que cada grupo tenga su propia matriz Σ_k . Esto genera fronteras de decisión **cuadráticas** y, en teoría, mayor flexibilidad cuando los grupos difieren no solo en su media sino también en su dispersión. El costo de esta flexibilidad es un mayor número de parámetros a estimar ($p(p+1)/2$ por grupo), lo cual incrementa el riesgo de sobreajuste, particularmente relevante aquí dado el tamaño reducido de los grupos (25 a 61 observaciones).

13 Estimación del Modelo

Listing 4: Ajuste del modelo QDA con scikit-learn

```
1 from sklearn.discriminant_analysis import
   QuadraticDiscriminantAnalysis
2
3 qda = QuadraticDiscriminantAnalysis(store_covariance=True)
4 qda.fit(X_scaled, y_enc)
```

14 Evaluación del Modelo QDA

14.1 Matriz de confusión

Cuadro 15: Matriz de confusión — QDA (reclasificación, $n = 114$)

Real / Predicho	A	A+	B	Total
A	8	20	33	61
A+	0	20	8	28
B	0	2	23	25
Total	8	42	64	114

14.2 Métricas de desempeño

Cuadro 16: Indicadores de desempeño — QDA

Métrica	Valor
Training Accuracy	44.74 %
Training Error	55.26 %
5-Fold CV Accuracy	32.49 % $\pm$ 12.86 %
LOO CV Accuracy	24.56 %
LOO Error rate	75.44 %

El QDA muestra un desempeño **notablemente inferior** al LDA en todas las métricas, y una varianza muy alta entre folds en la validación cruzada ($\pm 12.86\%$ frente a $\pm 3.79\%$ del LDA). Esto es consistente con lo esperado: al estimar 12 varianzas y $\binom{12}{2} = 66$ covarianzas *independientes por cada uno de los 3 grupos* con muestras de solo 25–61 observaciones, el modelo QDA **sobreajusta** severamente los datos de entrenamiento y generaliza mal, como lo confirma el desplome del LOO CV Accuracy a 24.56 %.

Comparación entre Modelos y Conclusiones

15 Resumen Comparativo

Cuadro 17: Comparación LDA vs QDA — principales métricas

Métrica	LDA	QDA
Supuesto de covarianza	Común (homocedástica)	Distinta por grupo
Training Accuracy	0.5965	0.4474
Training Error (%)	40.35 %	55.26 %
5-Fold CV Accuracy	0.5348	0.3249
5-Fold CV Std	±0.0379	±0.1286
LOO CV Accuracy	0.4649	0.2456
LOO Error (%)	53.51 %	75.44 %




Figura 4: Comparación visual de matrices de confusión — LDA (izquierda) vs QDA (derecha)

Hallazgo principal: el LDA supera al QDA en **todas** las métricas evaluadas, tanto en entrenamiento como en validación cruzada. La brecha es especialmente marcada en el LOO CV Accuracy (46.49 % del LDA vs 24.56 % del QDA), lo que confirma que la flexibilidad adicional del QDA no se traduce en mejor capacidad predictiva con este tamaño de muestra, sino en sobreajuste. Esto es coherente con el resultado de la prueba de Levene (Sección 6), donde la mayoría de las variables (10 de 12) cumplieron el supuesto de homogeneidad de varianzas, favoreciendo al LDA desde el diagnóstico de supuestos.

16 Predicción para Nuevos Clientes

Se evaluaron dos clientes hipotéticos con ambos modelos:

Cuadro 18: Predicción para clientes nuevos — LDA vs QDA

Caso	Modelo	Clase predicha	Probabilidad máxima
Buen perfil crediticio	LDA	A	0.4834
Buen perfil crediticio	QDA	A+	0.9702
Perfil de mayor riesgo	LDA	A	0.7811
Perfil de mayor riesgo	QDA	A+	0.8882

Es notable que el QDA asigna probabilidades posteriores **extremas** (cercanas a 0.97 y 0.89) en ambos casos hipotéticos, incluso para el cliente de mayor riesgo, mientras que el LDA produce probabilidades más moderadas y contrasta mejor entre ambos perfiles. Este comportamiento es otro síntoma del sobreajuste del QDA: al estimar covarianzas con tan pocos datos por grupo, el modelo se vuelve **excesivamente confiado** en sus predicciones, lo cual refuerza la recomendación de usar el LDA para la clasificación operativa de nuevos clientes.

17 Conclusiones Generales

Conclusiones — Análisis Discriminante de Buenos Clientes

1. **Los supuestos teóricos se cumplen solo parcialmente:** ninguna de las 36 combinaciones variable-categoría satisface normalidad univariante (Shapiro-Wilk, $p < 0,05$ en todos los casos), pero la **mayoría** de las variables (10 de 12) sí cumple homogeneidad de varianzas (Levene), lo cual favorece teóricamente al LDA sobre el QDA.
2. **El LDA supera consistentemente al QDA:** en entrenamiento (59.65 % vs 44.74 %), en validación cruzada 5-fold (53.48 % vs 32.49 %) y, de manera más concluyente, en validación LOO (46.49 % vs 24.56 %). La diferencia se explica por el tamaño limitado de la muestra (114 clientes en 3 grupos), insuficiente para estimar de forma estable las matrices de covarianza individuales que requiere el QDA.
3. **El poder discriminante se concentra en LD1:** la primera función discriminante explica el 79.32 % de la varianza total, y está dominada por las variables **Ingresos**, **monto aprobado de cash** y **deuda directa en la SBS**, sugiriendo que la dupla *capacidad de pago vs. endeudamiento externo* es el eje principal que distingue a los clientes A, A+ y B.
4. **La categoría B es la más difícil de clasificar:** con el LDA, su precisión es de solo 0.33 y su recall de 0.08 —de 25 clientes reales B, solo 2 fueron correctamente reclasificados—, lo que indica una fuerte superposición de

perfiles entre A y B en las variables disponibles.

5. **La brecha entre el error de entrenamiento y el error LOO es considerable** (40.35 % vs 53.51 % para LDA), confirmando que el accuracy de reclasificación sobre la misma muestra es optimista y que la validación LOO ofrece una estimación más realista del desempeño esperado sobre clientes nuevos.
6. **Recomendación:** se recomienda adoptar el **LDA** como modelo de apoyo a la reclasificación de clientes, dado su mejor desempeño y mayor estabilidad frente al QDA. Para mejorar la discriminación de la categoría B, se sugiere: (a) incorporar variables adicionales (p. ej. historial de pago a más largo plazo, garantías, sector económico), (b) reducir la multicolinealidad detectada entre variables de endeudamiento e ingresos mediante técnicas de selección de variables, y (c) ampliar el tamaño de muestra para estabilizar las estimaciones, especialmente si se desea explorar nuevamente el QDA en el futuro.