



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

ANÁLISIS DISCRIMINANTE LINEAL Y CUADRÁTICO

Curso: Análisis Discriminante
Docente: Carpio Vargas Edgar Eloy
Estudiante: Luque Cornejo Zulema Yasmile
Dataset: RECH6_2024.csv (ENDES 2024)
(20 290 registros, 43 variables originales)
Variable objetivo: Nivel de anemia infantil
(Con_anemia / Sin_anemia)
Herramientas: Python 3 (scikit-learn, scipy, pandas)
R 4.x (MASS, biotools, MVN, caret, klaR)
Repositorio: [GitHub/DISCRIMINANTE](#)
Fecha: 21 de junio de 2026

0 Índice

Introducción General	3
I Preparación del Dataset	4
1. Descripción del Dataset	4
2. Limpieza y Preparación de Datos	4
II Análisis Discriminante Lineal (LDA)	6
3. Fundamento Teórico	6
4. Verificación de Supuestos	6
4.1. Normalidad univariante (Shapiro-Wilk)	6
4.2. Normalidad multivariante (Test de Mardia)	7
4.3. Homogeneidad de matrices de covarianza (Test M de Box)	7
5. Ajuste del Modelo LDA	8
5.1. Medias por grupo	8
5.2. Función discriminante	8
5.3. Poder discriminante y significancia	9
6. Evaluación del Modelo LDA	9
7. Predicción de un Nuevo Caso	11
III Análisis Discriminante Cuadrático (QDA)	12
8. Fundamento Teórico	12
9. Homogeneidad de Covarianzas y Justificación del QDA	12
10. Ajuste del Modelo QDA	12
10.1. Matrices de covarianza por grupo	13
11. Evaluación del Modelo QDA	13

11.1. Regiones de decisión	15
12. Predicción de un Nuevo Caso	15
Comparación entre Modelos y Conclusiones	16
13. Resumen Comparativo	16
14. Conclusiones Generales	17

0 Introducción General

El presente informe desarrolla dos técnicas de **aprendizaje supervisado de clasificación**: el **Análisis Discriminante Lineal** (LDA, *Linear Discriminant Analysis*) y el **Análisis Discriminante Cuadrático** (QDA, *Quadratic Discriminant Analysis*), aplicadas al problema de clasificar la presencia de **anemia infantil** a partir de variables antropométricas, usando los microdatos de la Encuesta Demográfica y de Salud Familiar (ENDES) 2024 del INEI, módulo RECH6.

Ambas técnicas buscan una regla de clasificación que asigne cada observación al grupo más probable, pero difieren en un supuesto clave: el LDA asume que todos los grupos comparten la **misma matriz de covarianzas**, lo que genera fronteras de decisión **lineales**; el QDA no hace esa suposición y estima una matriz de covarianzas **distinta para cada grupo**, lo que genera fronteras de decisión **curvas (cuadráticas)**.

Objetivos del Informe

- Preparar el dataset de anemia infantil a partir del archivo crudo de ENDES, documentando y justificando cada exclusión de datos.
- Verificar los supuestos del análisis discriminante: normalidad univariante (Shapiro-Wilk), normalidad multivariante (Mardia) y homogeneidad de matrices de covarianza (M de Box).
- Ajustar y evaluar un modelo LDA (procedimiento de Fisher).
- Ajustar y evaluar un modelo QDA, contrastando sus matrices de covarianza por grupo.
- Comparar el desempeño de ambos modelos mediante matriz de confusión, curva ROC, AUC y validación cruzada de 10 pliegues.

Parte I

Preparación del Dataset

1 Descripción del Dataset

El archivo RECH6_2024.csv contiene **20 290 registros** de niños menores de 5 años con **43 variables** originales, documentadas en el diccionario de variables del INEI (Diccionario_RECH6.pdf). Para este análisis se seleccionaron las siguientes variables:

Cuadro 1: Variables seleccionadas del dataset RECH6_2024.csv		
Variable	Código ENDES	Descripción
edad_meses	HC1	Edad del niño en meses
peso_kg	HC2	Peso en kilogramos
talla_cm	HC3	Talla en centímetros
talla_edad_z	HC70	Z-score Talla/Edad (OMS)
peso_edad_z	HC71	Z-score Peso/Edad (OMS)
grupo_anemia	HC57A	Variable objetivo: nivel de anemia (Directriz OMS 2024 / RM 251-2024-MINSA)

Se excluyó deliberadamente la **hemoglobina** (HC53/HC56A) como predictor, ya que es la variable que *define* la anemia: incluirla generaría circularidad y una fuga de información que invalidaría el análisis.

2 Limpieza y Preparación de Datos

El archivo de ENDES utiliza **códigos numéricos para "valor no medido"**, documentados explícitamente en el diccionario de variables del INEI. Estos códigos no son datos reales y deben excluirse antes de cualquier análisis estadístico:

Cuadro 2: Códigos de "no medido"según el diccionario INEI			
Variable	Significado	Rango válido	Código "no medido"
HC2	Peso en kg (×10, 1 decimal)	15:500	9999
HC3	Talla en cm (×10, 1 decimal)	400:1500	9999
HC70	Z-score Talla/Edad (OMS)	−450:500	9996, 9997, 9998
HC71	Z-score Peso/Edad (OMS)	−450:500	9996, 9997, 9998
HC57A	Nivel de anemia (OMS 2024)	1:4	9 (No sabe)

Listing 1: Preparación del dataset en Python

```
1 df_crudo = pd.read_csv("RECH6_2024.csv", sep=";", low_memory=False)
2
```

```

3 mask_validos = (
4     (datos['peso_kg_x10'] < 999) &
5     (datos['talla_cm_x10'] < 9999) &
6     (datos['anemia_oms'].isin([1, 2, 3, 4])) &
7     (datos['talla_edad_z_x100'].abs() < 9000) &
8     (datos['peso_edad_z_x100'].abs() < 9000)
9 )
10 datos = datos[mask_validos].copy()
11
12 # Conversion a unidades reales
13 datos['peso_kg'] = datos['peso_kg_x10'] / 10
14 datos['talla_cm'] = datos['talla_cm_x10'] / 10
15 datos['talla_edad_z'] = datos['talla_edad_z_x100'] / 100
16 datos['peso_edad_z'] = datos['peso_edad_z_x100'] / 100
17
18 # Agrupacion de la variable dependiente en 2 categorias
19 datos['grupo_anemia'] = np.where(datos['anemia_oms'] == 4,
20                                  'Sin_anemia', 'Con_anemia')

```

Adicionalmente, las tres categorías de anemia con presencia de la condición (Grave, Moderada, Leve) se agruparon en una sola clase **Con_anemia**, ya que por separado los grupos resultan demasiado pequeños para un análisis discriminante robusto (18, 1 371 y 4 371 casos, respectivamente, frente a 12 598 casos sin anemia).

Cuadro 3: Resultado de la preparación del dataset

Descripción	Valor
Registros originales (crudo)	20 290
Filas excluidas (código "no medido")	1 984
Registros válidos	18 306 (90.2 %)
Grupo Sin_anemia	12 552 (68.6 %)
Grupo Con_anemia	5 754 (31.4 %)

No se descartó ningún otro dato ni se modificaron valores reales de ningún niño: únicamente se excluyeron observaciones marcadas como "no medidas" por el propio diseño de la encuesta ENDES.

Parte II

Análisis Discriminante Lineal (LDA)

3 Fundamento Teórico

El LDA busca una combinación lineal de las variables independientes que maximice la separación entre grupos, mediante el procedimiento de Fisher. La función discriminante toma la forma:

$$D = u_1X_1 + u_2X_2 + \cdots + u_kX_k,$$

donde los coeficientes u_j se obtienen maximizando el cociente entre la variabilidad *entre* grupos y la variabilidad *intra* grupos:

$$\frac{\mathbf{u}'\mathbf{B}\mathbf{u}}{\mathbf{u}'\mathbf{W}\mathbf{u}},$$

con $\mathbf{W}$ la matriz de suma de cuadrados intra-grupos y $\mathbf{B}$ la matriz de suma de cuadrados inter-grupos. El supuesto central del LDA es que la matriz de covarianzas es **igual en todos los grupos**, lo que produce una frontera de decisión **lineal**.

4 Verificación de Supuestos

4.1 Normalidad univariante (Shapiro-Wilk)

Se contrastó, para cada predictor y cada grupo, la hipótesis nula de que la variable se distribuye normalmente (submuestra de 500 observaciones por celda, dado el tamaño grande de la muestra completa):

Cuadro 4: Test de Shapiro-Wilk por variable y grupo

Grupo	Variable	Estadístico W	p-value
Sin_anemia	edad_meses	0.9545	< 0,001
Sin_anemia	peso_kg	0.9894	0.0011
Sin_anemia	talla_cm	0.9753	< 0,001
Sin_anemia	talla_edad_z	0.9959	0.2198
Sin_anemia	peso_edad_z	0.9869	0.0002
Con_anemia	edad_meses	0.9308	< 0,001
Con_anemia	peso_kg	0.9651	< 0,001
Con_anemia	talla_cm	0.9669	< 0,001
Con_anemia	talla_edad_z	0.9948	0.0895
Con_anemia	peso_edad_z	0.9815	< 0,001

La mayoría de variables rechaza la normalidad estricta, excepto `talla_edad_z` en ambos grupos. Esto es esperable con un tamaño de muestra grande, donde Shapiro-Wilk detecta desviaciones mínimas de la normalidad. El LDA es razonablemente robusto ante apartamientos moderados de este supuesto.




Figura 1: QQ-plots de los 5 predictores, por grupo (Sin_anemia / Con_anemia)

4.2 Normalidad multivariante (Test de Mardia)

Cuadro 5: Test de Mardia (asimetría y curtosis multivariante, submuestra n=2000)

Estadístico	Valor	p-value
Mardia Skewness	6 434.005	< 0,001
Mardia Kurtosis	67.907	< 0,001

Ambos test rechazan la normalidad multivariante conjunta, una limitación común en datos reales de encuestas poblacionales con escalas heterogéneas.

4.3 Homogeneidad de matrices de covarianza (Test M de Box)

H₀: las matrices de covarianza son iguales entre los grupos Con_anemia y Sin_anemia.

Cuadro 6: Test M de Box

Estadístico	Valor
Chi-cuadrado aproximado	2 277.788
Grados de libertad	15
p-value	< 0,001

Se **rechaza** la hipótesis de homogeneidad de covarianzas ($p < 0,001$, criterio conservador). Esto sugiere que el QDA podría ser teóricamente más apropiado (ver Parte III). Sin embargo, el LDA es una técnica robusta que se aplica de todas formas como primera aproximación, teniendo en cuenta esta limitación al interpretar los resultados.

5 Ajuste del Modelo LDA

El dataset se dividió en **70 % entrenamiento** (12 814 obs.) y **30 % prueba** (5 492 obs.), de forma estratificada por grupo.

Listing 2: Ajuste del modelo LDA

```

1 from sklearn.discriminant_analysis import
   LinearDiscriminantAnalysis
2
3 lda = LinearDiscriminantAnalysis(solver='svd', store_covariance=
   True)
4 lda.fit(X_train, y_train)

```

5.1 Medias por grupo

Cuadro 7: Medias de los predictores por grupo

Grupo	edad_meses	peso_kg	talla_cm	talla_edad_z	peso_edad_z
Con_anemia	28.614	12.338	85.471	-1,015	-0,245
Sin_anemia	34.361	13.694	90.466	-0,822	-0,107

Los niños con anemia presentan, en promedio, menor edad, menor peso, menor talla y puntuaciones Z más negativas que los niños sin anemia.

5.2 Función discriminante

Cuadro 8: Coeficientes de la función discriminante lineal (LD1)

Predictor	Coeficiente
Intercepto	-5,78784
edad_meses	-0,02854
peso_kg	-0,07912
talla_cm	0,09545
talla_edad_z	-0,13469
peso_edad_z	0,13848

$$\begin{aligned}
 D = & -5,78784 - 0,02854 (\text{edad_meses}) - 0,07912 (\text{peso_kg}) + 0,09545 (\text{talla_cm}) \\
 & - 0,13469 (\text{talla_edad_z}) + 0,13848 (\text{peso_edad_z})
 \end{aligned}$$

5.3 Poder discriminante y significancia

Cuadro 9: Medidas de poder discriminante de la función LDA

Medida	Valor
Autovalor (λ_1)	0.0428
Correlación canónica	0.2026
Lambda de Wilks (Λ)	0.95894
Chi-cuadrado aproximado	537.065 (gl = 5)
p-value	< 0,001

A pesar de que el autovalor y la correlación canónica son bajos (la función discrimina poco en términos relativos), el Lambda de Wilks resulta **estadísticamente significativo** ($p < 0,001$): la función discriminante captura una diferencia real, aunque modesta, entre los grupos.

6 Evaluación del Modelo LDA

Cuadro 10: Matriz de confusión — LDA (conjunto de prueba, n=5 492)

Real / Predicho	Con _ anemia	Sin _ anemia
Con _ anemia	146	1 580
Sin _ anemia	140	3 626

Cuadro 11: Métricas de desempeño — LDA

Métrica	Valor
Accuracy (test)	68.68 %
Error de clasificación (test)	31.32 %
Precisión (Con _ anemia)	0.51
Recall (Con _ anemia)	0.08
F1-score (Con _ anemia)	0.15
Precisión (Sin _ anemia)	0.70
Recall (Sin _ anemia)	0.96
F1-score (Sin _ anemia)	0.81
AUC	0.6293
Validación cruzada 10-fold (accuracy)	68.58 % (± 0.23 %)




Figura 2: Matriz de confusión gráfica — LDA




Figura 3: Curva ROC — LDA (AUC = 0.6293)

El modelo LDA tiene un **recall muy bajo para la clase Con_anemia** (8 %): clasifica casi todos los casos como Sin_anemia, favorecido por el desbalance de clases (68.6 % vs 31.4 %) y por la baja separación lineal entre grupos. La accuracy global (68.68 %) es engañosa: un clasificador trivial que siempre prediga

"Sin_anemia alcanzaría 68.6 %.

7 Predicción de un Nuevo Caso

Se clasificó un caso hipotético: niño de 24 meses, 11.5 kg, 84 cm, Z talla/edad = $-1,2$, Z peso/edad = $-0,8$.

Cuadro 12: Predicción LDA para el nuevo caso

Resultado	Valor
Clase predicha	Sin_anemia
P(Con_anemia)	0.3349
P(Sin_anemia)	0.6651

Parte III

Análisis Discriminante Cuadrático (QDA)

8 Fundamento Teórico

El QDA relaja el supuesto más restrictivo del LDA: en lugar de asumir una única matriz de covarianzas compartida, estima una matriz Σ_k distinta para **cada** clase k . La función discriminante cuadrática resultante es:

$$\delta_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k) + \log(\pi_k),$$

y la observación se asigna a la clase que maximiza $\delta_k(x)$. Al permitir covarianzas distintas, las fronteras de decisión del QDA son **curvas**, lo que le otorga mayor flexibilidad a costa de estimar más parámetros (y, por tanto, requerir más datos por grupo para una estimación estable).

9 Homogeneidad de Covarianzas y Justificación del QDA

El mismo test M de Box aplicado en la Parte II ($\chi^2 = 2277,788$, gl= 15, $p < 0,001$) **rechaza** la hipótesis de covarianzas homogéneas, lo que constituye la justificación estadística directa para emplear QDA en este problema.




Figura 4: Matrices de correlación por grupo. El QDA estima una matriz de covarianzas distinta para cada clase; aquí se muestran las correlaciones correspondientes para inspección visual de las diferencias estructurales entre grupos.

10 Ajuste del Modelo QDA

Listing 3: Ajuste del modelo QDA

```
1 from sklearn.discriminant_analysis import
   QuadraticDiscriminantAnalysis
```

```

3 modelo_qda = QuadraticDiscriminantAnalysis(store_covariance=True
4         )
4 modelo_qda.fit(X_train, y_train)

```

10.1 Matrices de covarianza por grupo

A diferencia del LDA (una sola matriz combinada), el QDA estima una matriz de covarianzas independiente para cada grupo:

Cuadro 13: Matriz de covarianzas — grupo Con_anemia

	edad_meses	peso_kg	talla_cm	talla_edad_z	peso_edad_z
edad_meses	244.962	44.277	177.680	-0,773	-1,380
peso_kg	44.277	10.518	36.270	0.970	1.226
talla_cm	177.680	36.270	141.847	2.484	1.294
talla_edad_z	-0,773	0.970	2.484	1.026	0.773
peso_edad_z	-1,380	1.226	1.294	0.773	1.027

Cuadro 14: Matriz de covarianzas — grupo Sin_anemia

	edad_meses	peso_kg	talla_cm	talla_edad_z	peso_edad_z
edad_meses	230.730	43.483	163.240	0.549	-0,196
peso_kg	43.483	12.026	36.304	1.501	1.894
talla_cm	163.240	36.304	130.693	3.881	2.652
talla_edad_z	0.549	1.501	3.881	1.013	0.808
peso_edad_z	-0,196	1.894	2.652	0.808	1.105

Se observan diferencias notables, por ejemplo en la varianza de **peso_kg** (10.518 vs 12.026) y en la covarianza entre **talla_cm** y **talla_edad_z** (2.484 vs 3.881), consistentes con el rechazo del test de Box.

11 Evaluación del Modelo QDA

Cuadro 15: Matriz de confusión — QDA (conjunto de prueba, n=5 492)

Real / Predicho	Con_anemia	Sin_anemia
Con_anemia	517	1 209
Sin_anemia	588	3 178

Cuadro 16: Métricas de desempeño — QDA

Métrica	Valor
Accuracy (test)	67.28 %
Error de clasificación (test)	32.72 %
Precisión (Con_anemia)	0.47
Recall (Con_anemia)	0.30
F1-score (Con_anemia)	0.37
Precisión (Sin_anemia)	0.72
Recall (Sin_anemia)	0.84
F1-score (Sin_anemia)	0.78
AUC	0.6350
Validación cruzada 10-fold (accuracy)	67.17 % (± 0.73 %)




Figura 5: Matriz de confusión gráfica — QDA

A diferencia del LDA, el QDA logra un **recall considerablemente mayor para Con_anemia** (30 % vs 8 %) y un mejor F1-score (0.37 vs 0.15), aunque con una accuracy global ligeramente inferior (67.28 % vs 68.68 %). El QDA logra una clasificación **más equilibrada** entre ambas clases.

11.1 Regiones de decisión




Figura 6: Regiones de decisión del QDA para distintos pares de predictores. Nótese la naturaleza curva (no lineal) de las fronteras, característica distintiva del QDA frente al LDA.

12 Predicción de un Nuevo Caso

Para el mismo caso hipotético (niño de 24 meses, 11.5 kg, 84 cm, Z talla/edad = $-1,2$, Z peso/edad = $-0,8$):

Cuadro 17: Predicción QDA para el nuevo caso

Resultado	Valor
Clase predicha	Sin_anemia
P(Con_anemia)	0.406
P(Sin_anemia)	0.594

El QDA asigna una probabilidad de **Con_anemia** considerablemente más alta (40.6 %) que el LDA (33.5 %) para el mismo caso, aunque ambos modelos coinciden en la clase predicha final.

Comparación entre Modelos y Conclusiones

13 Resumen Comparativo

Cuadro 18: Comparación LDA vs QDA — conjunto de prueba (n=5 492)

Métrica	LDA	QDA
Accuracy (test)	68.68 %	67.28 %
Error de clasificación (test)	31.32 %	32.72 %
Recall Con_anemia	0.08	0.30
F1-score Con_anemia	0.15	0.37
AUC	0.6293	0.6350
Accuracy validación cruzada (10-fold)	68.58 %	67.17 %
Matriz de covarianzas	Única (compartida)	
Frontera de decisión	Lineal	Cuadrática (curva)




Figura 7: Comparación de curvas ROC: LDA vs QDA

Hallazgo principal: aunque el test M de Box rechaza fuertemente la homogeneidad de covarianzas ($p < 0,001$), lo que en teoría favorece al QDA, en la práctica ambos modelos obtienen un desempeño global **muy similar** (diferencia de accuracy $< 1,5$ puntos porcentuales). El QDA mejora el **equilibrio entre clases** (mejor recall y F1 para Con_anemia y mayor AUC), mientras que el LDA es ligeramente superior en accuracy global y más estable en validación cruzada.

14 Conclusiones Generales

Conclusiones — Anemia Infantil (LDA vs QDA)

1. **Ambos modelos son significativos pero con poder discriminante modesto:** el Lambda de Wilks del LDA fue significativo ($p < 0,001$), pero el autovalor (0.0428) y la correlación canónica (0.2026) indican que las variables antropométricas explican solo una fracción limitada de la variabilidad entre grupos. Esto es razonable: la anemia depende fuertemente del estado de hierro y hemoglobina, que se excluyeron deliberadamente como predictores.
2. **El supuesto de homogeneidad de covarianzas no se cumple:** el test M de Box rechazó fuertemente la igualdad de matrices de covarianza ($\chi^2 = 2277,788$, $p < 0,001$), lo que constituye la justificación teórica para preferir QDA sobre LDA en este problema.
3. **El QDA mejora el equilibrio entre clases:** con un recall de 30 % para Con_anemia (frente a 8 % del LDA) y un AUC levemente superior (0.6350 vs 0.6293), el QDA captura mejor los casos positivos, que son los de mayor interés en salud pública.
4. **El LDA es más estable y ligeramente más preciso en promedio:** la accuracy de validación cruzada del LDA (68.58 %, desviación 0.23 %) fue más consistente que la del QDA (67.17 %, desviación 0.73 %), reflejo de que el LDA estima menos parámetros y es menos sensible a la variabilidad muestral.
5. **Recomendación:** si el objetivo prioritario es identificar correctamente a los niños *con* anemia (minimizar falsos negativos, relevante en un contexto de tamizaje de salud pública), el **QDA es preferible**. Si el objetivo es una clasificación global estable con menor varianza, el **LDA** es la opción más robusta. En ambos casos, incorporar variables adicionales (socioeconómicas, dietéticas, geográficas) probablemente mejoraría sustancialmente el poder discriminante de los modelos.