



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

CLASIFICACIÓN K-VECINOS CERCANOS (K-NN) PARA LA DETECCIÓN DE ANEMIA INFANTIL

Curso: Aprendizaje Supervisado
Docente: Carpio Vargas Edgar Eloy
Estudiante: Luque Cornejo Zulema Yasmile
Dataset: *ENDES 2024 – Módulo RECH6* (18 306 registros válidos)
Variable objetivo: Estado de anemia infantil (Sin Anemia / Anemia)
Tecnologías: Python 3.10 · scikit-learn · pandas
Repositorio: [GitHub/KNN](#)
Fecha: 21 de julio de 2026

Índice

1. Introducción	2
2. Marco Teórico	2
2.1. K-Vecinos Cercanos (K-NN)	2
2.2. Selección del Hiperparámetro k	2
2.3. Métricas de Evaluación	3
3. Descripción del Dataset	3
3.1. Fuente y Filtrado	3
3.2. Estadísticas Descriptivas	4
3.3. Distribución de la Variable Objetivo	4
3.4. Correlación entre Variables	6
4. Preprocesamiento y Configuración del Modelo	6
4.1. División del Dataset	6
4.2. Escalado de Variables	7
4.3. Configuración de Búsqueda de Hiperparámetros	7
5. Resultados	7
5.1. Modelo Base ($k = 5$): Sin y Con Validación Cruzada	7
5.2. Matriz de Confusión ($k = 5$)	8
5.3. Búsqueda del Hiperparámetro k Óptimo	9
5.4. Modelo Final (GridSearchCV)	10
5.5. Comparación entre las Tres Variantes del Modelo	11
5.6. Predicción sobre Casos Hipotéticos	11
6. Conclusiones	12
6.1. Recomendaciones	13

1. Introducción

La anemia infantil es uno de los principales problemas de salud pública en el Perú, particularmente en zonas altoandinas como la región Puno. Su detección oportuna a partir de indicadores antropométricos —recolectados de forma rutinaria en encuestas nacionales como la Encuesta Demográfica y de Salud Familiar (ENDES)— puede orientar estrategias de tamizaje cuando la medición directa de hemoglobina no está disponible.

El presente informe documenta el diseño, implementación y evaluación de un modelo de clasificación supervisada basado en el algoritmo de **K-Vecinos Cercanos (K-NN)**, aplicado al módulo **RECH6** de la ENDES 2024, con el objetivo de clasificar a un niño como *Con Anemia* o *Sin Anemia* a partir de sus indicadores antropométricos estandarizados (puntuaciones Z de la OMS), excluyendo deliberadamente la hemoglobina medida como predictor.

2. Marco Teórico

2.1. K-Vecinos Cercanos (K-NN)

K-NN es un algoritmo de clasificación no paramétrico y basado en instancias: para clasificar una nueva observación $\mathbf{x}$, se identifican los k puntos del conjunto de entrenamiento más cercanos según una métrica de distancia, y se asigna la clase mayoritaria entre esos vecinos:

$$\hat{y}(\mathbf{x}) = \arg \max_c \sum_{i \in N_k(\mathbf{x})} \mathbb{I}(y_i = c) \quad (1)$$

donde $N_k(\mathbf{x})$ es el conjunto de los k vecinos más cercanos a $\mathbf{x}$. Las métricas de distancia evaluadas en la búsqueda de hiperparámetros fueron:

$$d_{\text{euclidiana}}(\mathbf{x}, \mathbf{x}') = \sqrt{\sum_j (x_j - x'_j)^2} \quad (2)$$

$$d_{\text{manhattan}}(\mathbf{x}, \mathbf{x}') = \sum_j |x_j - x'_j| \quad (3)$$

$$d_{\text{chebyshev}}(\mathbf{x}, \mathbf{x}') = \max_j |x_j - x'_j| \quad (4)$$

Dado que K-NN calcula distancias, es indispensable **escalar** las variables predictoras para que ninguna domine el cálculo por su magnitud natural.

2.2. Selección del Hiperparámetro k

El valor de k controla el equilibrio sesgo-varianza: valores pequeños generan fronteras de decisión muy flexibles (riesgo de sobreajuste), mientras que valores grandes suavizan la frontera (riesgo de subajuste). El valor óptimo se determinó mediante **validación cruzada de 5 y 10 pliegues (k -fold cross-validation)** y **búsqueda exhaustiva de hiperparámetros (GridSearchCV)**.

2.3. Métricas de Evaluación

Para un problema de clasificación binaria, con TP , TN , FP y FN los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (6)$$

$$\text{Recall (Sensibilidad)} = \frac{TP}{TP + FN} \quad (7)$$

$$\text{Especificidad} = \frac{TN}{TN + FP} \quad (8)$$

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \quad (9)$$

Adicionalmente se reporta el **AUC-ROC**, el área bajo la curva que relaciona la tasa de verdaderos positivos con la tasa de falsos positivos a distintos umbrales.

3. Descripción del Dataset

3.1. Fuente y Filtrado

El dataset proviene del módulo **RECH6** (Cuestionario Individual de Niños) de la ENDES 2024, con 20 290 registros originales. Se aplicó el siguiente filtrado según el diccionario de variables:

- HC55 = 0: la hemoglobina fue efectivamente medida en el niño.
- HC57A $\in \{1, 2, 3, 4\}$: nivel de anemia válido (Nueva Directriz OMS 2024).
- HC70, HC71, HC72, HC73 < 9000: se descartan los códigos de valores fuera de límites plausibles o casos marcados (9996–9999).

Tras el filtrado quedaron **18 306 niños** con información completa y válida.

Cuadro 1: Descripción de variables — Módulo RECH6 (ENDES 2024)

Variable	Descripción	Tipo
edad_meses	Edad del niño en meses (HC1, 0–59)	Numérica
talla_edad_z	Puntuación Z Talla/Edad, OMS (HC70/100)	Numérica
peso_edad_z	Puntuación Z Peso/Edad, OMS (HC71/100)	Numérica
peso_talla_z	Puntuación Z Peso/Talla, OMS (HC72/100)	Numérica
imc_z	Puntuación Z de IMC, OMS (HC73/100)	Numérica
target	Variable objetivo: 1 = Anemia (HC57A $\in \{1, 2, 3\}$), 0 = Sin Anemia (HC57A=4)	Binaria

Nota metodológica: la hemoglobina (HC53, HC55, HC56, HC56A, HC57) se excluyó deliberadamente de los predictores, ya que es la variable con la que se define directamente el **target**; incluirla generaría circularidad en el modelo.

3.2. Estadísticas Descriptivas

Cuadro 2: Estadísticas descriptivas de las variables del modelo

Variable	Media	Desv. Est.	Mín	Mediana	Máx
edad_meses	32.530	15.604	6.00	33.00	59.00
talla_edad_z	-0.878	1.013	-5.51	-0.88	3.54
peso_edad_z	-0.142	1.040	-4.54	-0.18	4.43
peso_talla_z	0.480	1.010	-4.74	0.44	4.92
imc_z	0.576	0.992	-4.87	0.54	4.97
target	0.314	0.464	0	0	1

3.3. Distribución de la Variable Objetivo

Cuadro 3: Distribución del estado de anemia

Diagnóstico	Frecuencia	Porcentaje (%)
Sin Anemia	12 552	68.57
Anemia	5 754	31.43




Figura 1: Distribución absoluta y porcentual de la variable objetivo




Figura 2: Distribución de las 5 variables predictoras según estado de anemia




Figura 3: Histogramas de las variables numéricas del modelo

3.4. Correlación entre Variables

Cuadro 4: Correlación absoluta de cada predictor con el target

Variable	Correlación $ r $
edad_meses	0.1735
talla_edad_z	0.0925
peso_edad_z	0.0627
peso_talla_z	0.0260
imc_z	0.0151




Figura 4: Matriz de correlación entre predictores y target

Ninguna variable presenta una correlación fuerte de forma individual; `edad_meses` es la más asociada al target, seguida de `talla_edad_z`, lo que anticipa un poder predictivo moderado del modelo.

4. Preprocesamiento y Configuración del Modelo

4.1. División del Dataset

$$\underbrace{75\%}_{\text{Entrenamiento}} + \underbrace{25\%}_{\text{Prueba}} = 100\% \implies 13\,729 + 4\,577 = 18\,306 \text{ niños} \quad (10)$$

La división se realizó de forma **estratificada** respecto al target, preservando la proporción de 31.4 % de casos con anemia en ambos subconjuntos, con `random_state=123`.

4.2. Escalado de Variables

Se aplicó **MinMaxScaler**, ajustado únicamente sobre el conjunto de entrenamiento:

$$x' = \frac{x - x_{\text{mín,train}}}{x_{\text{máx,train}} - x_{\text{mín,train}}} \quad (11)$$

4.3. Configuración de Búsqueda de Hiperparámetros

Cuadro 5: Rejilla de búsqueda — `GridSearchCV` (`cv = 10`)

Hiperparámetro	Valores evaluados
<code>n_neighbors</code>	1 a 30
<code>metric</code>	euclidean, manhattan, chebyshev
<code>weights</code>	uniform, distance

5. Resultados

5.1. Modelo Base ($k = 5$): Sin y Con Validación Cruzada

Cuadro 6: Precisión del modelo base K-NN ($k = 5$)

Métrica	Valor
Precisión en entrenamiento (sin CV)	0.7455
Precisión en prueba (sin CV)	0.6528
Media de precisión (CV, 10 pliegues)	0.6387
Desviación estándar (CV)	0.0133
Intervalo 95 % (CV)	[0.6122, 0.6653]

Los 10 *folds* de validación cruzada obtuvieron: 0.6286, 0.6235, 0.6315, 0.6570, 0.6431, 0.6489, 0.6315, 0.6431, 0.6606 y 0.6195.




Figura 5: Precisión por pliegue en la validación cruzada ($k = 5$, $cv = 10$)

5.2. Matriz de Confusión ($k = 5$)

Cuadro 7: Matriz de confusión — modelo base ($k = 5$, conjunto de prueba, $n = 4\,577$)

	Predicho: Sin Anemia	Predicho: Anemia
Real: Sin Anemia	2 610 (TN)	528 (FP)
Real: Anemia	1 061 (FN)	378 (TP)




Figura 6: Matriz de confusión — valores absolutos y normalizados ($k = 5$)

Métrica	Valor
Accuracy (exactitud)	0.6528
Precisión	0.4172
Recall (sensibilidad)	0.2627
Especificidad	0.8317
F1-Score	0.3224
Falsa tasa de alarma	0.1683
Tasa de error	0.3472

Interpretación: con $k = 5$ el modelo identifica correctamente solo el **26.3 %** de los niños con anemia (*recall* bajo), aunque acierta el 83.2 % de los casos sin anemia (especificidad alta). La diferencia entre entrenamiento (0.7455) y prueba (0.6528) de **9.27 puntos** sugiere cierto sobreajuste.

5.3. Búsqueda del Hiperparámetro k Óptimo

Cuadro 8: Mejor k según criterio de selección

Criterio	k óptimo	Accuracy
Conjunto de prueba	24	0.6902
Validación cruzada (5-fold)	30	0.6813




Figura 7: Precisión de entrenamiento, prueba y validación cruzada en función de k

5.4. Modelo Final (GridSearchCV)

Hiperparámetro	Valor óptimo
n_neighbors	30
metric	chebyshev
weights	uniform
Mejor score en CV (10-fold)	0.6814

Cuadro 9: Precisión por clase — modelo final

Clase	Precisión	Recall	F1-Score	Soporte
Sin Anemia	0.7012	0.9436	0.8045	3 138
Anemia	0.5000	0.1230	0.1974	1 439




Figura 8: Precisión, recall y F1-score por clase — modelo final

Métrica	Valor
Accuracy final	0.6856 (68.56 %)
Mejora vs. k=5 inicial	+3.28 puntos porcentuales
AUC-ROC	0.6238
Precisión	0.5000
Recall (sensibilidad)	0.1230
F1-Score	0.1974

Interpretación: el ajuste de hiperparámetros mejoró el *accuracy* global en 3.28 puntos porcentuales (65.28 % → 68.56 %), principalmente a costa del *recall* de la clase Anemia, que **cae** de 0.2627 (k=5) a 0.1230 (k=30). El modelo final favorece la especificidad (detecta muy bien a los niños sin anemia, recall = 0.9436) mientras sacrifica sensibilidad ante los casos positivos.



Figura 9: Resumen visual del modelo final: curva ROC, selección de k, métricas, matriz de confusión, dispersión de aciertos/errores y comparación de modelos

5.5. Comparación entre las Tres Variantes del Modelo

Cuadro 10: Comparación de accuracy entre variantes del modelo K-NN

Variante	Accuracy
KNN $k = 5$ (sin CV)	0.6528
KNN $k = 5$ (con CV, media)	0.6387
KNN $k = 30$ (GridSearchCV, final)	0.6856

5.6. Predicción sobre Casos Hipotéticos

Se evaluó el modelo final sobre tres perfiles antropométricos hipotéticos:

Cuadro 11: Predicciones sobre perfiles de ejemplo

Perfil	Edad (m)	Talla/Edad Z	Diagnóstico	P(Anemia)	Confianza
Niño 1 (desnutrición marcada)	12	−2.5	Sin Anemia	0.4667	53.3 %
Niño 2 (indicadores normales)	36	0.2	Sin Anemia	0.2333	76.7 %
Niño 3 (caso intermedio)	24	−1.0	Sin Anemia	0.3000	70.0 %




Figura 10: Probabilidades de clasificación por perfil hipotético

Con el umbral estándar de 0.5, los tres perfiles se clasifican como *Sin Anemia*, aunque el Niño 1 (con mayor desnutrición crónica) obtiene la probabilidad de anemia más alta de los tres (46.67%), consistente con la asociación esperada entre déficit de talla y riesgo de anemia.

6. Conclusiones

- Capacidad predictiva moderada.** Usando exclusivamente 5 indicadores antropométricos (edad y 4 puntuaciones Z de la OMS), sin recurrir a la hemoglobina, el modelo final alcanzó un *accuracy* de **68.56 %** y un AUC-ROC de **0.6238**, apenas por encima del azar informado ($AUC = 0.5$).
- Compromiso sensibilidad-especificidad.** El modelo optimizado por GridSearchCV favorece fuertemente la clase mayoritaria (Sin Anemia, *recall* = 0.9436) a costa de un *recall* muy bajo para Anemia (0.1230). Para un caso de uso de tamizaje clínico, este comportamiento sería poco útil, ya que el objetivo prioritario suele ser **no dejar de detectar** casos positivos.
- La distancia chebyshev y k elevado dominan la búsqueda.** El mejor modelo encontrado usa $k = 30$ vecinos con métrica *chebyshev* y ponderación uniforme, lo que produce fronteras de decisión muy suavizadas —coherente con el bajo poder discriminante individual de cada predictor (correlaciones máximas de 0.17 con el target).

4. **Variables antropométricas insuficientes por sí solas.** Ninguna de las 5 variables mostró una correlación fuerte con el estado de anemia (`edad_meses`: $|r| = 0,17$ como máximo). Esto sugiere que la anemia infantil en este dataset está determinada por factores adicionales no capturados aquí —dieta, factores socioeconómicos, altitud, suplementación con hierro—, lo cual es consistente con la literatura epidemiológica sobre anemia en la niñez.
5. **Prevención de *data leakage* y circularidad.** El escalado (`MinMaxScaler`) se ajustó exclusivamente sobre el conjunto de entrenamiento, y la hemoglobina se excluyó de los predictores por definir directamente al target, garantizando la validez metodológica de la evaluación.

6.1. Recomendaciones

Se recomienda comparar este modelo K-NN con los demás clasificadores de la serie (LDA, QDA, regresión logística) sobre el mismo conjunto de predictores, e incorporar variables adicionales del cuestionario del hogar (acceso a agua, saneamiento, nivel educativo materno) que podrían mejorar sustancialmente la capacidad discriminativa, especialmente el *recall* de la clase Anemia.