



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

CLASIFICACIÓN NAIVE BAYES GAUSSIANO PARA LA DETECCIÓN DE ANEMIA INFANTIL

Curso: Aprendizaje Supervisado
Docente: Carpio Vargas Edgar Eloy
Estudiante: Luque Cornejo Zulema Yasmile
Dataset: *ENDES 2024 – Módulo RECH6* (17 798 registros válidos)
Variable objetivo: Nivel de anemia infantil (Sin_Anemia / Con_Anemia)
Tecnologías: Python 3.10 · scikit-learn · pandas · NumPy
Repositorio: [GitHub/NAIVEBAYES](#)
Fecha: 23 de julio de 2026

Informe académico basado en un modelo de clasificación supervisada Gaussian Naive Bayes,
implementado desde cero y verificado contra `scikit-learn`.

Índice

1. Introducción	2
2. Marco Teórico	2
2.1. Teorema de Bayes y el Supuesto Naive	2
2.2. Verosimilitud Gaussiana	2
2.3. Métricas de Evaluación	3
3. Descripción del Dataset	3
3.1. Fuente y Filtrado	3
3.2. Estadísticas Descriptivas	4
3.3. Distribución de la Variable Objetivo	4
3.4. Variables Categóricas	5
3.5. Correlación y Distribución de Predictores	6
4. Preprocesamiento y Configuración del Modelo	7
4.1. Codificación de Variables Categóricas	7
4.2. División del Dataset	8
4.3. Escalado de Variables	8
4.4. Implementación del Modelo	8
5. Resultados	8
5.1. Probabilidades a Priori	8
5.2. Accuracy: Manual vs. <code>sklearn</code>	9
5.3. Matriz de Confusión	9
5.4. Métricas por Clase	10
5.5. Predicción sobre Casos Hipotéticos	11
6. Conclusiones	11
6.1. Recomendaciones	12

1. Introducción

La anemia infantil es uno de los principales problemas de salud pública en el Perú, particularmente en zonas altoandinas como la región Puno. Su detección oportuna a partir de indicadores antropométricos y sociodemográficos —recolectados de forma rutinaria en encuestas nacionales como la Encuesta Demográfica y de Salud Familiar (ENDES)— puede orientar estrategias de tamizaje cuando la medición directa de hemoglobina no está disponible.

El presente informe documenta el diseño, implementación y evaluación de un modelo de clasificación supervisada basado en el algoritmo **Gaussian Naive Bayes (GNB)**, aplicado al módulo **RECH6** de la ENDES 2024, con el objetivo de clasificar a un niño como *Con Anemia* o *Sin Anemia* a partir de variables antropométricas y socio-demográficas, excluyendo deliberadamente la hemoglobina medida como predictor. El modelo se implementó **desde cero** (sin usar `def` fuera de la clase) y se validó contra la implementación de referencia `GaussianNB` de `scikit-learn`.

2. Marco Teórico

2.1. Teorema de Bayes y el Supuesto Naive

El clasificador Naive Bayes se basa en el teorema de Bayes para estimar la probabilidad posterior de cada clase c dado un vector de predictores $\mathbf{x} = (x_1, \dots, x_p)$:

$$P(y = c \mid \mathbf{x}) = \frac{P(\mathbf{x} \mid y = c) P(y = c)}{P(\mathbf{x})} \quad (1)$$

El supuesto *naive* (ingenuo) asume **independencia condicional** entre los predictores dado el valor de la clase, de modo que la verosimilitud conjunta se descompone en un producto de verosimilitudes univariadas:

$$P(\mathbf{x} \mid y = c) = \prod_{j=1}^p P(x_j \mid y = c) \quad (2)$$

La clase predicha es la que maximiza el posterior (equivalentemente, el producto del prior por la verosimilitud, ya que $P(\mathbf{x})$ es constante entre clases):

$$\hat{y}(\mathbf{x}) = \arg \max_c P(y = c) \prod_{j=1}^p P(x_j \mid y = c) \quad (3)$$

2.2. Verosimilitud Gaussiana

Para predictores continuos, **Gaussian Naive Bayes** modela la verosimilitud de cada variable, dentro de cada clase, como una distribución normal univariada:

$$P(x_j | y = c) = \frac{1}{\sqrt{2\pi\sigma_{c,j}^2}} \exp\left(-\frac{(x_j - \mu_{c,j})^2}{2\sigma_{c,j}^2}\right) \quad (4)$$

donde $\mu_{c,j}$ y $\sigma_{c,j}^2$ son la media y la varianza del predictor j estimadas únicamente con las observaciones de entrenamiento pertenecientes a la clase c . Por estabilidad numérica, la implementación trabaja en el dominio logarítmico:

$$\log P(y = c | \mathbf{x}) \propto \log P(y = c) + \sum_{j=1}^p \left[-\frac{1}{2} \log(2\pi\sigma_{c,j}^2) - \frac{(x_j - \mu_{c,j})^2}{2\sigma_{c,j}^2} \right] \quad (5)$$

y normaliza mediante la técnica *log-sum-exp* para obtener probabilidades posteriores válidas. Se añade un término de suavizado $\epsilon = 10^{-9}$ a cada varianza para evitar divisiones por cero.

2.3. Métricas de Evaluación

Para un problema de clasificación binaria, con TP , TN , FP y FN los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (6)$$

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (7)$$

$$\text{Recall (Sensibilidad)} = \frac{TP}{TP + FN} \quad (8)$$

$$\text{Especificidad} = \frac{TN}{TN + FP} \quad (9)$$

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \quad (10)$$

3. Descripción del Dataset

3.1. Fuente y Filtrado

El dataset proviene del módulo **RECH6** (Cuestionario Individual de Niños) de la ENDES 2024, con 20 290 registros originales y 43 columnas. Se aplicó el siguiente filtrado:

- $HC57A \in \{1, 2, 3, 4\}$: nivel de anemia efectivamente medido (Nueva Directriz OMS 2024), lo que redujo el dataset a 18 358 casos.
- $HC2, HC3, HC70, HC71, HC72, HC73 < 9000$: se descartan los códigos de peso, talla y puntuaciones Z fuera de límites plausibles o marcados.
- $HC61 \in \{0, 1, 2, 3\}$: nivel educativo de la madre con código válido.

Tras el filtrado quedaron **17 798 niños** con información completa y válida.

Cuadro 1: Descripción de variables del modelo — Módulo RECH6 (ENDES 2024)

Variable	Descripción	Tipo
Edad_meses	Edad del niño en meses (HC1, 6–59)	Numérica
Peso_kg	Peso corporal en kg (HC2/10)	Numérica
Talla_cm	Talla corporal en cm (HC3/10)	Numérica
TallaEdad_DE	Puntuación Z Talla/Edad, OMS (HC70/10)	Numérica
PesoEdad_DE	Puntuación Z Peso/Edad, OMS (HC71/10)	Numérica
PesoTalla_DE	Puntuación Z Peso/Talla, OMS (HC72/10)	Numérica
IMC_DE	Puntuación Z de IMC, OMS (HC73/10)	Numérica
Sexo	Sexo del niño (HC27: Hombre / Mujer)	Categórica
EducMadre	Nivel educativo de la madre (HC61)	Categórica
NivelAnemia	Variable objetivo: Con_Anemia (HC57A∈ {1, 2, 3}) / Sin_Anemia (HC57A=4)	Binaria

Nota metodológica: la hemoglobina (HC56A y variables relacionadas) se excluyó de los predictores por definir directamente al target; se conserva únicamente como referencia visual (Figura 2), no como *feature* del modelo.

3.2. Estadísticas Descriptivas

Cuadro 2: Estadísticas descriptivas de las variables numéricas

Variable	Media	Desv. Est.	Mín	Mediana	Máx
Edad_meses	32.294	15.621	6.00	32.00	59.00
Peso_kg	13.230	3.460	4.90	13.00	31.90
Talla_cm	88.718	11.844	55.20	89.60	119.00
TallaEdad_DE	−8.773	10.133	−55.10	−8.80	35.40
PesoEdad_DE	−1.413	10.406	−45.40	−1.80	44.30
PesoTalla_DE	4.804	10.113	−47.40	4.40	49.20
IMC_DE	5.763	9.936	−48.70	5.40	49.70

3.3. Distribución de la Variable Objetivo

Cuadro 3: Distribución del nivel de anemia

Diagnóstico	Frecuencia	Porcentaje (%)
Sin_Anemia	12 189	68.49
Con_Anemia	5 609	31.51




Figura 1: Distribución absoluta de la variable objetivo NivelAnemia




Figura 2: Hemoglobina ajustada por NivelAnemia (uso referencial, no es predictor del modelo)

3.4. Variables Categóricas

Cuadro 4: Distribución de las variables categóricas

Variable	Categoría	Frecuencia
Sexo	Hombre	9 035
	Mujer	8 763
EducMadre	Secundaria	12 144
	Superior	2 783
	Primaria	2 693
	Sin_educacion	178




Figura 3: Variables categóricas (Sexo, EducMadre) según NivelAnemia

3.5. Correlación y Distribución de Predictores




Figura 4: Heatmap de correlaciones entre las variables numéricas y el target




Figura 5: Distribución de Edad_meses, TallaEdad_DE e IMC_DE según NivelAnemia




Figura 6: Distribución de la edad (meses) por NivelAnemia

Como en la serie de modelos previos aplicados a este dataset, ninguna variable antropométrica muestra una asociación fuerte de forma individual con el target, lo que anticipa un poder predictivo moderado del modelo.

4. Preprocesamiento y Configuración del Modelo

4.1. Codificación de Variables Categóricas

Las variables **Sexo** y **EducMadre** se transformaron mediante **One-Hot Encoding** (`drop_first=False`), generando 6 columnas dummy: **Sexo_Hombre**, **Sexo_Mujer**, **EducMadre Primaria**, **EducMadre Secundaria**, **EducMadre Sin educacion** y **EducMadre Superior**. Combinadas con las 7 variables numéricas, el modelo utiliza **13 predictores** en total.

4.2. División del Dataset

$$\underbrace{80\%}_{\text{Entrenamiento}} + \underbrace{20\%}_{\text{Prueba}} = 100\% \implies 14\,238 + 3\,560 = 17\,798 \text{ niños} \quad (11)$$

La división se realizó de forma **estratificada** respecto al target (`NivelAnemia`), con `random_state=42`, preservando proporciones similares de anemia en ambos subconjuntos.

Cuadro 5: Distribución del target en entrenamiento y prueba

Clase	Entrenamiento (n=14 238)	Prueba (n=3 560)
Sin _Anemia	9 751	2 438
Con _Anemia	4 487	1 122

4.3. Escalado de Variables

Se aplicó **StandardScaler** únicamente sobre las 7 columnas numéricas, ajustado solo con el conjunto de entrenamiento:

$$x' = \frac{x - \bar{x}_{\text{train}}}{s_{\text{train}}} \quad (12)$$

Las columnas dummy generadas por el One-Hot Encoding no se escalan.

4.4. Implementación del Modelo

Se entrenaron y compararon dos versiones del clasificador Gaussian Naive Bayes:

- **Manual:** clase `GaussianNaiveBayes` implementada desde cero, calculando *priors*, medias y varianzas por clase, y prediciendo mediante log-verosimilitud (Ecuación 5) con suavizado $\epsilon = 10^{-9}$.
- **Referencia:** `sklearn.naive_bayes.GaussianNB`, usada para verificar la correctitud de la implementación manual.

5. Resultados

5.1. Probabilidades a Priori

Cuadro 6: Probabilidades a priori estimadas por clase (entrenamiento)

Clase	Log-prior	Prior
Con _Anemia	-1.1547	0.3151
Sin _Anemia	-0.3785	0.6849

5.2. Accuracy: Manual vs. sklearn

Cuadro 7: Precisión (accuracy) del modelo Gaussian Naive Bayes

Implementación	Entrenamiento	Prueba
Manual (desde cero)	0.6589	0.6517
sklearn GaussianNB	0.6589	0.6517




Figura 7: Comparación de accuracy: implementación manual vs. sklearn

Las predicciones de la implementación manual coinciden **exactamente** con las de **sklearn** en el conjunto de prueba: **3 560/3 560 (100.0 %)**, con una diferencia de accuracy de 0.000000. Esto valida la correctitud matemática de la implementación desde cero.

5.3. Matriz de Confusión

Cuadro 8: Matriz de confusión — conjunto de prueba ($n = 3\,560$), ambas implementaciones

	Predicho: Con _Anemia	Predicho: Sin _Anemia
Real: Con _Anemia	396 (TP)	726 (FN)
Real: Sin _Anemia	514 (FP)	1 924 (TN)




Figura 8: Matrices de confusión — modelo manual vs. `sklearn` (idénticas)

5.4. Métricas por Clase

Cuadro 9: Precisión, recall y F1-score por clase — conjunto de prueba

Clase	Precisión	Recall	F1-Score	Soporte
Con_Anemia	0.44	0.35	0.39	1 122
Sin_Anemia	0.73	0.79	0.76	2 438
Macro avg	0.58	0.57	0.57	3 560
Weighted avg	0.63	0.65	0.64	3 560

Métrica	Valor
Accuracy final	0.6517 (65.17 %)
Precisión (Con_Anemia)	0.4352
Recall (Con_Anemia)	0.3529
Especificidad	0.7892
F1-Score (Con_Anemia)	0.3898
Falsa tasa de alarma	0.2108
Tasa de error	0.3483

Interpretación: el modelo identifica correctamente el **35.3%** de los niños con anemia (*recall* moderado-bajo), mientras acierta el 78.9% de los casos sin anemia (especificidad alta). La cercanía entre el accuracy de entrenamiento (0.6589) y de prueba (0.6517) —diferencia de apenas 0.72 puntos— indica que el modelo **no sobreajusta**, algo esperable dado que Naive Bayes es un modelo de baja varianza.

5.5. Predicción sobre Casos Hipotéticos

Se evaluó el modelo manual sobre cuatro perfiles antropométricos y sociodemográficos hipotéticos, sin usar hemoglobina:

Cuadro 10: Predicciones sobre perfiles de ejemplo (modelo manual)

Perfil	Edad (m)	Diagnóstico	P(Con_Anemia)	P(Sin_Anemia)
Niño 1	6	Con_Anemia	0.7928	0.2072
Niño 2	18	Con_Anemia	0.6847	0.3153
Niño 3	36	Sin_Anemia	0.0488	0.9512
Niño 4	50	Con_Anemia	1.0000	0.0000

Las predicciones de la implementación manual coinciden exactamente con las de `sklearn` para los cuatro perfiles. Los Niños 1 y 2 (edades tempranas, puntuaciones Z de talla/-peso más negativas) fueron clasificados con `Con_Anemia` y alta confianza (79.3 % y 68.5 % respectivamente), mientras que el Niño 3 (indicadores cercanos a la media) fue clasificado como `Sin_Anemia` con 95.1 % de confianza — consistente con la asociación esperada entre déficit nutricional temprano y mayor riesgo de anemia.

6. Conclusiones

- Capacidad predictiva moderada.** Usando 7 indicadores antropométricos y 2 variables sociodemográficas (sexo y educación materna), sin recurrir a la hemoglobina, el modelo Gaussian Naive Bayes alcanzó un *accuracy* de **65.17 %** en el conjunto de prueba, con un desempeño similar al de otros clasificadores de la serie aplicados al mismo dataset.
- Implementación manual verificada.** La clase `GaussianNaiveBayes` construida desde cero reprodujo **exactamente** (3 560/3 560 predicciones, diferencia de *accuracy* = 0) los resultados de `sklearn.GaussianNB`, validando tanto el cálculo de *priors* y verosimilitudes gaussianas como la normalización *log-sum-exp* empleada para la estabilidad numérica.
- Ausencia de sobreajuste.** La diferencia entre *accuracy* de entrenamiento (0.6589) y de prueba (0.6517) es de apenas 0.72 puntos porcentuales, coherente con la naturaleza de baja varianza de Naive Bayes frente a modelos más flexibles como K-NN.
- Compromiso sensibilidad-especificidad.** El modelo favorece la especificidad (79 % de los niños sin anemia bien clasificados) frente a un *recall* moderado para la clase `Con_Anemia` (35 %). Para un caso de uso de tamizaje clínico, donde suele priorizarse no dejar de detectar casos positivos, este balance podría ajustarse modificando el umbral de decisión o los pesos de clase.
- Supuesto de independencia condicional.** El desempeño moderado es consistente con el hecho de que las puntuaciones Z antropométricas (talla/edad, peso/edad, peso/talla, IMC) están naturalmente correlacionadas entre sí, lo cual viola parcialmente el supuesto *naive* de independencia condicional del modelo y puede limitar

su capacidad discriminativa frente a métodos que sí modelan la covarianza entre predictores (p. ej. LDA/QDA).

6. **Prevención de *data leakage* y circularidad.** El escalado (StandardScaler) se ajustó exclusivamente sobre el conjunto de entrenamiento, y la hemoglobina se excluyó de los predictores por definir directamente al target, garantizando la validez metodológica de la evaluación.

6.1. Recomendaciones

Se recomienda comparar este modelo Naive Bayes con los demás clasificadores de la serie (K-NN, LDA, QDA, regresión logística) sobre un conjunto de predictores común, así como explorar variantes que relajen el supuesto de independencia (p. ej. LDA/QDA, que sí modelan la covarianza entre las puntuaciones Z), e incorporar variables adicionales del cuestionario del hogar (acceso a agua, saneamiento, altitud) que podrían mejorar la capacidad discriminativa, especialmente el *recall* de la clase Con_Anemia.