



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

CLASIFICACIÓN RANDOM FOREST PARA LA DETECCIÓN DE ANEMIA INFANTIL

Curso: Aprendizaje Supervisado
Docente: Carpio Vargas Edgar Eloy
Estudiante: [Nombre del estudiante]
Dataset: *ENDES 2024 – Módulo RECH6* (17 798 registros válidos)
Variable objetivo: Nivel de anemia infantil (Sin_Anemia / Con_Anemia)
Tecnologías: Python 3.10 · scikit-learn · pandas · NumPy
Repositorio: [GitHub/RANDOMFOREST](#)
Fecha: 24 de julio de 2026

Informe académico basado en un modelo de clasificación supervisada Random Forest, optimizado mediante GridSearchCV y evaluado frente a un modelo base con hiperparámetros por defecto.

Índice

1. Introducción	2
2. Marco Teórico	2
2.1. Árboles de Decisión como Base del Ensamble	2
2.2. Bagging y Aleatorización de Variables	2
2.3. Importancia de Variables por Permutación	3
2.4. Métricas de Evaluación	3
3. Descripción del Dataset	3
3.1. Fuente y Filtrado	3
3.2. Estadísticas Descriptivas	4
3.3. Distribución de la Variable Objetivo	5
3.4. Variables Categóricas	6
3.5. Correlación y Distribución de Predictores	7
4. Preprocesamiento y Configuración del Modelo	8
4.1. Codificación de Variables Categóricas	8
4.2. División del Dataset	9
4.3. Escalado de Variables	9
4.4. Implementación del Modelo	9
5. Resultados	10
5.1. Accuracy: Modelo Base vs. Modelo Optimizado	10
5.2. Matriz de Confusión	11
5.3. Métricas por Clase	11
5.4. Importancia de Variables	12
5.5. Predicción sobre Casos Hipotéticos	13
6. Conclusiones	13
6.1. Recomendaciones	14

1. Introducción

La anemia infantil es uno de los principales problemas de salud pública en el Perú, particularmente en zonas altoandinas como la región Puno. Su detección oportuna a partir de indicadores antropométricos y sociodemográficos —recolectados de forma rutinaria en encuestas nacionales como la Encuesta Demográfica y de Salud Familiar (ENDES)— puede orientar estrategias de tamizaje cuando la medición directa de hemoglobina no está disponible.

El presente informe documenta el diseño, implementación y evaluación de un modelo de clasificación supervisada basado en el algoritmo **Random Forest (RF)**, aplicado al módulo **RECH6** de la ENDES 2024, con el objetivo de clasificar a un niño como *Con Anemia* o *Sin Anemia* a partir de variables antropométricas y sociodemográficas, excluyendo deliberadamente la hemoglobina medida como predictor. Se entrenó un modelo base con hiperparámetros por defecto y un modelo optimizado mediante **GridSearchCV** con validación cruzada estratificada de 5 particiones, comparando ambos en accuracy, sensibilidad y capacidad de generalización.

2. Marco Teórico

2.1. Árboles de Decisión como Base del Ensamble

Un árbol de decisión particiona recursivamente el espacio de predictores mediante reglas binarias del tipo $x_j \leq t$, buscando en cada nodo la partición que minimiza la impureza de los subconjuntos resultantes. Para clasificación, la impureza de Gini de un nodo con proporciones de clase p_c se define como:

$$G = 1 - \sum_{c=1}^C p_c^2 \quad (1)$$

Un árbol individual, entrenado sin restricciones, tiende a memorizar el conjunto de entrenamiento (varianza alta), lo que motiva el uso de métodos de ensamble.

2.2. Bagging y Aleatorización de Variables

Random Forest construye B árboles de decisión, cada uno entrenado sobre una muestra *bootstrap* (con reemplazo) del conjunto de entrenamiento (*bagging*), y en cada partición de cada árbol solo se evalúa un subconjunto aleatorio de $m \approx \sqrt{p}$ variables (de un total de p predictores). Esta doble aleatorización —de observaciones y de variables— decorrelaciona los árboles individuales y reduce la varianza del ensamble sin aumentar sustancialmente su sesgo.

La predicción final para clasificación se obtiene por **voto mayoritario** (o promedio de probabilidades) entre los B árboles:

$$\hat{y}(\mathbf{x}) = \arg \max_c \frac{1}{B} \sum_{b=1}^B \mathbb{I}[h_b(\mathbf{x}) = c] \quad (2)$$

donde $h_b(\mathbf{x})$ es la predicción del b -ésimo árbol. Al promediar sobre B árboles poco correlacionados, la varianza del estimador se reduce aproximadamente en un factor $1/B$ respecto a un único árbol, mientras la profundidad de cada árbol permite capturar interacciones no lineales entre predictores.

2.3. Importancia de Variables por Permutación

A diferencia de la importancia basada en la disminución media de impureza (Gini), que favorece variables de alta cardinalidad, la **importancia por permutación** mide la caída real del desempeño del modelo (aquí, ROC-AUC) al permutar aleatoriamente los valores de una variable en el conjunto de prueba, manteniendo el resto sin cambios. Una caída grande indica que el modelo depende fuertemente de esa variable para discriminar entre clases.

2.4. Métricas de Evaluación

Para un problema de clasificación binaria, con TP , TN , FP y FN los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3)$$

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (4)$$

$$\text{Recall (Sensibilidad)} = \frac{TP}{TP + FN} \quad (5)$$

$$\text{Especificidad} = \frac{TN}{TN + FP} \quad (6)$$

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \quad (7)$$

3. Descripción del Dataset

3.1. Fuente y Filtrado

El dataset proviene del módulo **RECH6** (Cuestionario Individual de Niños) de la ENDES 2024, con 20 290 registros originales y 43 columnas. Se aplicó el siguiente filtrado:

- $HC57A \in \{1, 2, 3, 4\}$: nivel de anemia efectivamente medido (Nueva Directriz OMS 2024), lo que redujo el dataset a 18 358 casos.

- HC2, HC3, HC70, HC71, HC72, HC73 < 9000: se descartan los códigos de peso, talla y puntuaciones Z fuera de límites plausibles o marcados.
- HC61 $\in \{0, 1, 2, 3\}$: nivel educativo de la madre con código válido.

Tras el filtrado quedaron **17 798 niños** con información completa y válida.

Cuadro 1: Descripción de variables del modelo — Módulo RECH6 (ENDES 2024)

Variable	Descripción	Tipo
Edad_meses	Edad del niño en meses (HC1, 6–59)	Numérica
Peso_kg	Peso corporal en kg (HC2/10)	Numérica
Talla_cm	Talla corporal en cm (HC3/10)	Numérica
TallaEdad_DE	Puntuación Z Talla/Edad, OMS (HC70/100)	Numérica
PesoEdad_DE	Puntuación Z Peso/Edad, OMS (HC71/100)	Numérica
PesoTalla_DE	Puntuación Z Peso/Talla, OMS (HC72/100)	Numérica
IMC_DE	Puntuación Z de IMC, OMS (HC73/100)	Numérica
Sexo	Sexo del niño (HC27: Hombre / Mujer)	Catégorica
EducMadre	Nivel educativo de la madre (HC61)	Catégorica
NivelAnemia	Variable objetivo: Con_Anemia (HC57A $\in \{1, 2, 3\}$) / Sin_Anemia (HC57A=4)	Binaria

Nota metodológica: la hemoglobina (HC56A y variables relacionadas) se excluyó de los predictores por definir directamente al target; se conserva únicamente como referencia visual (Figura 2), no como *feature* del modelo.

3.2. Estadísticas Descriptivas

Cuadro 2: Estadísticas descriptivas de las variables numéricas

Variable	Media	Desv. Est.	Mín	Mediana	Máx
Edad_meses	32.294	15.621	6.00	32.00	59.00
Peso_kg	13.230	3.460	4.90	13.00	31.90
Talla_cm	88.718	11.844	55.20	89.60	119.00
TallaEdad_DE	−0.877	1.013	−5.51	−0.88	3.54
PesoEdad_DE	−0.141	1.041	−4.54	−0.18	4.43
PesoTalla_DE	0.480	1.011	−4.74	0.44	4.92
IMC_DE	0.576	0.994	−4.87	0.54	4.97

El valor promedio de TallaEdad_DE (−0,877) es consistente con el patrón de desnutrición crónica (retardo en talla) reportado para la niñez altoandina, mientras que PesoTalla_DE e IMC_DE muestran valores promedio positivos, sin indicios de desnutrición aguda generalizada en la muestra.

3.3. Distribución de la Variable Objetivo

Cuadro 3: Distribución del nivel de anemia

Diagnóstico	Frecuencia	Porcentaje (%)
Sin_Anemia	12 189	68.49
Con_Anemia	5 609	31.51




Figura 1: Distribución absoluta de la variable objetivo NivelAnemia




Figura 2: Hemoglobina ajustada por NivelAnemia (uso referencial, no es predictor del modelo)

3.4. Variables Categóricas

Cuadro 4: Distribución de las variables categóricas

Variable	Categoría	Frecuencia
Sexo	Hombre	9 035
	Mujer	8 763
EducMadre	Secundaria	12 144
	Superior	2 783
	Primaria	2 693
	Sin_educacion	178




Figura 3: Variables categóricas (Sexo, EducMadre) según NivelAnemia

3.5. Correlación y Distribución de Predictores




Figura 4: Heatmap de correlaciones entre las variables numéricas y el target




Figura 5: Distribución de Edad_meses, TallaEdad_DE e IMC_DE según NivelAnemia




Figura 6: Distribución de la edad (meses) por NivelAnemia

Como en la serie de modelos previos aplicados a este dataset, ninguna variable antropométrica muestra una asociación fuerte de forma individual con el target, lo que anticipa un poder predictivo moderado del modelo.

4. Preprocesamiento y Configuración del Modelo

4.1. Codificación de Variables Categóricas

Las variables **Sexo** y **EducMadre** se transformaron mediante **One-Hot Encoding** (`drop_first=False`), generando 6 columnas dummy: **Sexo_Hombre**, **Sexo_Mujer**, **EducMadre_Primeria**, **EducMadre_Secundaria**, **EducMadre_Sin_educacion** y **EducMadre_Superior**. Combinadas con las 7 variables numéricas, el modelo utiliza **13 predictores** en total.

4.2. División del Dataset

$$\underbrace{80\%}_{\text{Entrenamiento}} + \underbrace{20\%}_{\text{Prueba}} = 100\% \implies 14\,238 + 3\,560 = 17\,798 \text{ niños} \quad (8)$$

La división se realizó de forma **estratificada** respecto al target (`NivelAnemia`), con `random_state=42`, preservando proporciones similares de anemia en ambos subconjuntos.

Cuadro 5: Distribución del target en entrenamiento y prueba

Clase	Entrenamiento (n=14 238)	Prueba (n=3 560)
Sin _Anemia	9 751	2 438
Con _Anemia	4 487	1 122

4.3. Escalado de Variables

Se aplicó **StandardScaler** únicamente sobre las 7 columnas numéricas, ajustado solo con el conjunto de entrenamiento:

$$x' = \frac{x - \bar{x}_{\text{train}}}{s_{\text{train}}} \quad (9)$$

Las columnas dummy generadas por el One-Hot Encoding no se escalan. Aunque Random Forest es invariante a transformaciones monótonas de los predictores (el escalado no afecta las particiones del árbol), se mantiene por consistencia metodológica con los demás modelos de la serie evaluados sobre el mismo dataset.

4.4. Implementación del Modelo

Se entrenaron y compararon dos configuraciones del clasificador `RandomForestClassifier` de `scikit-learn`:

- **Modelo Base:** 100 árboles (`n_estimators=100`), sin restricción de profundidad ni de mínimo de muestras por hoja (hiperparámetros por defecto).
- **Modelo Optimizado:** hiperparámetros seleccionados mediante `GridSearchCV` con validación cruzada estratificada de 5 particiones, optimizando ROC-AUC sobre la grilla `n_estimators` ∈ {150, 250}, `max_depth` ∈ {8, 12}, `min_samples_leaf` = 1, `class_weight` ∈ {None, balanced}.

Cuadro 6: Mejores hiperparámetros encontrados por GridSearchCV

Hiperparámetro	Valor óptimo
n_estimators	150
max_depth	8
min_samples_leaf	1
class_weight	None
Mejor ROC-AUC (validación cruzada)	0.6424

5. Resultados

5.1. Accuracy: Modelo Base vs. Modelo Optimizado

Cuadro 7: Precisión (accuracy) del modelo Random Forest

Modelo	Entrenamiento	Prueba
Base (n_estimators=100, sin restricciones)	0.9999	0.6663
Optimizado (GridSearchCV)	0.7284	0.6983




Figura 7: Comparación de accuracy: modelo base vs. modelo optimizado

El modelo base, sin restricción de profundidad, alcanza **99.99 %** de accuracy en entrenamiento pero solo **66.63 %** en prueba —una brecha de más de 33 puntos porcentuales que evidencia un **sobreajuste severo**: los árboles sin poda memorizan el ruido del conjunto de entrenamiento. El modelo optimizado limita la profundidad (`max_depth=8`), reduciendo la brecha train-test a **3.0 puntos** y mejorando el

accuracy de prueba a **69.83 %**.

5.2. Matriz de Confusión

Cuadro 8: Matriz de confusión — conjunto de prueba ($n = 3\,560$), modelo optimizado

	Predicho: Sin _Anemia	Predicho: Con _Anemia
Real: Sin _Anemia	2 305 (TN)	133 (FP)
Real: Con _Anemia	941 (FN)	181 (TP)




Figura 8: Matrices de confusión — modelo base vs. modelo optimizado

5.3. Métricas por Clase

Cuadro 9: Precisión, recall y F1-score por clase — conjunto de prueba, modelo optimizado

Clase	Precisión	Recall	F1-Score	Soporte
Con _Anemia	0.5764	0.1613	0.2521	1 122
Sin _Anemia	0.7101	0.9454	0.8110	2 438
Macro avg	0.6433	0.5534	0.5316	3 560
Weighted avg	0.6680	0.6983	0.6349	3 560

Métrica	Valor
Accuracy final	0.6983 (69.83 %)
ROC-AUC	0.6391
Precisión (Con_Anemia)	0.5764
Recall (Con_Anemia)	0.1613
Especificidad	0.9454
F1-Score (Con_Anemia)	0.2521
Falsa tasa de alarma	0.0546
Tasa de error	0.3017

Interpretación: el modelo identifica correctamente solo el **16.1 %** de los niños con anemia (*recall* bajo), mientras acierta el 94.5 % de los casos sin anemia (especificidad muy alta). El `GridSearchCV` seleccionó `class_weight=None` en lugar de `balanced` porque optimizó ROC-AUC promedio y no una métrica sensible al desbalance orientada a la clase positiva; en la práctica, esto produce un modelo conservador que rara vez predice *Con_Anemia* salvo que la evidencia sea muy fuerte.

5.4. Importancia de Variables




Figura 9: Importancia de variables por permutación — modelo optimizado

Cuadro 10: Importancia de variables por permutación (top 5)

Variable	Caída de ROC-AUC
Edad_meses	0.0286
Talla_cm	0.0247
TallaEdad_DE	0.0120
Peso_kg	0.0096
PesoEdad_DE	0.0085

Las variables antropométricas directas (edad y talla) resultan más informativas que los puntajes Z derivados, sugiriendo que el modelo captura principalmente el efecto de

la edad sobre el riesgo de anemia (mayor prevalencia en la primera infancia) más que patrones finos de desnutrición crónica.

5.5. Predicción sobre Casos Hipotéticos

Se evaluó el modelo optimizado sobre cuatro perfiles antropométricos y sociodemográficos hipotéticos, sin usar hemoglobina:

Cuadro 11: Predicciones sobre perfiles de ejemplo (modelo optimizado)

Perfil	Edad (m)	Diagnóstico	P(Con_Anemia)	P(Sin_Anemia)
Niño 1	6	Sin_Anemia	0.4176	0.5824
Niño 2	18	Sin_Anemia	0.3790	0.6210
Niño 3	36	Sin_Anemia	0.1911	0.8089
Niño 4	50	Sin_Anemia	0.3160	0.6840

El Niño 4 (50 meses, $Talla_{Edad_DE} = -2,9$, $Peso_{Edad_DE} = -2,3$, un perfil marcadamente compatible con desnutrición crónica y aguda) fue clasificado por el modelo como **Sin_Anemia**, con una probabilidad de anemia de solo 31.6 %. Este resultado ilustra en la práctica el bajo *recall* (16.1 %) reportado en la Tabla 9: el modelo optimizado, calibrado para maximizar ROC-AUC global sin ponderar clases, tiende a subestimar el riesgo de anemia incluso en perfiles antropométricos de alto riesgo.

6. Conclusiones

- 1. Capacidad predictiva moderada.** Usando 7 indicadores antropométricos y 2 variables sociodemográficas (sexo y educación materna), sin recurrir a la hemoglobina, el modelo Random Forest optimizado alcanzó un *accuracy* de **69.83 %** y un ROC-AUC de **0.6391** en el conjunto de prueba, desempeño similar al de otros clasificadores de la serie aplicados al mismo dataset.
- 2. El ajuste de hiperparámetros corrigió un sobreajuste severo.** El modelo base (sin restricciones) alcanzó 99.99 % de *accuracy* en entrenamiento pero solo 66.63 % en prueba (brecha de 33.4 puntos). Limitar la profundidad a `max_depth=8` mediante `GridSearchCV` redujo esa brecha a 3.0 puntos y mejoró el *accuracy* de prueba en 3.2 puntos porcentuales, evidenciando la importancia de la regularización en modelos de árboles.
- 3. Bajo recall en la clase de interés clínico.** El modelo identifica correctamente solo el **16.1 %** de los niños con anemia, frente a una especificidad del 94.5 % para niños sin anemia. `GridSearchCV` seleccionó `class_weight=None` por optimizar ROC-AUC promedio, una métrica que no penaliza directamente los falsos negativos; para un caso de uso de tamizaje clínico, donde detectar casos positivos suele ser prioritario, este balance debe revisarse.

4. **Edad y talla como variables más informativas.** La importancia por permutación ubica a `Edad_meses` y `Talla_cm` como los predictores más relevantes, por encima de los puntajes Z antropométricos derivados, lo que sugiere que el modelo captura sobre todo el patrón etario de la anemia infantil (mayor prevalencia en la primera infancia) más que patrones finos de desnutrición.
5. **Ventaja del ensamble frente a un único árbol.** Al promediar sobre múltiples árboles decorrelacionados (mediante *bagging* y aleatorización de variables), Random Forest reduce la varianza inherente a un árbol individual, lo que explica por qué el modelo optimizado, aun con `max_depth` moderado, generaliza mejor que un árbol de decisión sin ensamblar entrenado en condiciones similares.
6. **Prevención de *data leakage* y circularidad.** El escalado (`StandardScaler`) se ajustó exclusivamente sobre el conjunto de entrenamiento, y la hemoglobina se excluyó de los predictores por definir directamente al target, garantizando la validez metodológica de la evaluación.

6.1. Recomendaciones

Se recomienda comparar este modelo Random Forest con los demás clasificadores de la serie (Naive Bayes, K-NN, LDA, QDA, regresión logística) sobre el mismo conjunto de predictores, así como probar `class_weight="balanced"` u optimizar directamente sobre *recall* o F1 en lugar de ROC-AUC para mejorar la detección de casos `Con_Anemia`. También se sugiere ajustar el umbral de decisión (en lugar del valor por defecto de 0.5) y explorar la incorporación de variables adicionales del cuestionario del hogar (acceso a agua, saneamiento, altitud) que podrían mejorar la capacidad discriminativa, especialmente el *recall* de la clase `Con_Anemia`.