



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

REGRESIÓN LOGÍSTICA SIMPLE Y MÚLTIPLE

Anemia Infantil — ENDES 2024

Curso: Regresión Logística
Docente: Carpio Vargas Edgar Eloy
Estudiante: Luque Cornejo Zulema Yasmile
Dataset: RECH6_2024.csv (ENDES 2024)
(20 290 registros, 43 variables originales)
Variable objetivo: Presencia de anemia infantil
(Con_anemia / Sin_anemia)
Herramientas: Python 3 (statsmodels, scikit-learn, pandas)
Repositorio: [GitHub/REGRESIONLOGISTICA](#)
Semilla: 123
Fecha: 21 de junio de 2026

0 Índice

Introducción General	3
I Preparación del Dataset	4
1. Descripción del Dataset	4
2. Limpieza y Preparación de Datos	4
II Regresión Logística Simple (RLS)	6
3. Fundamento Teórico	6
4. Análisis Exploratorio de Datos	6
5. Estimación del Modelo	6
5.1. Ecuación del modelo	7
5.2. Odds Ratio e interpretación	7
6. Bondad de Ajuste	8
7. Evaluación del Modelo	8
7.1. Curva ROC y AUC	8
7.2. Matriz de confusión (umbral = 0.5)	9
7.3. Gráfico del modelo con intervalos de confianza	10
7.4. Predicción para nuevos valores	10
8. Resumen del Modelo Simple	11
III Regresión Logística Múltiple (RLM)	12
9. Fundamento Teórico	12
10. Diagnóstico de Multicolinealidad (VIF)	12
11. Selección de Variables	12

12.Comparación de Modelos Candidatos	13
13.Ajuste del Modelo Final (RLM)	14
13.1. Ecuación del modelo final	14
13.2. Odds Ratios e interpretación	15
14.Evaluación del Modelo Final	15
14.1. Validación cruzada 10-fold	15
14.2. Matriz de confusión	15
15.Análisis de Sensibilidad	17
16.Predicción para un Caso Nuevo	18
 Comparación entre Modelos y Conclusiones	 19
17.Resumen Comparativo	19
18.Conclusiones Generales	19

0 Introducción General

El presente informe desarrolla dos modelos de **regresión logística binaria** aplicados al problema de clasificar la presencia de **anemia infantil** a partir de variables antropométricas, usando los microdatos de la Encuesta Demográfica y de Salud Familiar (ENDES) 2024 del INEI, módulo RECH6.

La regresión logística estima la probabilidad de que una observación pertenezca a la clase positiva (presencia de anemia) en función de uno o más predictores, mediante la función logística:

$$P(Y = 1 | X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k}}$$

Se diferencian dos enfoques: (i) la **Regresión Logística Simple** (RLS), con un único predictor (`talla_edad_z`), que sirve como línea base de comparación; y (ii) la **Regresión Logística Múltiple** (RLM), que incorpora hasta 5 variables antropométricas y aplica métodos sistemáticos de selección de predictores.

Objetivos del Informe

- Preparar el dataset de anemia infantil desde el archivo crudo de ENDES, documentando cada paso de limpieza.
- Ajustar y evaluar un modelo de Regresión Logística Simple con `talla_edad_z` como predictor.
- Ajustar y evaluar un modelo de Regresión Logística Múltiple con 5 predictores antropométricos, aplicando selección de variables por múltiples métodos (SelectKBest, RFE, Forward, Backward, Lasso L1 y búsqueda exhaustiva).
- Comparar el desempeño de ambos modelos mediante matriz de confusión, curva ROC, AUC y validación cruzada de 10 pliegues.

Parte I

Preparación del Dataset

1 Descripción del Dataset

El archivo `RECH6_2024.csv` contiene **20 290 registros** de niños menores de 5 años con **43 variables** originales. Para este análisis se seleccionaron las siguientes variables:

Cuadro 1: Variables seleccionadas del dataset `RECH6_2024.csv`

Variable	Código ENDES	Descripción
<code>edad_meses</code>	HC1	Edad del niño en meses
<code>peso_kg</code>	HC2	Peso en kilogramos (valor crudo ÷ 10)
<code>talla_cm</code>	HC3	Talla en centímetros (valor crudo ÷ 10)
<code>talla_edad_z</code>	HC70	Z-score Talla/Edad (OMS, valor crudo ÷ 100)
<code>peso_edad_z</code>	HC71	Z-score Peso/Edad (OMS, valor crudo ÷ 100)
<code>grupo_anemia</code>	HC57A	Variable objetivo: nivel de anemia (Directriz OMS 2024 / RM 251-2024-MINSA)

Se excluyó deliberadamente la **hemoglobina** (HC53/HC56A) como predictor, ya que es la variable que *define* la anemia. Incluirla generaría circularidad y una fuga de información que invalidaría el análisis.

2 Limpieza y Preparación de Datos

El archivo de ENDES utiliza códigos numéricos para “valor no medido”, documentados en el diccionario de variables del INEI:

Cuadro 2: Códigos de “no medido” según el diccionario INEI

Variable	Significado	Rango válido	Código “no medido”
HC2	Peso (valor crudo)	< 999	9999
HC3	Talla (valor crudo)	< 9999	9999
HC70	Z-score Talla/Edad (OMS)	$ x < 9000$	9996, 9997, 9998
HC71	Z-score Peso/Edad (OMS)	$ x < 9000$	9996, 9997, 9998
HC57A	Nivel de anemia (OMS 2024)	1 : 4	9 (No sabe)

Listing 1: Preparación del dataset desde el archivo crudo

```
1 df_crudo = pd.read_csv("RECH6_2024.csv", sep=";", low_memory=False)
2
3 mask_validos = (
```

```

4      (datos['peso_kg_x10'] < 999) &
5      (datos['talla_cm_x10'] < 9999) &
6      (datos['anemia_oms'].isin([1, 2, 3, 4])) &
7      (datos['talla_edad_z_x100'].abs() < 9000) &
8      (datos['peso_edad_z_x100'].abs() < 9000)
9  )
10 datos = datos[mask_validos].copy()
11
12 # Conversion a unidades reales
13 datos['peso_kg'] = datos['peso_kg_x10'] / 10
14 datos['talla_cm'] = datos['talla_cm_x10'] / 10
15 datos['talla_edad_z'] = datos['talla_edad_z_x100'] / 100
16 datos['peso_edad_z'] = datos['peso_edad_z_x100'] / 100
17
18 # Variable objetivo binaria
19 datos['grupo_anemia'] = np.where(datos['anemia_oms'] == 4,
20                                'Sin_anemia', 'Con_anemia')

```

Las tres categorías de anemia positiva (Grave: 18 casos, Moderada: 1 371, Leve: 4 371) se unificaron en **Con_anemia** por ser numéricamente insuficientes para tratarlas por separado.

Cuadro 3: Resultado de la preparación del dataset

Descripción	Valor
Registros originales (crudo)	20 290
Filas excluidas (código “no medido”)	1 984
Registros válidos	18 306 (90.2 %)
Sin_anemia (HC57A = 4)	12 552 (68.6 %)
Con_anemia (HC57A = 1/2/3)	5 754 (31.4 %)

Parte II

Regresión Logística Simple (RLS)

3 Fundamento Teórico

La Regresión Logística Simple modela la probabilidad de pertenecer a la clase positiva en función de **un único predictor cuantitativo**:

$$\ln\left(\frac{P(Y = 1)}{1 - P(Y = 1)}\right) = \beta_0 + \beta_1 X$$

donde el miembro izquierdo es el *logit* o logaritmo de la razón de odds. Los parámetros β_0 y β_1 se estiman por **máxima verosimilitud** (MLE). El exponencial del coeficiente, e^{β_1} , es el **Odds Ratio** (OR) y cuantifica el efecto multiplicativo sobre las odds por cada unidad de incremento en X .

4 Análisis Exploratorio de Datos

Cuadro 4: Estadísticos descriptivos — `talla_edad_z` por grupo

Grupo	Media	Mediana	Mín.	Máx.
Sin_anemia	-0,822	—	-5,51	3,54
Con_anemia	-1,015	—	-5,51	3,54

Los niños con anemia presentan una puntuación `talla_edad_z` promedio más negativa (-1,015 vs -0,822), indicando mayor desnutrición crónica en ese grupo.




Figura 1: Izquierda: distribución de clases. Centro: histograma de `talla_edad_z`. Derecha: boxplot por grupo (los valores más negativos se concentran levemente en `Con_anemia`).

5 Estimación del Modelo

Listing 2: Ajuste del modelo RLS con statsmodels

```

1 X_sm = sm.add_constant(datos[['talla_edad_z']])
2 y_sm = datos['anemia']
3 modelo_sm = sm.Logit(y_sm, X_sm).fit()

```

Cuadro 5: Resultado de la estimación — Regresión Logística Simple (statsmodels)

Variable	Coef.	Std. Err.	z	P> z	IC 2.5 %	IC 97.5 %
Intercepto	-0,9616	0.022	-43,627	< 0,001	-1,005	-0,918
talla_edad_z	-0,1985	0.016	-12,452	< 0,001	-0,230	-0,167
$n = 18\,306$ Log-Likelihood: -11 317 AIC: 22 638,39 BIC: 22 654,02 Pseudo R^2 McFadden: 0,0069 LLR p-value: $4,69 \times 10^{-36}$						

5.1 Ecuación del modelo

$$\text{logit}(P(\text{anemia})) = -0,9616 + (-0,1985) \times \text{talla_edad_z}$$

$$\hat{P}(\text{anemia} = 1 \mid X) = \frac{e^{-0,9616-0,1985 X}}{1 + e^{-0,9616-0,1985 X}}$$

5.2 Odds Ratio e interpretación

Cuadro 6: Odds Ratios e intervalos de confianza al 95 % — RLS

Variable	OR	IC 2.5 %	IC 97.5 %
Intercepto	0.38227	0.36611	0.39915
talla_edad_z	0.82000	0.79477	0.84601

Por cada unidad que **aumenta** `talla_edad_z` (mejor talla para la edad), las odds de tener anemia se **reducen** un 18.0 % (OR = 0,8200, IC 95 %: 0.795–0.846). El predictor es estadísticamente significativo ($z = -12,45$, $p < 0,001$).

6 Bondad de Ajuste

Cuadro 7: Indicadores de bondad de ajuste — RLS

Indicador	Valor
Pseudo R ² McFadden	0.0069
Pseudo R ² Cox & Snell	0.0085
Pseudo R ² Nagelkerke	0.0120
AIC	22 638.39
BIC	22 654.02
Likelihood Ratio Test (χ^2 , gl = 1)	157.18
p-value del LRT	$4,69 \times 10^{-36}$

Los Pseudo R² son muy bajos (0.007–0.012), lo que refleja que un único predictor antropométrico captura una fracción mínima de la variabilidad en la presencia de anemia. El LRT es altamente significativo, confirmando que el modelo aporta información relevante frente al modelo nulo.

7 Evaluación del Modelo

7.1 Curva ROC y AUC

Cuadro 8: Métricas de la curva ROC — RLS

Métrica	Valor
AUC (modelo completo)	0.5560
AUC (prueba 30 %)	0.5602
AUC (CV 10-fold)	0.5558
Umbral óptimo	0.3137
Sensibilidad en umbral	0.5535
Especificidad en umbral	0.5307




Figura 2: Curva ROC — Regresión Logística Simple (AUC = 0.5560)

7.2 Matriz de confusión (umbral = 0.5)

Cuadro 9: Matriz de confusión — RLS (dataset completo, umbral = 0.5)

Real / Predicho	Sin_anemia	Con_anemia
Sin_anemia	12 547	5
Con_anemia	5 750	4

Cuadro 10: Métricas de desempeño — RLS

Métrica	Valor
Accuracy (entrenamiento)	68.56 %
Error de clasificación	31.44 %
Accuracy (prueba 30 %)	—
AUC-ROC	0.5560
AUC-ROC (CV 10-fold)	0.5558

7.3 Gráfico del modelo con intervalos de confianza




Figura 3: Curva logística ajustada con IC al 95 %. A medida que `talla_edad_z` aumenta (mejor crecimiento), la probabilidad estimada de anemia disminuye suavemente.

7.4 Predicción para nuevos valores

Cuadro 11: Probabilidades predichas para valores seleccionados de `talla_edad_z`

<code>talla_edad_z</code>	P(anemia)	Clasificación
0	0.2770	Sin_anemia
-1	0.2985	Sin_anemia
-2	0.3210	Sin_anemia
-3	0.3449	Sin_anemia

Con umbral = 0.5 el modelo clasifica casi todas las observaciones como **Sin_anemia**, porque las probabilidades estimadas se concentran entre 0.27 y 0.37, por debajo del umbral. Esto es consecuencia directa del bajo poder predictivo de un único predictor y del desbalance de clases (68.6 % sin anemia).

8 Resumen del Modelo Simple

Cuadro 12: Resumen ejecutivo — Regresión Logística Simple

Elemento	Valor
Variable dependiente	<code>anemia</code> (0 = Sin, 1 = Con)
Variable independiente	<code>talla_edad_z</code> (Z-score Talla/Edad, OMS)
Ecuación	$\text{logit} = -0,9616 + (-0,1985) \times \text{talla_edad_z}$
OR (<code>talla_edad_z</code>)	0.8200 (reducción de 18.0 % por unidad)
AIC	22 638.39
Pseudo R^2 McFadden	0.0069
AUC-ROC (completo)	0.5560
AUC-ROC (CV 10-fold)	0.5558
Significancia	$p < 0,001$

Parte III

Regresión Logística Múltiple (RLM)

9 Fundamento Teórico

La Regresión Logística Múltiple extiende el modelo simple a k predictores:

$$\ln\left(\frac{P(Y=1)}{1-P(Y=1)}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k$$

Cada β_j representa el cambio en el logit por unidad de X_j , *manteniendo las demás variables constantes*. El OR asociado a X_j es e^{β_j} e indica cuánto se multiplican las odds de la clase positiva por cada unidad de incremento en X_j (*ceteris paribus*).

Una ventaja clave del modelo múltiple sobre el simple es su capacidad de **controlar por variables confusoras**: la asociación observada entre `talla_edad_z` y anemia puede verse influenciada por la edad y el peso del niño, que el modelo múltiple aísla explícitamente.

10 Diagnóstico de Multicolinealidad (VIF)

Antes de seleccionar variables, se evaluó la multicolinealidad mediante el **Factor de Inflación de Varianza (VIF)**:

Cuadro 13: Factor de Inflación de Varianza (VIF) — 5 predictores

Variable	VIF
peso_kg	572.84
talla_cm	291.29
edad_meses	61.35
peso_edad_z	11.77
talla_edad_z	4.58

`peso_kg` y `talla_cm` presentan VIF extremadamente altos (> 100), indicando colinealidad severa entre sí y con las demás variables. `edad_meses` y `peso_edad_z` también superan el umbral preocupante de 10. Solo `talla_edad_z` ($VIF = 4.58$) no presenta multicolinealidad. Esto justifica la aplicación de métodos de selección de variables para construir un modelo más parsimonioso y estable.

11 Selección de Variables

Se aplicaron cuatro métodos de selección para identificar las variables con mayor poder predictivo, buscando $k = 3$ predictores en cada caso:

Cuadro 14: Variables seleccionadas por cada método

Método	Variables seleccionadas	Frecuencia
SelectKBest (ANOVA F)	talla_cm, peso_kg, edad_meses	—
RFE	edad_meses, talla_cm, talla_edad_z	—
Forward Selection	edad_meses, peso_kg, peso_edad_z	—
Backward Elimination	talla_cm, talla_edad_z, peso_edad_z	—
Lasso L1 ($C = 0,1$)	talla_cm, talla_edad_z	—
Más frecuentes (≥ 3 métodos)	talla_cm, edad_meses, talla_edad_z	3/4 o más




Figura 4: Frecuencia de selección de cada variable por los cuatro métodos. La línea roja indica el umbral de 3 métodos para ser considerada “frecuente”.

Las variables `talla_cm`, `edad_meses` y `talla_edad_z` fueron seleccionadas por al menos 3 de los 4 métodos y se adoptaron como predictores del modelo final.

12 Comparación de Modelos Candidatos

Se entrenaron y compararon 8 modelos candidatos (incluyendo una búsqueda exhaustiva de las 31 combinaciones posibles de las 5 variables):

Cuadro 15: Tabla comparativa de los 8 modelos candidatos (ordenados por AUC-ROC)

Modelo	N° vars	Acc. Train	Acc. Test	AUC-ROC	Log Loss
Frecuentes	3	0.6850	0.6868	0.6228	0.6021
RFE	3	0.6850	0.6868	0.6228	0.6021
Mejor Exhaustiva	3	0.6850	0.6868	0.6228	0.6021
Lasso L1	2	0.6859	0.6868	0.6225	0.6022
Backward	3	0.6858	0.6876	0.6224	0.6022
Completo	5	0.6846	0.6857	0.6220	0.6024
SelectKBest	3	0.6842	0.6860	0.6220	0.6023
Forward	3	0.6859	0.6860	0.6133	0.6053

Los modelos “Frecuentes”, RFE y la mejor combinación exhaustiva arrojan idéntico desempeño: Accuracy test = 68.68 % y AUC = 0.6228, con 3 variables. El modelo “Frecuentes” (`talla_cm`, `edad_meses`, `talla_edad_z`) se seleccionó como modelo final por su mayor AUC y mayor parsimonia frente al modelo completo.

La búsqueda exhaustiva de las 31 combinaciones confirmó que la mejor combinación de 3 variables (`edad_meses`, `talla_cm`, `talla_edad_z`) coincide con la selección por frecuencia:

Cuadro 16: Top 5 combinaciones de la búsqueda exhaustiva

Rango	Variables	Accuracy	AUC
1	<code>edad_meses</code> , <code>talla_cm</code> , <code>talla_edad_z</code>	0.6868	0.6228
2	<code>edad_meses</code> , <code>talla_cm</code> , <code>talla_edad_z</code> , <code>peso_edad_z</code>	0.6871	0.6227
3	<code>edad_meses</code> , <code>peso_kg</code> , <code>talla_cm</code> , <code>talla_edad_z</code>	0.6871	0.6227
4	<code>edad_meses</code> , <code>talla_cm</code>	0.6873	0.6225
5	<code>edad_meses</code> , <code>talla_cm</code> , <code>peso_edad_z</code>	0.6857	0.6225

13 Ajuste del Modelo Final (RLM)

Listing 3: Ajuste del modelo final con statsmodels

```

1 X_train_sm = sm.add_constant(X_train_final)      # talla_cm,
   edad_meses, talla_edad_z
2 modelo_sm = sm.Logit(y_train, X_train_sm)
3 resultado_sm = modelo_sm.fit(dis=0)

```

Cuadro 17: Resultado de la estimación — Regresión Logística Múltiple (statsmodels)

Variable	Coef.	Std. Err.	z	P> z	IC 2.5 %	IC 97.5 %
Intercepto	0,7329	0.090	8,177	< 0,001	0,557	0,909
<code>talla_cm</code>	-4,2057	0.593	-7,089	< 0,001	-5,368	-3,043
<code>edad_meses</code>	1,2164	0.360	3,378	0,001	0,511	1,922
<code>talla_edad_z</code>	0,1160	0.310	0,374	0,708	-0,492	0,724
$n_{\text{train}} = 14644$	Pseudo R ² McFadden: 0,03378			LLR p-value: $3,70 \times 10^{-133}$		

13.1 Ecuación del modelo final

En escala **normalizada** MinMax (0–1), los coeficientes de sklearn son:

$$\text{logit} = 0,7244 + (-3,0957) \times \text{talla_cm} + (0,5517) \times \text{edad_meses} + (-0,3594) \times \text{talla_edad_z}$$

13.2 Odds Ratios e interpretación

Cuadro 18: Coeficientes y Odds Ratios — modelo RLM (escala normalizada)

Variable	$\hat{\beta}$ (norm.)	OR	Efecto
talla_cm	-3,0957	0.0452	Mayor talla → odds se reducen 95.5 %
edad_meses	0,5517	1.7361	Mayor edad → odds aumentan 73.6 %
talla_edad_z	-0,3594	0.6981	Mejor Z-score → odds se reducen 30.2 %

Interpretación principal:

- **talla_cm** es el predictor más influyente: niños más altos (en valor absoluto) tienen muchas menos probabilidades de anemia, lo que se refleja en el OR = 0.045 (en escala normalizada). Es **significativa** ($p < 0,001$).
- **edad_meses**: a mayor edad del niño, mayor probabilidad de anemia. Este efecto resulta contra-intuitivo a primera vista, pero puede reflejar la madurez cronológica sin que el estado nutricional mejore proporcionalmente. Es **significativa** ($p = 0,001$).
- **talla_edad_z**: mejores Z-scores se asocian a menor anemia, pero su efecto **no es significativo** ($p = 0,708$) al controlar por **talla_cm** y **edad_meses**, con quienes comparte información.

14 Evaluación del Modelo Final

14.1 Validación cruzada 10-fold

Cuadro 19: Validación cruzada 10-fold — RLM

Métrica	Valor
CV Accuracy (media)	68.54 %
CV Accuracy (± 1 DE)	± 0.79 %
Scores individuales	0.690, 0.681, 0.688, 0.683, 0.690, 0.688, 0.689, 0.682, 0.684, 0.678

14.2 Matriz de confusión

Cuadro 20: Matriz de confusión — RLM (conjunto de prueba, $n = 3\,662$)

Real / Predicho	Sin _anemia	Con _anemia
Sin _anemia	2 463	48
Con _anemia	1 099	52

Cuadro 21: Métricas de desempeño — RLM (conjunto de prueba)

Métrica	Valor
Accuracy	68.68 %
Error de clasificación	31.32 %
Precisión (Con_anemia)	0.52
Recall (Con_anemia)	0.05
F1-score (Con_anemia)	0.08
Precisión (Sin_anemia)	0.69
Recall (Sin_anemia)	0.98
F1-score (Sin_anemia)	0.81
AUC-ROC	0.6228
Log Loss	0.6021
CV Accuracy (10-fold)	68.54 % (± 0.0079)




Figura 5: Matriz de confusión gráfica — RLM (conjunto de prueba)




Figura 6: Curva ROC — Regresión Logística Múltiple (AUC = 0.6228)

Al igual que la RLS, el modelo múltiple tiene un **recall muy bajo para Con_anemia** (5 %): clasifica la gran mayoría como Sin_anemia. Este fenómeno es consecuencia del fuerte desbalance de clases (68.6 % / 31.4 %) y de que las variables antropométricas disponibles no discriminan suficientemente entre ambos grupos. La accuracy global (68.68 %) es engañosa: un clasificador trivial que predijera siempre Sin_anemia ya alcanzaría ese porcentaje.

15 Análisis de Sensibilidad

Se evaluó el efecto de variar cada predictor (manteniendo los demás en su media) sobre la probabilidad predicha de Con_anemia:

Cuadro 22: Análisis de sensibilidad — $P(\text{Con_anemia})$ al variar cada predictor

Variable	Valor	$P(\text{Con_anemia})$
talla_cm	55.20	0.6933
talla_cm	71.15	0.5105
talla_cm	87.10	0.3247
talla_cm	103.05	0.1815
talla_cm	119.00	0.0928
edad_meses	6	0.2516
edad_meses	19	0.2785
edad_meses	33	0.3070
edad_meses	46	0.3371
edad_meses	59	0.3686
talla_edad_z	-5,51	0.3473
talla_edad_z	-3,25	0.3273
talla_edad_z	-0,98	0.3078
talla_edad_z	1,28	0.2890
talla_edad_z	3,54	0.2709

talla_cm es el predictor con mayor efecto: al pasar de 55.2 cm a 119.0 cm, la probabilidad de anemia cae de 69.3 % a 9.3 %. Por su parte, **edad_meses** tiene un efecto más moderado y positivo (a mayor edad, mayor probabilidad), mientras que **talla_edad_z** tiene el menor impacto marginal.

16 Predicción para un Caso Nuevo

Se clasificó un caso con los valores medios del conjunto de entrenamiento: **talla_cm** = 88.80, **edad_meses** = 32.44, **talla_edad_z** = -0,879.

Cuadro 23: Predicción RLM para el caso con valores medios

Resultado	Valor
$P(\text{Sin_anemia})$	0.6931 (69.31 %)
$P(\text{Con_anemia})$	0.3069 (30.69 %)
Clase predicha	Sin_anemia

Comparación entre Modelos y Conclusiones

17 Resumen Comparativo

Cuadro 24: Comparación RLS vs RLM — principales métricas

Métrica	RLS	RLM
N° de predictores	1	3
Predictores	talla_edad_z	talla_cm, edad_meses, talla_edad_z
AIC	22 638.39	—
Pseudo R ² McFadden	0.0069	0.0338
AUC-ROC (prueba)	0.5602	0.6228
AUC-ROC (CV 10-fold)	0.5558	—
Accuracy (prueba)	68.56 %	68.68 %
Recall Con_anemia	≈ 0 %	5 %
F1-score Con_anemia	≈ 0	0.08
Log Loss	—	0.6021
CV Accuracy (10-fold)	—	68.54 % (±0.79 %)

Hallazgo principal: el paso de 1 predictor (RLS) a 3 predictores (RLM) produce una mejora sustancial en el Pseudo R² McFadden (de 0.007 a 0.034) y en el AUC (de 0.556 a 0.623), aunque la accuracy global apenas varía (68.56 % → 68.68 %), evidenciando que ambos modelos sufren del mismo problema de clasificación sesgada hacia la clase mayoritaria.

18 Conclusiones Generales

Conclusiones — Regresión Logística Simple y Múltiple

- Ambos modelos son estadísticamente significativos pero con poder predictivo modesto:** el Likelihood Ratio Test fue significativo en la RLS ($\chi^2 = 157,18$, $p < 10^{-35}$) y en la RLM ($p < 10^{-130}$), pero los Pseudo R² son bajos (0.007 y 0.034, respectivamente). Las variables antropométricas capturan solo una fracción limitada de la variabilidad en la anemia infantil.
- La adición de predictores mejora el ajuste:** el modelo múltiple supera al simple en AUC (0.623 vs 0.556) y en Pseudo R² (0.034 vs 0.007), confirmando que `talla_cm` y `edad_meses` aportan información complementaria a `talla_edad_z`.
- La multicolinealidad es severa entre predictores crudos:** los VIF

de `peso_kg` (572.8) y `talla_cm` (291.3) reflejan una correlación casi lineal entre ambas variables. Los métodos de selección de variables permitieron identificar el subconjunto más informativo y menos colineal.

4. **talla_edad_z pierde significancia en el modelo múltiple:** al controlar por `talla_cm` (que contiene información similar), `talla_edad_z` no es significativa ($p = 0,708$). Sin embargo, se mantiene en el modelo porque es seleccionada consistentemente por múltiples métodos y su exclusión no mejora el AUC.
5. **El desbalance de clases es el principal obstáculo:** con un 68.6 % de la muestra sin anemia, ambos modelos tienden a clasificar casi todo como `Sin_anemia`. Técnicas de remuestreo (SMOTE, undersampling), ajuste de umbrales o modelos con pesos de clase podrían mejorar sustancialmente el recall para `Con_anemia`.
6. **Recomendación:** para un estudio de tamizaje de salud pública donde importa identificar correctamente a los niños *con* anemia, se recomienda incorporar variables socioeconómicas, dietéticas y geográficas, y aplicar técnicas de balanceo de clases. Con las variables disponibles, la RLM con `talla_cm + edad_meses + talla_edad_z` constituye la mejor aproximación con poder discriminativo moderado ($AUC = 0.623$).