



UNIVERSIDAD NACIONAL DEL ALTIPLANO

Escuela Profesional de Ingeniería Estadística e Informática

XGBOOST

Curso: Aprendizaje Supervisado
Docente: Carpio Vargas Edgar Eloy
Estudiante: Luque Cornejo Zulema Yasmile
Dataset I: `datosestresyansiedad.xlsx`
(1 200 registros, 13 variables)
Dataset II: `datossalarios.xlsx`
(250 000 registros, 10 variables)
Repositorio: [GitHub/XGBOOST](#)
Lenguajes: Python 3 / R (tidymodels)
Librería: XGBoost 3.2.0
Fecha: 15 de mayo de 2026

0 Índice

I Predicción de Nivel de Estrés en Adolescentes	3
1. Introducción	3
2. Descripción del Dataset	3
3. Análisis Exploratorio de Datos (EDA)	4
3.1. Distribución de la variable objetivo	4
3.2. Matriz de correlaciones	5
3.3. Preprocesamiento	5
4. Procedimiento de Modelado	5
4.1. Partición de datos	5
4.2. Modelo XGBoost Base	5
4.3. Optimización de Hiperparámetros (GridSearchCV)	6
5. Resultados	6
5.1. Métricas de evaluación	6
5.2. Validación cruzada (10 folds)	7
5.3. Importancia de variables	7
5.4. Predicciones individuales	7
5.4.1. Perfil único	7
5.4.2. Múltiples perfiles	8
6. Conclusiones del Análisis I	8
II Predicción de Salarios en el Sector Tecnológico	10
7. Introducción	10
8. Descripción del Dataset	10
9. Análisis Exploratorio de Datos (EDA)	11
9.1. Distribución del salario	11
9.2. Salario promedio por categoría	11

9.3. Correlaciones entre variables numéricas	12
9.4. Preprocesamiento	12
10.Procedimiento de Modelado	12
10.1. Partición estratificada	12
10.2. Optimización de Hiperparámetros (GridSearchCV)	12
11.Resultados	13
11.1. Métricas de evaluación	13
11.2. Validación cruzada (5 folds)	13
11.3. Importancia de variables	14
11.4. Curva de aprendizaje	14
11.5. Predicciones para nuevos perfiles	14
11.5.1. Análisis contextual: Data Scientist en Healthcare	14
12.Conclusiones del Análisis II	15

Parte I

Predicción de Nivel de Estrés en Adolescentes

1 Introducción

El bienestar emocional de los adolescentes es un problema de salud pública de creciente relevancia. El uso intensivo de redes sociales, el déficit de sueño y la presión académica han sido identificados como factores de riesgo para el estrés crónico en jóvenes de entre 13 y 19 años.

Este primer análisis tiene como objetivo construir un modelo predictivo del **nivel de estrés** (`stress_level`, escala discreta 1–10) a partir de variables socioemocionales y de hábitos digitales, utilizando el algoritmo **XGBoost** (*eXtreme Gradient Boosting*).

Objetivos del Análisis I

- Explorar la distribución de `stress_level` y sus correlaciones con predictores clave.
- Entrenar un modelo XGBoost base y un modelo optimizado mediante *Grid Search* con validación cruzada.
- Comparar ambos modelos con métricas de regresión estándar.
- Identificar las variables de mayor importancia predictiva.
- Generar predicciones individuales y para múltiples perfiles.

2 Descripción del Dataset

El conjunto de datos *Teen Mental Health* contiene información de **1 200 adolescentes** (13–19 años) con **13 variables**:

Cuadro 1: Variables del dataset `datosestresyansiedad.xlsx`

Variable	Tipo	Descripción
age	Numérica	Edad (13–19 años)
gender	Categorica	Género (male/female)
daily_social_media_hours	Numérica	Horas diarias en redes sociales
platform_usage	Categorica	Plataforma usada (Instagram, TikTok, Both)
sleep_hours	Numérica	Horas de sueño diarias
screen_time_before_sleep	Numérica	Horas de pantalla antes de dormir
academic_performance	Numérica	Rendimiento académico (0–4)
physical_activity	Numérica	Actividad física (horas)
social_interaction_level	Categorica	Nivel de interacción social (low/medium/high)
anxiety_level	Numérica	Nivel de ansiedad (1–10)
addiction_level	Numérica	Nivel de adicción digital (1–10)
depression_label	Binaria	Etiqueta de depresión (0/1)
stress_level	Numérica	Variable objetivo (1–10)

Valores nulos: ninguno. El dataset está completo.

Estadísticas descriptivas de `stress_level`: media = 5,45, desviación estándar = 2,90, rango [1, 10]. La distribución es aproximadamente uniforme a lo largo de toda la escala.

3 Análisis Exploratorio de Datos (EDA)

3.1 Distribución de la variable objetivo

El nivel de estrés presenta una distribución relativamente uniforme, con frecuencias de entre 104 y 139 observaciones en cada valor entero de la escala 1–10. Esto implica que el modelo debe aprender a distinguir niveles sin la ventaja de una clase dominante.

Cuadro 2: Distribución de `stress_level`

Nivel	Frecuencia
1	134
2	108
3	116
4	139
5	129
6	114
7	106
8	104
9	122
10	128

3.2 Matriz de correlaciones

El mapa de calor de correlaciones (calculado con `df.corr()`) revela:

- `anxiety_level` ↔ `stress_level`: $r = 0,17$ (correlación positiva más fuerte del conjunto).
- `depression_label` ↔ `daily_social_media_hours`: $r = 0,18$ (correlación relevante aunque no con el target).
- Las demás correlaciones con `stress_level` son menores a $|0,05|$, lo que sugiere relaciones **no lineales** predominantes — justificando el uso de modelos de ensamblado como XGBoost.

3.3 Preprocesamiento

Se aplicó codificación ordinal manual:

Listing 1: Codificación de variables categóricas

```

1 df_encoded['gender'] = df_encoded['gender'].map({'male': 1, '
  female': 0})
2 df_encoded['platform_usage'] = df_encoded['platform_usage'].map(
3     {'Instagram': 0, 'TikTok': 1, 'Both': 2})
4 df_encoded['social_interaction_level'] = \
5     df_encoded['social_interaction_level'].map(
6     {'low': 0, 'medium': 1, 'high': 2})

```

La variable `depression_label` fue excluida de los predictores por ser una etiqueta adicional de salida (posible fuga de información).

4 Procedimiento de Modelado

4.1 Partición de datos

Se realizó una partición **80 %/20 %** sin estratificación explícita:

- Entrenamiento: 960 observaciones.
- Prueba: 240 observaciones.

4.2 Modelo XGBoost Base

El primer modelo se entrenó con los hiperparámetros por defecto de `XGBRegressor`, usando la función objetivo `reg:squarederror` (error cuadrático).

Listing 2: Entrenamiento del modelo base

```

1 xgb_base = XGBRegressor(

```

```

2     objective='reg:squarederror',
3     random_state=42, n_jobs=-1, verbosity=0)
4 xgb_base.fit(X_train, y_train)
5 y_pred_base = xgb_base.predict(X_test)

```

4.3 Optimización de Hiperparámetros (GridSearchCV)

Se realizó una búsqueda exhaustiva en una grilla de **216 combinaciones** con **validación cruzada de 5 folds**:

Listing 3: Grilla de hiperparámetros

```

1 param_grid = {
2     'n_estimators'      : [100, 200, 300],
3     'max_depth'         : [3, 5, 7],
4     'learning_rate'     : [0.05, 0.1, 0.2],
5     'subsample'         : [0.8, 1.0],
6     'colsample_bytree'  : [0.8, 1.0],
7     'min_child_weight' : [1, 3]
8 }
9 grid_search = GridSearchCV(
10     estimator=xgb_cv, param_grid=param_grid,
11     cv=5, scoring='neg_root_mean_squared_error', n_jobs=-1)
12 grid_search.fit(X_train, y_train)

```

Mejores hiperparámetros encontrados:

Cuadro 3: Hiperparámetros óptimos — Análisis I (Estrés)

Hiperparámetro	Valor óptimo
colsample_bytree	0.8
learning_rate	0.05
max_depth	3
min_child_weight	1
n_estimators	100
subsample	0.8

5 Resultados

5.1 Métricas de evaluación

Cuadro 4: Comparación de métricas — Análisis I (Estrés)

Modelo	RMSE	MAE	R ²	MAPE (%)
XGBoost Base	3.3373	2.7660	-0,4364	94.17
XGBoost Optimizado	2.7882	2.3915	-0,0026	83.93

Interpretación de las métricas

El modelo optimizado reduce el RMSE en un **16.45 %** respecto al base. Sin embargo, el coeficiente R^2 negativo (próximo a cero en el optimizado) indica que las variables disponibles tienen **capacidad predictiva muy limitada** para `stress_level`. Esto es consistente con las bajas correlaciones observadas en el EDA.

5.2 Validación cruzada (10 folds)

Para obtener una estimación robusta e imparcial del error de generalización se realizó una validación cruzada de **10 folds** sobre el dataset completo:

Cuadro 5: Resultados de validación cruzada 10-fold

Estadístico	RMSE
Por fold	3.066, 2.925, 2.919, 2.894, 3.089, 2.800, 3.106, 2.891, 3.051, 2.813
Media	2.9554
Desviación estándar	0.1079
IC 95 %	[2.74, 3.17]

El RMSE medio en CV (2.96) es consistente con el obtenido en test (2.79), indicando que **no hay sobreajuste significativo**.

5.3 Importancia de variables

Las variables con mayor capacidad predictiva según el F-score de XGBoost son:

1. `age` — 0,124
2. `anxiety_level` — 0,116
3. `physical_activity` — 0,096
4. `academic_performance` — 0,095
5. `daily_social_media_hours` — 0,093

La variable `social_interaction_level` es la de menor importancia (0,067), lo que sugiere que el nivel de interacción social tiene poca influencia predictiva directa sobre el estrés en este dataset.

5.4 Predicciones individuales

5.4.1. Perfil único

Listing 4: Predicción de un adolescente individual

```

1 nuevo_registro = {
2     'age': 16, 'gender': 1,
3     'daily_social_media_hours': 5.0,
4     'platform_usage': 2,      # Both
5     'sleep_hours': 6.5,
6     'screen_time_before_sleep': 2.0,
7     'academic_performance': 3.0,
8     'physical_activity': 1.0,
9     'social_interaction_level': 1, # medium
10    'anxiety_level': 5,
11    'addiction_level': 6
12 }
13 prediccion = xgb_opt.predict(pd.DataFrame([nuevo_registro]))[0]
14 # Resultado: 5.44 / 10 -> Nivel: Medio

```

5.4.2. Múltiples perfiles

Cuadro 6: Predicciones para cinco perfiles de adolescentes

Perfil	Horas redes	Sueño	Ansiedad	Estrés pred.	Nivel
Adolescente saludable	1.5	8.5	2	5.50	Medio
Alto uso redes + poco sueño	7.5	5.0	8	5.40	Medio
Perfil promedio	4.0	6.5	5	5.44	Medio
Estrés elevado + adicción	6.0	4.5	9	5.34	Medio
Activo y equilibrado	2.5	7.5	3	5.44	Medio

Observación crítica: Todos los perfiles, incluyendo el de “Estrés elevado + adicción” y el “Adolescente saludable”, reciben predicciones muy similares ($\approx 5,4$). Esto refleja la **escasa señal predictiva** contenida en las variables del dataset para distinguir niveles de estrés individuales.

6 Conclusiones del Análisis I

Conclusiones — Predicción de Estrés

1. **Mejora moderada:** El modelo optimizado reduce el RMSE en 16.45 % y el MAE en 13.54 % respecto al modelo base, pero ambos presentan un R^2 cercano o inferior a cero.
2. **Capacidad predictiva limitada:** Las variables del dataset tienen correlaciones muy bajas con `stress_level` ($|r| < 0,17$), lo que indica que el nivel de estrés es un fenómeno **multifactorial** no capturado completamente por las variables disponibles.

3. **Sin sobreajuste:** La validación cruzada de 10 folds confirma que el RMSE en CV ($2,96 \pm 0,11$) es coherente con el test (2,79), por lo que el modelo no memoriza los datos de entrenamiento.
4. **Variables más relevantes:** La edad (`age`) y el nivel de ansiedad (`anxiety_level`) son los predictores con mayor poder discriminativo, lo que es teóricamente coherente.
5. **Recomendación:** Para mejorar la capacidad predictiva se sugiere incorporar variables adicionales (historial clínico, contexto familiar, calidad del sueño subjetiva) y explorar modelos de clasificación ordinal en lugar de regresión continua.

Parte II

Predicción de Salarios en el Sector Tecnológico

7 Introducción

La determinación justa y competitiva de salarios en el sector tecnológico es un problema relevante tanto para los empleados como para las organizaciones. Las variaciones salariales dependen de múltiples factores: experiencia, educación, título profesional, industria y localización geográfica, entre otros.

Este segundo análisis construye un modelo predictivo del **salario anual en USD** a partir de variables laborales y demográficas, usando XGBoost sobre un gran dataset de **250 000 registros**.

Objetivos del Análisis II

- Explorar la distribución salarial y las diferencias por categoría.
- Entrenar un modelo XGBoost base y optimizarlo mediante GridSearchCV.
- Evaluar el desempeño con RMSE, MAE, R^2 y MAPE.
- Identificar los factores más influyentes en el salario.
- Generar predicciones para perfiles laborales específicos.

8 Descripción del Dataset

El conjunto de datos `datossalarios.xlsx` contiene **250 000 registros** con **10 variables**:

Cuadro 7: Variables del dataset `datossalarios.xlsx`

Variable	Tipo	Descripción
<code>titulo_profesional</code>	Categórica	Rol/cargo (12 categorías)
<code>anios_experiencia</code>	Numérica	Años de experiencia (0–20)
<code>nivel_educativo</code>	Categórica	Nivel educativo (5 categorías)
<code>numero_habilidades</code>	Numérica	Número de habilidades técnicas (1–19)
<code>industria</code>	Categórica	Sector industrial (10 categorías)
<code>tamaño_empresa</code>	Categórica	Tamaño de empresa (5 categorías)
<code>ubicación</code>	Categórica	País/región (10 categorías)
<code>trabajo_remoto</code>	Categórica	Modalidad de trabajo (3 categorías)
<code>certificaciones</code>	Numérica	Número de certificaciones (0–5)
<code>salario</code>	Numérica	Variable objetivo (USD)

Estadísticas descriptivas de salario:

Cuadro 8: Estadísticas descriptivas de la variable `salario` (USD)

Estadístico	Valor
Observaciones	250 000
Media	\$145 718
Desv. estándar	\$37 408
Mínimo	\$31 867
Q1	\$119 358
Mediana	\$143 453
Q3	\$169 492
Máximo	\$333 046

Valores nulos: ninguno. El dataset está completamente limpio.

9 Análisis Exploratorio de Datos (EDA)

9.1 Distribución del salario

La distribución de `salario` es aproximadamente **normal (campana de Gauss)**, centrada alrededor de \$145 718. El boxplot muestra pocos valores atípicos en la cola superior, lo que indica que salarios extremadamente altos son raros pero existen.

9.2 Salario promedio por categoría

Cuadro 9: Salario promedio (USD) por título profesional — Top 5

Título Profesional	Salario Promedio
AI Engineer	\$175 490
Machine Learning Engineer	\$165 530
Product Manager	\$157 636
Cloud Engineer	\$152 103
DevOps Engineer	\$146 953

Cuadro 10: Salario promedio (USD) por modalidad de trabajo remoto

Modalidad	Salario Promedio
Yes (Totalmente remoto)	\$149 398
Hybrid (Híbrido)	\$145 975
No (Presencial)	\$142 302

9.3 Correlaciones entre variables numéricas

- `anios_experiencia` $\leftrightarrow$ `salario`: $r = 0,44$ (correlación positiva moderada — la más fuerte).
- `numero_habilidades` $\leftrightarrow$ `salario`: $r = 0,13$.
- `certificaciones` $\leftrightarrow$ `salario`: $r = 0,07$.
- Las correlaciones entre predictores numéricos son prácticamente 0, descartando problemas de multicolinealidad.

9.4 Preprocesamiento

Se utilizó `OrdinalEncoder` de `scikit-learn` para la codificación de las 6 variables categóricas, con manejo de categorías desconocidas:

10 Procedimiento de Modelado

10.1 Partición estratificada

Se realizó una partición **80 %/20 %** estratificada por cuartiles del salario para garantizar representación proporcional:

- Entrenamiento: 200 000 observaciones.
- Prueba: 50 000 observaciones.

10.2 Optimización de Hiperparámetros (GridSearchCV)

Idéntica grilla que en el Análisis I (**216 combinaciones, 5-fold CV**), totalizando **1 080 ajustes**:

Mejores hiperparámetros encontrados:

Cuadro 11: Hiperparámetros óptimos — Análisis II (Salarios)

Hiperparámetro	Valor óptimo
<code>colsample_bytree</code>	0.8
<code>learning_rate</code>	0.05
<code>max_depth</code>	7
<code>min_child_weight</code>	3
<code>n_estimators</code>	300
<code>subsample</code>	0.8

A diferencia del análisis de estrés, el modelo de salarios requiere mayor profundidad (`max_depth = 7`) y más árboles (`n_estimators = 300`), lo que refleja la mayor complejidad estructural del problema (mayor n , relaciones no lineales más marcadas).

11 Resultados

11.1 Métricas de evaluación

Cuadro 12: Comparación de métricas — Análisis II (Salarios)

Modelo	RMSE (USD)	MAE (USD)	R ²	MAPE (%)
XGBoost Base	\$5 543.68	\$4 418.62	0.9782	3.25
XGBoost Optimizado	\$5 200.27	\$4 139.76	0.9808	3.05
Mejora (%)	6.19 %	6.32 %	+0.27 pp	6.15 %

Interpretación de las métricas — Salarios

El modelo optimizado alcanza un $R^2 = 0,9808$, lo que significa que explica el **98.08 % de la varianza salarial**. El RMSE de \$5 200 sobre salarios medios de \$145 718 representa un error relativo de tan solo el **3.57 %** — un desempeño **excelente** para este tipo de problema.

11.2 Validación cruzada (5 folds)

Cuadro 13: Validación cruzada 5-fold — XGBoost Optimizado (Salarios)

Fold	RMSE (USD)
Fold 1	\$5 184.50
Fold 2	\$5 173.97
Fold 3	\$5 208.27
Fold 4	\$5 200.66
Fold 5	\$5 188.23
Media	\$5 191.13
Desv. estándar	\$12.10
CV del modelo	0.2 %

La **estabilidad excepcional** ($CV = 0.2\%$) confirma que el modelo generaliza de forma consistente y sin sobreajuste, incluso con 250 000 registros y 1 080 ajustes en el grid search.

11.3 Importancia de variables

Cuadro 14: Importancia de variables (F-score) — Modelo de Salarios

Variable	Importancia	Rango
tamaño_empresa	0.246	1
ubicación	0.252	2
anios_experiencia	0.285	3
nivel_educativo	0.132	4
titulo_profesional	0.130	5
numero_habilidades	0.072	6
trabajo_remoto	0.059	7
certificaciones	0.032	8
industria	0.060	9

Las variables más influyentes son los **años de experiencia**, la **ubicación geográfica** y el **tamaño de la empresa** — resultado coherente con la lógica del mercado laboral tecnológico.

11.4 Curva de aprendizaje

La curva de aprendizaje muestra que el RMSE en entrenamiento decrece sostenidamente mientras el RMSE en test converge desde 35 000 a 5 200 USD en aproximadamente 100 árboles, estabilizándose thereafter. No se observa divergencia entre ambas curvas, lo que descarta sobreajuste.

11.5 Predicciones para nuevos perfiles

Cuadro 15: Predicciones salariales para cinco perfiles de ejemplo

Perfil	Años exp.	Educación	País	Salario pred.
Data Scientist (Healthcare)	5	Master	USA	\$193 118
AI Engineer senior (remoto, PhD)	12	PhD	Canada	\$270 463
Frontend junior (startup, India)	3	Bachelor	India	\$60 155
Business Analyst (Finance, híbrido)	8	Bachelor	Australia	\$102 610
Product Manager experimentado	15	Master	USA	\$247 196

11.5.1. Análisis contextual: Data Scientist en Healthcare

Para la predicción de \$193 118 del primer perfil:

- El salario predicho supera al **89.3 %** del dataset histórico.

- Está por encima de la media de \$145 718 en **+\$47 400**.
- Dentro del rol “Data Scientist”, la predicción supera la media del rol (\$147 250 aprox.), lo que refleja el efecto positivo de trabajar en USA con 5 años de experiencia y formación de maestría.

12 Conclusiones del Análisis II

Conclusiones — Predicción de Salarios

1. **Excelente desempeño predictivo:** El modelo optimizado alcanza $R^2 = 0,9808$ y $MAPE = 3,05\%$, situándolo entre los modelos de alta precisión para predicción salarial.
2. **Mejora significativa sobre el base:** La optimización de hiperparámetros reduce el RMSE en $\approx 6,2\%$ y el MAE en $\approx 6,3\%$. Para salarios de seis cifras, esto representa ahorros/diferencias de **\$343 por observación en promedio**.
3. **Altísima estabilidad en CV:** El coeficiente de variación del RMSE entre folds es de tan solo 0.2% , reflejando un modelo robusto y sin sobreajuste a pesar del uso de 250 000 observaciones.
4. **Factores determinantes del salario:** Los años de experiencia, la ubicación geográfica y el tamaño de la empresa son los principales determinantes, con los títulos de IA/ML liderando los salarios por categoría profesional.
5. **Aplicabilidad práctica:** El modelo puede emplearse en sistemas de benchmarking salarial, negociación de ofertas y planificación de recursos humanos en el sector tecnológico.
6. **Limitaciones:** La codificación ordinal de variables como `nivel_educativo` o `industria` asume un orden que puede no ser plenamente correcto. Se recomienda explorar codificación *target encoding* o *embeddings categóricos* como alternativa.